

RAPPORT DE STAGE DE FIN D'ÉTUDES

Cycle Ingénieur — 5^{ème} Année

Spécialité Big Data & Intelligence Artificielle

ADMP AI Studio : Modernisation et automatisation des pipelines ETL de migration de données via une architecture d'IA agentique

Mohamed KACHMAR

127418

Sous la direction de :

Encadrant Académique

Ilias TOUGUI

Anouar RIAD SOLH

Université Internationale de Rabat

Tutrice en Entreprise

Amal Mesbah

AFD.tech Part of Accenture

Ce stage a été effectué au sein de :

AFD.tech Part of Accenture — Rabat, Maroc

2025 – 2026

Remerciements

Avant d'entamer la présentation de ce travail, je tiens à exprimer ma profonde gratitude à toutes les personnes qui, de près ou de loin, ont contribué à la réussite de ce stage de fin d'études et à la réalisation de ce rapport.

Je souhaite tout d'abord adresser mes sincères remerciements à mon maître de stage chez AFD.Tech, Mme Amal Mesbah, pour son accueil, sa disponibilité et la confiance qu'il m'a témoignée tout au long de cette mission de migration de données. Ses conseils techniques et sa vision stratégique ont été essentiels à ma progression.

Mes remerciements s'adressent également à l'ensemble de l'équipe ADMP pour leur intégration chaleureuse et leur soutien au quotidien. Évoluer au sein d'un environnement aussi stimulant que celui d'Accenture a été une opportunité d'apprentissage inestimable.

Je tiens à exprimer ma reconnaissance envers mon encadrant pédagogique à l'Université Internationale de Rabat UIR, professeur Tougui, pour son suivi attentif et le temps qu'il a consacré à l'orientation de mon projet.

Enfin, je ne saurais clore ces remerciements sans exprimer ma gratitude la plus profonde à ma famille. À mes parents, pour leur soutien inconditionnel et leurs encouragements constants durant toutes ces années d'études. À mon frère et à ma sœur, pour leur présence et leur complicité. Ce travail est aussi le fruit de leur amour et de leur confiance.

Que tous ceux qui ont contribué à faire de ce projet une expérience enrichissante trouvent ici l'expression de ma haute considération.

Abstract

Traditional data migration processes, particularly during the analysis and design phases, suffer from a heavy reliance on manual tasks and fragmented management tools (such as spreadsheets and decentralized office documents). This classic approach, prone to human error, results in extended delays and a lack of traceability that limits overall project efficiency.

The objective of this project is to design and develop the ADMP AI Studio, an intelligent platform aimed at modernizing system architecture and automating data migration ETL (Extract, Transform, Load) pipelines within the Accenture group. The goal is to drastically reduce manual intervention while standardizing the generation of transformation rules.

The adopted methodology relies on deploying an innovative Agentic Artificial Intelligence architecture. A multi-agent system, orchestrated via LangGraph and integrating advanced Large Language Models (LLMs) using "Chain of Thought" reasoning, was implemented. Technically, the architecture transitions toward centralized storage under PostgreSQL leveraging the JSON format. Various specialized agents (Scope, Design, Validation) work in synergy to ingest data models, autonomously perform Gap Analysis, and validate the consistency of operations.

The main results highlight the successful automation of critical design deliverables (Data Mapping, Table Mapping, SDS, TDS). The new infrastructure establishes a continuous, secure, and auditable data flow, thereby ensuring data quality before injection into target systems, and paving the way for the automation of complex transformation phases.

Keywords : Data migration, Agentic Artificial Intelligence, ETL pipeline, System architecture, Automation.

Résumé

Les processus traditionnels de migration de données, notamment lors de la phase d'analyse et de conception, souffrent d'une forte dépendance aux tâches manuelles et d'une fragmentation des outils de gestion (tableurs, documents bureautiques décentralisés). Cette approche classique, sujette aux erreurs humaines, entraîne des délais prolongés et un manque de traçabilité limitant l'efficacité globale des projets.

L'objectif de ce projet est de concevoir et développer l'ADMP AI Studio, une plateforme intelligente visant à moderniser l'architecture système et à automatiser les pipelines ETL (Extract, Transform, Load) de migration de données au sein du groupe Accenture. Le but est de réduire drastiquement l'intervention manuelle tout en standardisant la production des règles de transformation.

La méthode adoptée repose sur le déploiement d'une architecture novatrice d'Intelligence Artificielle agentique. Un système multi-agents, orchestré via LangGraph et intégrant des modèles de langage avancés (LLMs) utilisant le raisonnement "Chain of Thought", a été mis en place. Techniquement, l'architecture transitionne vers un stockage centralisé sous PostgreSQL exploitant le format JSON. Différents agents spécialisés (Scope, Design, Validation) travaillent en synergie pour ingérer les modèles de données, effectuer des analyses d'écarts (Gap Analysis) de manière autonome, et valider la cohérence des opérations.

Les principaux résultats mettent en évidence l'automatisation réussie de la génération des livrables critiques de conception (Data Mapping, Table Mapping, SDS, TDS). La nouvelle infrastructure établit un flux de données continu, sécurisé et auditable, fiabilisant ainsi la qualité des données avant leur injection vers les systèmes cibles, et préparant le terrain pour l'automatisation des phases de transformation complexes.

Mots-clés : Migration de données, Intelligence Artificielle agentique, Pipeline ETL, Architecture système, Automatisation.

Table des matières

Table des figures

Liste des tableaux

List of Abbreviations

A two-column table listing every acronym or abbreviation used in the report (e.g. API, REST, UML, DB) alongside its full meaning. List them in alphabetical order. Only include abbreviations actually used in the document.

API	Application Programming Interface
DB	Database

Chapitre 1

Introduction Générale

1.1 Introduction Générale

La transformation numérique des entreprises impose aujourd'hui des défis sans précédent en matière de gestion et d'intégration des données. Parmi ces défis, la migration de données, processus consistant à transférer de manière sécurisée et contrôlée les données d'un système source vers un système cible, constitue un enjeu stratégique majeur. C'est dans ce contexte que s'inscrit le présent Projet de Fin d'Études, réalisé au sein de l'équipe ADMP (Accenture Data Migration Platform) d'Accenture, et portant sur le développement d'une plateforme de migration de données basée sur l'intelligence artificielle pour l'amélioration et l'optimisation des processus d'intégration des données.

1.2 Organisme d'accueil

1.2.1 Présentation d'Accenture

Accenture plc est une entreprise multinationale de services professionnels, fondée en 1989 sous le nom d'Andersen Consulting avant de devenir Accenture en 2001, et dont le siège social est situé à Dublin, en Irlande. Cotée à la Bourse de New York (NYSE : ACN), Accenture figure parmi les plus grandes entreprises mondiales de conseil et de services technologiques. En termes de performance financière, l'exercice fiscal 2025 (clos le 31 août 2025) témoigne de la solidité et de l'envergure du groupe, comme l'illustre le Tableau ??.

Indicateur	Valeur (FY 2025)
Chiffre d'affaires	69,7 milliards USD (+7%)
Résultat net (GAAP)	7,83 milliards USD
Nouvelles commandes (<i>bookings</i>)	80,6 milliards USD
Effectif mondial	≈ 779 000 collaborateurs
Clients servis	≈ 9 000 dans plus de 120 pays
Bureaux et opérations	200+ villes dans 52 pays

TABLE 1.1 – Indicateurs clés d'Accenture pour l'exercice fiscal 2025



FIGURE 1.1 – Logo du groupe Accenture

L'entreprise s'articule autour de plusieurs domaines d'activité complémentaires : Strategy & Consulting, Technology, Operations, Accenture Song (ex-Interactive) et Industry X. Sa stratégie repose sur l'ambition d'être le *reinvention partner of choice* de ses clients, en combinant expertise sectorielle approfondie, partenariats écosystémiques et investissements massifs dans l'innovation.

L'intelligence artificielle occupe une place centrale dans la stratégie d'Accenture. En 2023, le groupe a annoncé un investissement de **3 milliards de dollars sur trois ans** dans sa practice *Data & AI*, visant à doubler ses effectifs IA à 80 000 professionnels et à créer des accélérateurs pour 19 secteurs industriels distincts. Les résultats de cet investissement sont déjà visibles : en FY 2025, le chiffre d'affaires lié à l'IA avancée (GenAI, IA agentique, IA physique) a triplé pour atteindre **2,7 milliards USD**, avec des commandes GenAI de **5,9 milliards USD** et plus de **6 000 projets d'IA avancée** livrés au cours de l'exercice. L'effectif *Data & AI* est passé de 40 000 à **77 000 professionnels**, et plus de 550 000 collaborateurs ont été formés aux fondamentaux de l'IA générative.

1.2.2 Accenture au Maroc

Au Maroc, Accenture est implantée à Casablanca, au sein du parc technologique **Casanear-shore** (Sidi Maarouf), Shore 10, Park 1100, Boulevard Al Qods. Sous les entités **Accenture Morocco** et **Accenture Maghreb**, la filiale marocaine fournit des prestations de services en conseil en management, en télécommunications et en technologies de l'information. Le centre de Casablanca sert de hub nearshore pour les projets européens et africains, offrant un accès à un vivier de talents qualifiés et à un environnement opérationnel compétitif.

Le site de **Rabat, Meditech** accueille également des équipes Accenture, dont l'équipe ADMP au sein de laquelle ce PFE a été réalisé. Ce positionnement géographique permet une collaboration étroite avec les équipes européennes (principalement basées en France et en Espagne) tout en bénéficiant de la proximité culturelle et linguistique avec les clients francophones.

1.2.3 Positionnement de l'équipe ADMP au sein d'Accenture

L'**Accenture Data Migration Platform (ADMP)** est une capacité de migration propriétaire développée par Accenture depuis plus de **25 ans**, dédiée à l'accélération, l'automatisation et la sécurisation des projets de migration de données à grande échelle.

L'équipe ADMP se positionne au sein de la practice **Technology, Data & AI** et constitue un centre d'expertise spécialisé dans la migration de systèmes legacy vers des plateformes modernes. Son périmètre d'intervention est mondial et couvre trois géographies : North America, APAC et EMEA.

Les chiffres clés de l'ADMP, présentés dans le Tableau ??, illustrent sa maturité et son envergure.

TABLE 1.2 – Indicateurs clés de la plateforme ADMP

Indicateur	Valeur
Années d'expérience	+25 ans
Migrations gérées	+200 projets
Objets métier migrés	+75 millions
Spécialistes techniques et fonctionnels	+55
Géographies couvertes	3 (NA, APAC, EMEA)
Coût de licence	Aucun
Réduction des coûts vs approche non industrielle	Jusqu'à 66%

L'ADMP a servi des clients majeurs dans des secteurs variés, principalement l'assurance (Generali, AXA, Chubb, QBE, MMA, Allianz, AG2R La Mondiale), les utilities (SAUR) et l'industrie (Legrand, Bureau Veritas), avec des systèmes cibles tels que Duck Creek, Guidewire, Salesforce, Vitech et SAP.

La plateforme repose sur trois piliers fondamentaux :

- **Smart Designs** : des documents structurés (Word/Excel) qui décrivent les règles de transformation, les mappings de champs, les relations entre tables et les contraintes métier. Ces documents sont lisibles par les équipes fonctionnelles tout en étant interprétables automatiquement par la plateforme pour générer les programmes de migration.
- **Cycle ETL automatisé** : à partir des Smart Designs, ADMP génère automatiquement les programmes d'extraction, transformation et chargement, sans nécessiter de développeurs ETL traditionnels.
- **Qualité et traçabilité** : la plateforme intègre des modules de validation (pre-load et post-load), des contrôles d'intégrité, des tableaux de bord de suivi et des rapports d'anomalies facilitant les itérations entre équipes techniques et fonctionnelles.

Dans le cadre de son programme d'évolution stratégique, l'équipe ADMP a initié l'intégration de l'intelligence artificielle au sein de la plateforme, articulée autour de trois axes majeurs : l'**ADMP AI Engine** (moteur d'IA pour l'automatisation de la validation, la génération de règles et les suggestions en temps réel), l'**ADMP Studio** (outil web de design remplaçant les plugins VBA) et l'amélioration des **outils de design existants** par infusion de GenAI. C'est précisément dans ce programme d'innovation que s'inscrit le présent PFE.

1.3 Présentation d'AFDTech

Fondée en 1998 par Jérôme Picard, **AFD.Tech** est une société française de conseil et d'ingénierie qui s'est progressivement imposée comme un acteur incontournable du marché des infrastructures informatiques, des réseaux et des télécommunications. Initialement positionnée sur le conseil de haut niveau dans le domaine télécom, au point d'avoir longtemps été qualifiée de « *Pure Player Télécom* », l'entreprise a su, au fil des années, élargir son champ d'expertise pour accompagner les grandes entreprises dans l'ensemble de leur transformation digitale : ingénierie réseau, cybersécurité, cloud computing, gestion des données, automatisation et intelligence artificielle.

Avec une croissance annuelle soutenue, AFD.Tech intervient aujourd'hui sur des projets complexes auprès de clients majeurs des secteurs bancaire, assurance, énergie, transport, télécommunications et services publics. Son implantation géographique s'étend sur trois pays (France, Belgique et Maroc) et compte aujourd'hui une dizaine de bureaux répartis entre Paris, Bruxelles, Rabat, Lyon, Strasbourg, Lille, Nantes, Toulouse, Marseille et Rennes.

Le tableau ?? synthétise les principales informations relatives à l'entreprise.



FIGURE 1.2 – Logo d'AFD.Tech Part of Accenture

Attribut	Valeur
Raison sociale	AFD.Tech Part of Accenture
Année de création	1998
Fondateur	Jérôme Picard
Siège social	Paris, France
Présence internationale	France, Belgique, Maroc
Implantation au Maroc	Depuis 2014 (Rabat)
Effectif global	Plus de 1 600 collaborateurs
Effectif au Maroc	Plus de 900 collaborateurs
Secteurs d'activité	Télécoms, IT, Cloud, Cybersécurité, Data, IA
Site web	https://afd.tech

TABLE 1.3 – Informations clés sur AFD.Tech Part of Accenture

1.3.1 Le rapprochement avec Accenture

L'année 2022 marque un tournant majeur dans l'histoire de l'entreprise. Le **1^{er} avril 2022**, AFD.Tech rejoint officiellement le groupe **Accenture**, leader mondial des services aux entreprises et administrations, à l'issue d'une opération de rachat à 100 % du capital annoncée le 15 décembre 2021. Cette acquisition, motivée par la volonté d'Accenture de renforcer ses capacités en services réseaux autour des technologies 5G, fibre et *cloud-first networks*, s'est traduite par l'intégration de plus de 1 600 professionnels hautement qualifiés au sein du groupe.

Désormais désignée sous la dénomination **AFD.Tech Part of Accenture**, l'entreprise a conservé sa culture d'expertise technique tout en bénéficiant de la dimension internationale, des moyens et de l'écosystème d'innovation d'Accenture. Cette intégration stratégique a permis à AFD.Tech d'élargir significativement son périmètre commercial : alors que ses clients étaient historiquement basés en France (à hauteur de 90 %) et en Belgique, l'entreprise travaille aujourd'hui également avec des clients au Benelux, en Italie et au Royaume-Uni.

1.3.2 AFD.Tech au Maroc : MEDITECH et MEDxp

L'implantation marocaine d'AFD.Tech, démarrée en **2014** avec une équipe de quelques dizaines d'ingénieurs, a connu une croissance exponentielle pour devenir aujourd'hui l'un des piliers du développement nearshore du groupe. Cette dynamique s'est concrétisée par la création successive de deux centres d'excellence dédiés aux nouvelles technologies à Rabat.

MEDITECH. Inauguré en 2021, MEDITECH a été le premier centre d'innovation d'AFD.Tech au Maroc. Construit sur **2 000 m²** et accueillant aujourd'hui **plus de 300 ingénieurs**, il a été conçu dès l'origine comme un lieu d'excellence technologique, ouvert et collaboratif, capable d'incarner l'identité innovante du groupe. Il a posé les fondations de la stratégie d'expansion marocaine et constitue toujours le cœur opérationnel des activités locales.

MEDxp. Ouvert en avril 2023, MEDxp prolonge cette dynamique avec une vocation encore plus orientée vers les technologies de pointe. Ce second pôle, également de 2 000 m², est dédié aux nouvelles technologies et accueille plus de 300 ingénieurs experts en **5G, intelligence artificielle et data science**. Au-delà de sa dimension technique, MEDxp se veut un espace de culture et de partage, centré sur l'expérience offerte aux candidats et aux collaborateurs.

L'équipe marocaine compte aujourd'hui **plus de 900 experts** et joue un rôle crucial dans l'évolution du groupe. Elle est dirigée par **Amine El Rhayour**, *Director of the Service Delivery Center Morocco*, dont le parcours d'ingénieur incarne la trajectoire d'excellence technique portée par l'entreprise au Maroc. L'organisation interne s'articule autour de plusieurs pôles stratégiques, comme illustré par la figure ??.



FIGURE 1.3 – Le centre d'excellence MEDITECH à Rabat

FIGURE 1.4 – Organigramme du centre AFD.Tech Maroc

L'expertise déployée à Rabat couvre un périmètre étendu : ingénierie réseau et télécoms, transformation digitale, cloud computing, intelligence artificielle, data science et migration de données. C'est précisément dans ce dernier domaine, au sein de l'équipe ADMP, que s'inscrit le présent stage de fin d'études.

1.4 Contexte académique

1.4.1 Présentation de l'Université Internationale de Rabat

L'**Université Internationale de Rabat (UIR)** est une université privée d'excellence fondée en 2010, située sur le campus Technopolis à Rabat-Salé. Reconnue par l'État marocain, l'UIR propose des formations innovantes dans les domaines de l'ingénierie, de l'architecture, du management (Rabat Business School), du droit, des sciences politiques, des énergies renouvelables et des sciences de la santé.

Partenaire de grandes universités françaises et européennes, notamment l'Université de Nantes, l'UIR offre des doubles diplômes et une forte ouverture internationale à ses étudiants. L'université s'est distinguée récemment par un palmarès historique au Salon International des Inventions de Genève (4 médailles et un prix spécial) et par l'intégration de Rabat Business School dans le classement QS Executive MBA 2026.



FIGURE 1.5 – L'Université Internationale de Rabat

1.4.2 L'École Supérieure d'Informatique et du Numérique (ESIN)

Le présent PFE est réalisé dans le cadre de la formation d'**ingénieur en informatique** dispensée par l'**École Supérieure d'Informatique et du Numérique (ESIN)**, composante de l'UIR. L'ESIN a pour mission de former des informaticiens hautement qualifiés et de mener des activités de recherche accompagnant le développement technologique et économique du Maroc.

La formation s'étend sur cinq ans : deux années de cycle préparatoire intégré, suivies de trois années de cycle ingénieur. La première année du cycle ingénieur constitue un tronc commun, et la deuxième année offre un choix de spécialisation entre : **Big Data**, **Ingénierie des systèmes d'information**, **Sécurité des systèmes d'information** et **Cloud Computing & Virtualisation**.

Les objectifs pédagogiques du programme (PEO) visent à former des ingénieurs capables d'appliquer les principes de l'informatique dans un cadre professionnel, de déployer des fondements interdisciplinaires, et de résoudre de manière créative des problèmes au sein d'équipes pluridisciplinaires.

L'ESIN est née d'un partenariat académique entre l'UIR et l'Université de Nantes, et bénéficie de partenariats industriels avec des entreprises de premier plan, assurant ainsi une pédagogie axée sur l'insertion professionnelle et le rapprochement avec le monde socio-économique.

1.5 Cadrage du projet de stage

1.5.1 Sujet et périmètre de la mission

Le sujet de ce PFE s'intitule : « **Développement d'une plateforme de migration de données basée sur l'IA pour l'amélioration et l'optimisation des processus d'intégration des données** ».

Il s'inscrit dans le programme d'évolution d'ADMP visant à intégrer l'intelligence artificielle au cœur de la plateforme. Les objectifs stratégiques de cette intégration sont triples :

- **Rester un différenciateur réel** en matière de migration grâce à un moteur IA dédié (ADMP AI Engine).
- **Optimiser et accélérer** le temps nécessaire à la rédaction des spécifications de migration, et automatiser l'analyse des audits de données.
- **Créer un véritable assistant intelligent** pour les spécificateurs, réduisant la charge globale de travail.

Le périmètre de la mission couvre principalement la **génération du bundle Databricks**, un module central de la nouvelle architecture ADMP, dont les détails techniques seront présentés dans les chapitres 5 et 6. Ce module vise à automatiser la création des artefacts de migration en s'appuyant sur des technologies de traitement distribué (Apache Spark / Databricks) et d'intelligence artificielle générative.

1.5.2 Objectifs opérationnels et livrables attendus

Les objectifs opérationnels du PFE se déclinent comme suit :

- **Comprendre et maîtriser** la méthodologie ADMP et ses livrables (SDS, IDS, TDS, DS, RC, DP, TT, MS) à travers la formation Core ADMP Design School (CIDS).
- **Contribuer opérationnellement** aux projets de migration en cours, notamment en matière d'analyse de données, de validation de tickets et de rédaction de spécifications.
- **Concevoir et implémenter** le module de génération du bundle Databricks dans le cadre de l'évolution IA de la plateforme.
- **Tester et valider** la solution développée sur des cas réels de migration.
- **Documenter** l'ensemble du travail réalisé dans le présent rapport de PFE.

Ce travail s'inscrit dans la continuité des contributions précédentes de l'équipe : le PFE de Elharrioui Aymen portant sur la conception d'un agent intelligent basé sur RAG et l'architecture AppSync/GraphQL, et le PFE de Majbar Nizar portant sur le fine-tuning d'un LLM (Mistral 7B avec LoRA) pour la génération de règles de transformation.

1.5.3 Planning prévisionnel

Le stage se déroule sur une période de six mois, organisée en phases progressives, comme le résume le Tableau ??.

TABLE 1.4 – Planning prévisionnel du stage

Phase	Période	Activités principales
Intégration & Formation	Mois 1–2	Onboarding, CIDS (2 semaines), découverte des outils et de la méthodologie ADMP
Contribution opérationnelle	Mois 2–4	Participation aux projets de migration, analyse de données, gestion de tickets, validation
Conception & Développement	Mois 3–5	Conception et implémentation du module de génération du bundle Databricks
Tests & Validation	Mois 5–6	Tests, évaluation, documentation, rédaction du rapport

Un diagramme de Gantt détaillé est présenté en annexe.

1.6 Organisation du rapport

Le présent rapport est structuré selon une logique narrative séquentielle, guidant le lecteur depuis la compréhension du problème jusqu'à la validation de la solution proposée :

- **Chapitre 2, Contexte et Problématique** : présente de manière générique les enjeux et défis de la migration de données, indépendamment de tout projet client, et formule la problématique de recherche.
- **Chapitre 3, État de l'Art** : explore les fondements théoriques de la migration, les solutions existantes sur le marché (outils ETL, services cloud), la plateforme ADMP dans son état actuel, les avancées de l'IA dans l'intégration de données, et identifie les limites et opportunités qui positionnent notre contribution.
- **Chapitre 4, Cadre Méthodologique et Gestion de Projet** : décrit l'organisation agile du travail, le cycle de vie des tickets, les processus de validation des données et les pratiques collaboratives de l'équipe.
- **Chapitre 5, Conception et Architecture de la Solution** : présente exclusivement les éléments nouveaux de notre contribution, l'architecture IA cible et le module de génération du bundle Databricks, en s'appuyant sur la description de l'existant fournie au chapitre 3.
- **Chapitre 6, Implémentation** : détaille la réalisation technique des modules, l'environnement de développement, et les difficultés rencontrées avec leurs solutions.
- **Chapitre 7, Résultats et Évaluation** : présente le protocole de test, les résultats obtenus et une discussion critique de la solution.
- **Chapitre 8, Conclusion et Perspectives** : synthétise les contributions, les compétences acquises et les pistes d'évolution futures.

Chapitre 2

Contexte et Problématique

La transformation numérique est devenue un impératif stratégique pour les entreprises de toutes tailles et de tous secteurs. Au coeur de cette transformation se trouve un processus souvent sous-estimé mais fondamental : la migration de données. Qu'il s'agisse de remplacer un système legacy par une plateforme moderne, de consolider des bases de données après une fusion-acquisition, ou d'adopter des solutions cloud pour gagner en agilité, la migration de données constitue le socle invisible sur lequel repose le succès – ou l'échec – de tout projet de modernisation. Ce chapitre dresse un panorama des enjeux et des défis liés à la migration de données, avant de formuler la problématique qui guidera l'ensemble de ce travail.

2.1 La migration de données : définition et enjeux

2.1.1 Qu'est-ce qu'une migration de données ?

La migration de données désigne le processus de transfert de données d'un système source vers un système cible, tout en garantissant leur intégrité, leur qualité et leur conformité aux exigences du nouvel environnement. Ce processus ne se limite pas à un simple déplacement physique de fichiers : il implique l'extraction des données depuis le système d'origine, leur transformation pour les adapter au modèle cible (types de données, formats, contraintes métier, relations entre entités), et leur chargement dans le nouveau système. Ce triptyque, universellement connu sous l'acronyme **ETL** (*Extract, Transform, Load*), constitue le paradigme fondamental de toute opération de migration [microsoft_etl].




FIGURE 2.1 – Schéma du processus ETL classique.

Il est essentiel de distinguer la migration de données d'autres processus apparentés. L'**intégration de données** vise à combiner en continu des données provenant de sources hétérogènes, tandis que la **réplication** crée des copies synchronisées entre systèmes. La migration, quant à elle, est un événement ponctuel et planifié, avec un début et une fin définis, qui s'inscrit généralement dans un projet plus large de transformation des systèmes d'information [cloudficient2025].

2.1.2 Typologies de migration

Les projets de migration de données se déclinent en plusieurs typologies selon le contexte métier qui les déclenche :

- **Re-platforming (migration applicative)** : il s'agit du remplacement d'un système legacy par une plateforme moderne. C'est le cas, par exemple, lorsqu'une entreprise migre son CRM on-premise vers Salesforce, ou son ERP vers SAP S/4HANA. Cette catégorie représente la majorité des projets de migration à grande échelle [admp_core].
- **Consolidation et fusion (Merger & Acquisition)** : lors d'une fusion ou d'une acquisition, les entreprises doivent fusionner leurs bases de données hétérogènes en un référentiel unifié,

un défi d'autant plus complexe que les systèmes à consolider peuvent avoir des modèles de données radicalement différents.

- **Migration vers le cloud** : avec 94 % des organisations utilisant déjà une infrastructure cloud en 2025 et 85 % engagées dans une transition *cloud-first*, la migration des données on-premise vers des environnements cloud (AWS, Azure, GCP) ou hybrides est devenue un processus incontournable [duplocloud2025].
- **Profiling et cleansing** : certaines migrations sont motivées principalement par un objectif d'amélioration de la qualité des données – nettoyage, déduplication, enrichissement – avant leur réinjection dans un système existant ou nouveau [admp_core].
- **Externalisation de processus métier (BPO)** : le transfert de processus métier vers un prestataire externe nécessite la migration sécurisée des données associées, avec des contraintes strictes de confidentialité et de conformité.

2.1.3 Enjeux stratégiques pour les entreprises

La migration de données est bien plus qu'un exercice technique : c'est un enjeu stratégique à fort impact business. Les chiffres du marché en témoignent de manière éloquent.

Le **marché mondial de la migration de données** est estimé à **12,8 milliards USD en 2025** et devrait atteindre **36,8 milliards USD d'ici 2033**, soit un taux de croissance annuel composé (CAGR) de **14,6 %** [datamintel2026]. En parallèle, le marché plus large de l'**intégration de données** (incluant les plateformes ETL/ELT, iPaaS et outils de streaming) est évalué à **17,58 milliards USD en 2025**, avec une projection à **33,24 milliards USD en 2030** (CAGR de 13,6 %) [mam2025]. Le marché spécifique des **logiciels ETL**, quant à lui, est estimé à **15 milliards USD en 2025** et devrait atteindre **45 milliards USD d'ici 2033** (CAGR de 12 %) [mordor2025].




FIGURE 2.2 – Évolution du marché mondial de la migration de données (2024–2034).

Le tableau ?? synthétise les principales estimations de marché issues de différents cabinets d'analyse :

TABLE 2.1 – Estimations du marché de la migration de données selon différentes sources.

Source	Val. 2025	Projection	CAGR	Période
DataM Intelligence	12,8 Mds USD	36,8 Mds USD (2033)	14,6 %	2026–2033
Market Research Future	10,56 Mds USD	34,57 Mds USD (2035)	12,59 %	2025–2035
Market Trends Analysis	15,2 Mds USD (2024)	32,8 Mds USD (2033)	9,2 %	2025–2033

Ces chiffres révèlent une réalité sans équivoque : la migration de données est un marché en pleine expansion, porté par la transformation digitale, l'adoption massive du cloud, et l'émergence de l'intelligence artificielle qui exige des données propres, structurées et accessibles. Les outils de migration pilotés par l'IA connaissent d'ailleurs une croissance de **28 %** selon Gartner [kellton2025].

Au-delà de la croissance du marché, les enjeux stratégiques se déclinent en quatre dimensions :

- **Continuité d'activité** : toute interruption ou perte de données durant une migration peut paralyser les opérations métier, avec des conséquences financières et réputationnelles considérables.
- **Conformité réglementaire** : les réglementations sur la protection des données (RGPD, CCPA, HIPAA) imposent des exigences strictes en matière de traçabilité, de sécurité et de gouvernance durant le processus de migration [kaopiz2025].
- **Coût et time-to-market** : les coûts de migration représentent typiquement **30 à 50 % du budget total d'un projet de modernisation IT**. La capacité à migrer rapidement et efficacement devient donc un avantage compétitif majeur [kaopiz2025].
- **Fondation pour l'IA** : les systèmes d'intelligence artificielle modernes exigent des données de haute qualité. Une migration mal exécutée peut compromettre l'ensemble des initiatives IA d'une organisation avant même leur démarrage [kaopiz2025].

2.2 Anatomie d'un projet de migration : les défis

Malgré son importance stratégique, la migration de données reste l'un des processus les plus risqués et les plus complexes du paysage IT. Comme le souligne une analyse approfondie publiée en 2025, **83 % des projets de migration échouent ou dépassent leur budget et leurs délais**. Selon Gartner, près de **70 % des projets de migration n'atteignent pas leurs objectifs**, souvent en raison de risques sous-estimés, d'une planification insuffisante ou d'une validation inadéquate [kaopiz2025, kanerika2025].

2.2.1 Hétérogénéité des systèmes source et cible

Le premier défi fondamental réside dans la disparité entre les systèmes d'origine et de destination. Les données sources peuvent provenir de bases relationnelles (Oracle, SQL Server, DB2), de fichiers plats (CSV, TXT), de systèmes mainframe (VSAM, IMS), ou d'applications métier propriétaires, chacun avec ses propres formats, encodages et conventions de nommage. Le système cible, quant à lui, impose son propre modèle de données, ses contraintes d'intégrité référentielle et ses règles de validation [admp_core].

Cette hétérogénéité génère des **incompatibilités de schéma** qui sont à l'origine de **45 % des échecs de migration** selon les analyses sectorielles. La réconciliation entre ces modèles divergents nécessite un travail minutieux de *mapping* – à la fois au niveau des tables (*Table Mapping*) et des champs (*Data Mapping*) – qui constitue l'un des exercices les plus chronophages et les plus sujets à erreur du processus [cloudficient2025].

2.2.2 Volumétrie et performance

L'explosion des volumes de données amplifie considérablement la complexité des migrations. La création mondiale de données devrait atteindre **181 zettaoctets en 2025**, et l'entreprise moyenne gère ses données à travers **14 systèmes distincts simultanément**. À cette échelle, les défis de performance deviennent critiques : les temps d'extraction s'allongent, les transformations consomment des ressources considérables, et les fenêtres de migration (souvent limitées à des week-ends ou des périodes de faible activité) deviennent insuffisantes [kaopiz2025].

Les organisations traitent désormais des volumes allant du téraoctet au pétaoctet, avec une vélocité de données exigeant des migrations à temps d'arrêt quasi nul. Les risques ETL se multiplient de manière exponentielle avec l'augmentation de la taille des données, rendant la validation et la réconciliation de plus en plus complexes et chronophages [kanerika2025].

2.2.3 Qualité et intégrité des données

La qualité des données sources constitue un facteur déterminant – et souvent sous-estimé – du succès d'une migration. Selon un rapport Gartner de 2023, la mauvaise qualité des données

coûte aux organisations en moyenne **12,9 millions de dollars par an** en ressources gaspillées et en opportunités manquées [gartner_quality]. Un rapport IBM de 2025 confirme cette tendance : **43 % des directeurs des opérations** identifient la qualité des données comme leur priorité la plus critique, et plus d'un quart des organisations estiment perdre plus de **5 millions de dollars annuellement** en raison de données de mauvaise qualité [ibm2025].

Dans le contexte spécifique de la migration, les problèmes de qualité se manifestent sous plusieurs formes :

- **Données incomplètes** : champs obligatoires non renseignés, enregistrements tronqués, historiques partiels.
- **Données incohérentes** : doublons, formats hétérogènes (dates, adresses, codes), valeurs contradictoires entre systèmes.
- **Données obsolètes** : informations périmées qui ne reflètent plus la réalité métier.
- **Données corrompues** : altérations dues à des bugs applicatifs, des migrations antérieures mal exécutées, ou des problèmes d'encodage.

Selon une étude Experian, **64 % des projets de migration analysés dépassent leur budget**, et seulement **46 % sont livrés dans les délais prévus**, en grande partie à cause de problèmes de qualité de données non anticipés [montecarlo2025]. Par ailleurs, **35 % des projets de migration cloud échouent directement à cause d'une qualité de données insuffisante** [wifitalents2025].

2.2.4 Complexité des règles de transformation métier

Au-delà du simple transfert de données, la migration implique l'application de **règles de transformation métier** souvent complexes et spécifiques à chaque domaine fonctionnel. Ces règles déterminent comment les données sources doivent être restructurées, enrichies, filtrées ou agrégées pour correspondre au modèle cible.

Les défis typiques incluent :

- **Relations N :M (Many-to-Many)** : les associations complexes entre entités (par exemple, entre compétences et ressources, ou entre contrats et prestations) nécessitent des étapes intermédiaires de regroupement et de dédoublonnage.
- **Transcodification** : la correspondance entre les valeurs codifiées du système source et celles du système cible (codes pays, types de contrat, statuts) requiert des tables de correspondance exhaustives et validées par le métier.
- **Création conditionnelle d'enregistrements** : certains enregistrements cibles n'existent pas dans le système source et doivent être créés selon des règles métier spécifiques (par exemple, la création automatique d'un enregistrement maître pour chaque groupe d'enregistrements détail).

- **Gestion des cas particuliers** : les exceptions, les cas limites et les incohérences historiques nécessitent un traitement au cas par cas, difficilement automatisable.

La formalisation et l'implémentation de ces règles constituent l'un des postes les plus coûteux en temps et en expertise dans un projet de migration, et c'est souvent à ce niveau que se creuse le fossé entre les spécifications fonctionnelles et leur traduction technique.

2.2.5 Traçabilité et auditabilité du processus

Dans un environnement réglementaire de plus en plus exigeant, la capacité à **tracer l'ensemble du processus de migration** – de l'extraction à la source jusqu'au chargement dans la cible – est devenue une exigence non négociable. Les régulateurs et les auditeurs attendent des organisations qu'elles puissent démontrer :

- **L'origine de chaque donnée migrée** (*data lineage*) : d'où vient-elle, quelles transformations a-t-elle subies, qui les a validées.
- **L'intégrité du transfert** : aucune donnée n'a été perdue, altérée ou dupliquée durant le processus.
- **La conformité des transformations** : les règles appliquées correspondent exactement aux spécifications validées par le métier.

Or, **34 % des organisations rapportent des lacunes de conformité durant la migration**, et **38 % déclarent que la préparation aux audits est difficile** dans ce contexte. Les outils ETL traditionnels, souvent qualifiés de boîtes noires, rendent cette traçabilité particulièrement ardue, car le lien entre les spécifications fonctionnelles et le code exécuté n'est ni direct ni transparent [gitnux_cloud, admp_overview].

2.2.6 Coordination entre équipes IT et Business

La migration de données se situe à l'intersection de deux mondes : celui des **équipes techniques** (développeurs ETL, DBA, architectes) qui maîtrisent les outils et les systèmes, et celui des **équipes métier** (analystes fonctionnels, utilisateurs finaux, responsables qualité) qui détiennent la connaissance des règles de gestion et des cas d'usage. Cette dualité engendre des défis organisationnels majeurs :

- **Barrière linguistique** : les équipes techniques raisonnent en termes de tables, de requêtes et de schémas, tandis que les équipes métier parlent de contrats, de clients et de polices. La traduction entre ces deux langages est source de malentendus et d'erreurs.
- **Cycle de validation long** : chaque itération de migration nécessite une revue fonctionnelle par le métier, qui doit vérifier que les données migrées correspondent à ses attentes. Ce cycle peut s'étendre sur plusieurs semaines.

- **Résistance au changement** : 70 % des migrations échouent en partie à cause d'une mauvaise gestion du changement et de la résistance des utilisateurs [worldmetrics2025].
- **Pénurie de compétences** : 80 % des organisations rapportent que le manque d'expertise interne est leur principal frein à la réussite des migrations, et 25 % citent le manque de compétences comme cause directe d'échec [wifitalents2025, gitnux_cloud].

Le tableau ?? synthétise les six défis majeurs avec leur impact et leur fréquence :

Défi	Impact principal	Statistique clé
Hétérogénéité des systèmes	Incompatibilités, corruption	45 % des échecs
Volumétrie et performance	Dépassements de délais	Estimation erronée de 40–60 %
Qualité des données	Surcoûts, reprises	12,9 M\$/an en moyenne (Gartner)
Complexité des transformations	Écart design–build	30–50 % du budget IT total
Traçabilité et auditabilité	Non-conformité	34 % de lacunes de conformité
Coordination IT / Business	Retards, malentendus	70 % d'échecs liés au change management

TABLE 2.2 – Synthèse des principaux défis d'un projet de migration de données.

2.3 Formulation de la problématique

L'analyse des enjeux et des défis présentés dans les sections précédentes met en lumière un constat central : **la migration de données reste un processus à haut risque, coûteux et fortement dépendant de l'expertise humaine**, malgré l'existence d'outils ETL et de méthodologies établies.

Trois lacunes structurelles émergent de cette analyse :

- **Le fossé Design–Build** : dans la plupart des approches actuelles, il existe un décalage significatif entre la rédaction des spécifications fonctionnelles (le *design*) et leur implémentation technique (le *build*). Ce fossé est source d'erreurs, de retards et de surcoûts, car il nécessite une traduction manuelle des règles métier en code ETL exécutable [admp_overview].
- **L'opacité des processus** : les outils ETL traditionnels fonctionnent comme des boîtes noires, rendant difficile la validation fonctionnelle, l'auditabilité et la réconciliation des données par les équipes non techniques.
- **L'absence d'intelligence artificielle** : alors que l'IA transforme de nombreux domaines de l'IT, les processus de migration de données restent largement manuels – de la rédaction des spécifications à la détection des anomalies, en passant par la génération des programmes de transformation. Les outils de migration pilotés par l'IA n'en sont qu'à leurs débuts, avec seulement **35 % des entreprises utilisant des plateformes augmentées par l'IA** pour leurs migrations [reanin2025].

Ces constats nous amènent à formuler la problématique suivante :

Comment concevoir et implémenter une plateforme de migration de données intégrant l'intelligence artificielle pour automatiser et optimiser les processus d'intégration, réduire le fossé entre la conception fonctionnelle et l'exécution technique, et améliorer la qualité, la traçabilité et l'efficacité globale du processus de migration ?

Cette problématique sera explorée à travers l'état de l'art (chapitre suivant), qui examinera les solutions existantes – y compris la plateforme ADMP – et les avancées de l'IA dans le domaine de l'intégration de données, avant de présenter notre contribution visant à enrichir cette plateforme par des capacités d'intelligence artificielle.

Chapitre 3

État de l'Art

3.1 État de l'Art

Le chapitre précédent a mis en lumière les défis structurels de la migration de données et formulé la problématique centrale de ce travail. Le présent chapitre explore l'état de l'art scientifique et technologique afin d'identifier les fondements, les solutions existantes, et les opportunités d'amélioration qui positionnent notre contribution. Nous commençons par les fondements théoriques, passons en revue les solutions du marché, décrivons en profondeur la plateforme ADMP dans son état actuel, explorons les avancées de l'intelligence artificielle appliquées au domaine, avant d'analyser les limites de l'existant et de formuler notre positionnement.

3.1.1 Fondements théoriques

3.1.1.1 Le paradigme ETL / ELT : principes et évolution

Le paradigme **ETL (Extract, Transform, Load)** constitue depuis plusieurs décennies le socle fondamental de toute opération d'intégration de données. Il décrit un processus en trois phases séquentielles : l'**extraction** des données depuis les systèmes sources, leur **transformation** dans une zone intermédiaire (staging) pour les adapter au modèle cible, puis leur **chargement** dans le système de destination. Ce paradigme a été le pilier de l'ère du data warehousing classique, où les ressources de calcul étaient limitées et coûteuses, imposant un pré-traitement rigoureux des données avant leur insertion dans l'entrepôt.

Avec l'avènement du cloud computing et des entrepôts de données modernes (Snowflake, BigQuery, Amazon Redshift), un paradigme alternatif a émergé : l'**ELT (Extract, Load, Transform)**. Dans cette approche, les données brutes sont d'abord chargées dans le système cible, puis transformées directement en exploitant la puissance de calcul élastique de l'infrastructure cloud. L'ELT offre une flexibilité analytique accrue, une meilleure utilisation des ressources et un time-to-insight réduit, tout en posant de nouveaux défis en matière de gouvernance et de gestion technique.




FIGURE 3.1 – Comparaison des paradigmes ETL et ELT

L'évolution de l'ETL vers l'ELT ne se résume pas à une simple réorganisation des étapes : elle reflète un changement fondamental dans la philosophie de gestion des données. Comme le souligne Vanga (2024) dans son étude publiée dans *l'International Journal for Multidisciplinary Research*, cette transition est catalysée par la croissance exponentielle des volumes de données, la prolifération des sources hétérogènes, et les exigences d'analyse en temps réel. Les architectures modernes tendent vers des modèles hybrides combinant les forces des deux approches, avec l'émergence de concepts tels que le **zero-ETL** et le **data mesh** qui promettent de réduire encore la complexité des pipelines de données. Le Tableau ?? présente une comparaison synthétique des deux paradigmes.

Critère	ETL	ELT
Transformation	Avant le chargement (staging)	Après le chargement (in-warehouse)
Infrastructure	On-premise, ressources limitées	Cloud-native, calcul élastique
Flexibilité	Schéma rigide, pré-défini	Schéma flexible, late-binding
Vitesse	Plus lent sur grands volumes	Plus rapide (puissance cloud)
Gouvernance	Contrôle pré-chargement	Nécessite gouvernance SQL forte
Outils typiques	Informatica, Talend, SSIS	dbt, Snowflake, BigQuery

TABLE 3.1 – Comparaison entre ETL et ELT

3.1.1.2 Modélisation des données

La réussite d'un projet de migration repose en grande partie sur la maîtrise des modèles de données source et cible. Trois approches principales de modélisation coexistent dans l'écosystème :

- **Le modèle relationnel**, fondé sur les travaux de Codd (1970), organise les données en tables liées par des clés primaires et étrangères. Il reste le standard dominant dans les systèmes transactionnels (OLTP) et les plateformes CRM comme Salesforce.
- **Le modèle dimensionnel**, popularisé par Kimball, structure les données autour de tables de faits et de dimensions, optimisées pour l'analyse (OLAP). Il est au cœur des entrepôts de données classiques.
- **Le modèle orienté objet**, qui encapsule données et comportements dans des objets liés par héritage et composition, est utilisé dans les systèmes modernes et les plateformes cloud-native. Comme le détaille la formation CIDS d'ADMP, « *an object-oriented data model consists of basic concepts : Object, Object identifier, Attributes, Methods, Class, Class hierarchy, and Inheritance* ».

La compréhension de ces modèles est essentielle pour le Data Analyst qui doit établir les correspondances (mappings) entre le système source et le système cible, en tenant compte des différences structurelles, des contraintes d'intégrité et des relations entre entités.

3.1.1.3 Qualité des données : métriques et frameworks

La qualité des données est un facteur déterminant du succès de toute migration. Le concept de dimensions de qualité des données a été formalisé en 1996 par les professeurs Richard Y. Wang et Diane M. Strong dans leur article fondateur « *Beyond Accuracy : What Data Quality Means to Data Consumers* ». Depuis, le framework DAMA-DMBOK a standardisé **six dimensions fondamentales** universellement adoptées, présentées dans le Tableau ??.

Dimension	Description	Exemple d'impact en migration
Exactitude	Les données reflètent-elles fidèlement la réalité ?	Adresse client erronée → livraison échouée
Complétude	Tous les champs requis sont-ils renseignés ?	Champ obligatoire vide → rejet au chargement
Cohérence	Les données sont-elles uniformes entre systèmes ?	Prix différent entre web et mobile
Fraîcheur	Les données sont-elles disponibles à temps ?	Données obsolètes → décisions erronées
Validité	Les données respectent-elles les formats et règles ?	Date « 30 février » → rejet de validation
Unicité	Pas de doublons ?	Doublons clients → métriques faussées

TABLE 3.2 – Dimensions de la qualité des données et impact en migration

Le coût de la non-qualité est considérable : selon Gartner (2023), la mauvaise qualité des données coûte en moyenne **12,9 millions de dollars par an** aux organisations. Dans le contexte spécifique de la migration, la mise en place de contrôles de qualité automatisés (profiling, validation pré-chargement, réconciliation post-chargement) est donc un prérequis incontournable.



FIGURE 3.2 – Les dimensions de la qualité des données

3.1.1.4 Gouvernance des données et conformité

La gouvernance des données établit les politiques, processus et responsabilités qui encadrent la gestion des données tout au long de leur cycle de vie. Dans le contexte de la migration, elle revêt une importance critique pour trois raisons :

Premièrement, la **traçabilité des données** (*data lineage*), la capacité à retracer le parcours complet d'une donnée depuis son origine jusqu'à sa destination, en passant par chaque transformation, est devenue une exigence réglementaire explicite. Le RGPD (Article 30) impose aux organisations de maintenir des registres des activités de traitement, incluant la classification des données, le suivi de la qualité, et les politiques de rétention.

Deuxièmement, le **principe de responsabilité** (*accountability*, Article 5(2) du RGPD) exige que les organisations puissent **démontrer**, et non simplement affirmer, leur conformité, à travers des politiques documentées, des rôles définis, des contrôles techniques et des traces d'audit.

Troisièmement, les réglementations émergentes comme l'**EU AI Act** ajoutent une couche supplémentaire de complexité : les organisations utilisant l'IA dans leurs processus de migration doivent documenter de manière exhaustive les flux de données, avec des amendes pouvant atteindre **7,5 à 35 millions d'euros** en cas de non-conformité.

L'intégration du data lineage dans le cadre de gouvernance offre des avantages concrets :

amélioration de la redevabilité, support au troubleshooting, analyse d'impact proactive lors des mises à jour, et simplification des audits de conformité.




FIGURE 3.3 – Exemple de traçabilité des données (Data Lineage)

3.1.2 Solutions existantes sur le marché

3.1.2.1 Outils ETL traditionnels

Le marché des outils ETL traditionnels est dominé par trois acteurs majeurs, chacun avec ses forces et ses limites :

Informatica PowerCenter est considéré comme la référence enterprise-grade. Il offre une large connectivité (Oracle, DB2, Teradata, NoSQL), un profilage automatique des données, et des mécanismes robustes de gestion des erreurs. Cependant, son coût de licence élevé, sa courbe d'apprentissage abrupte et son interface vieillissante limitent son accessibilité.

Talend propose une approche open-source (Talend Open Studio) complétée par une édition entreprise. Basé sur Java, il offre plus de 900 connecteurs, un support natif du Big Data (Hadoop, Spark), et une interface drag-and-drop accessible. Il constitue un choix privilégié pour les organisations cherchant flexibilité et maîtrise des coûts.

SSIS (SQL Server Integration Services) de Microsoft est intégré à SQL Server sans coût de licence additionnel. Performant dans les environnements Microsoft-centric, il souffre néanmoins d'un support limité pour les systèmes non-Microsoft et d'une scalabilité restreinte en environnements hétérogènes.

Le Tableau ?? présente une comparaison détaillée de ces trois outils.

TABLE 3.3 – Comparaison des outils ETL traditionnels

Critère	Informatica	Talend	SSIS
Type	Propriétaire	Open-source + Enterprise	Propriétaire (inclus SQL Server)
Coût	Élevé	Gratuit (OS) / Modéré (Ent.)	Inclus avec SQL Server
Cloud	Fort (IICS)	Excellent (cloud-native)	Limité (via ADF)
Big Data	Add-ons requis	Support natif (Spark, Hadoop)	Support basique
Connectivité	Très large	900+ connecteurs	Fort en Microsoft
Courbe d'apprentissage	Raide	Modérée	Modérée

3.1.2.2 Services cloud natifs

L'essor du cloud a donné naissance à des services d'intégration de données entièrement managés :

AWS Glue est un service ETL serverless basé sur Apache Spark, intégré à l'écosystème AWS (S3, Redshift, Athena). Il propose un Data Catalog automatisé, le support batch et streaming, et un studio visuel de développement de pipelines.

Azure Data Factory (ADF) de Microsoft offre plus de 90 connecteurs natifs, des Data Flows Spark pour les transformations no-code, et un runtime d'intégration hybride permettant de connecter données on-premise et cloud. Son intégration avec Azure Synapse, Databricks et Power BI en fait un choix naturel pour les organisations dans l'écosystème Microsoft.

Google Cloud Dataflow, basé sur Apache Beam, se distingue par son modèle unifié batch/streaming et sa facturation à la seconde. Il excelle dans le traitement en temps réel et les workloads analytiques avancés.

Le Tableau ?? compare ces trois services cloud.

TABLE 3.4 – Comparaison des services cloud natifs

Critère	AWS Glue	Azure Data Factory	GCP Dataflow
Moteur	Apache Spark	Spark (Data Flows)	Apache Beam
Modèle	Serverless	Serverless + IR	Serverless
Connecteurs	70+	90+	Google Cloud natif
Streaming	Oui (Kinesis, MSK)	Limité	Excellent (Pub/Sub)
Coût/TB batch	~1,84	~1,42	~2,11
Latence streaming p99	~120ms	~148ms	~89ms

3.1.2.3 Approches ad hoc / scripts custom

De nombreuses organisations développent encore des scripts ad hoc (SQL, Python, Shell) pour gérer leurs migrations. Cette approche offre une flexibilité maximale et un coût initial faible, mais présente des limites critiques : absence de standardisation, aucune traçabilité intrinsèque, dépendance aux développeurs individuels, maintenance difficile, et risque élevé d'erreurs sur les projets à grande échelle.

3.1.2.4 Analyse comparative et limites communes

Malgré leurs différences, toutes ces solutions partagent des limitations structurelles communes :

- **Le fossé Design-Build** : dans chaque cas, les spécifications fonctionnelles doivent être traduites manuellement en code exécutable par une équipe technique, créant un risque permanent de décalage entre le design et l'implémentation.
- **Effet boîte noire** : les moteurs ETL traditionnels ne permettent pas aux équipes fonctionnelles de vérifier directement que le code implémenté correspond aux spécifications validées.
- **Absence de couche métier** : les services cloud natifs sont performants pour le transport de données, mais manquent de la couche fonctionnelle nécessaire pour gérer les règles de transformation complexes, les Key Decisions, et la validation métier itérative.
- **Coûts cachés** : licences logicielles, infrastructure dédiée, main-d'œuvre technique spécialisée, et coûts de maintenance s'accumulent au fil du projet.

C'est dans ce contexte que la plateforme ADMP se positionne comme une réponse industrielle visant à combler ces lacunes.

3.1.3 La plateforme ADMP : état actuel

3.1.3.1 Envergure mondiale et chiffres clés




FIGURE 3.4 – Envergure mondiale de la plateforme ADMP : chiffres clés et 3 géographies

L'**Accenture Data Migration Platform (ADMP)** est une solution propriétaire d'Accenture dédiée à la migration de données d'entreprise à grande échelle. Forte de plus de **25 ans d'expérience**, la plateforme a accompagné plus de **200 projets de migration** à travers le monde, avec plus de **75 millions d'objets métier migrés** par une équipe de plus de **55 spécialistes** techniques et fonctionnels. La plateforme intervient dans **3 géographies** : North America, APAC et EMEA, positionnant ADMP comme « *a powerhouse for data migration & services* ».

3.1.3.2 Quatre piliers de valeur




FIGURE 3.5 – Les quatre piliers de valeur de la plateforme ADMP

La valeur d'ADMP repose sur quatre piliers complémentaires qui structurent l'offre de service :

- **Advanced Tooling** : une suite d'outils et d'accélérateurs permettant de rendre les activités de migration transparentes et efficaces, et d'en réduire la charge additionnelle.
- **Skilled Resources** : la capacité à mobiliser rapidement une équipe d'experts en migration de données, capable d'interagir avec l'ensemble des parties prenantes tout au long du projet.
- **Strong Methodology** : un ensemble de meilleures pratiques éprouvées et validées, de la phase de découverte jusqu'au déploiement, garantissant une livraison dans les délais avec un risque réduit. « *Experience gained on transformation projects of various complexities* ».
- **Alignment with the Project Strategy** : la capacité à étendre l'expérience acquise sur la plateforme pour aider à mettre en œuvre un processus industrialisé de gestion de la qualité et de la migration des données.

3.1.3.3 Un service de migration sur mesure




FIGURE 3.6 – Les neuf dimensions du service de migration sur mesure ADMP

ADMP propose un service de migration global articulé autour de neuf dimensions clés :

- **Methodology** : méthodologie éprouvée et validée (de la découverte au déploiement), standardisée, s'appuyant sur des experts en migration.
- **Agility** : compatible avec les méthodes Agile, avec des ressources ajustables et scalables.
- **Data Load** : accélérateur de chargement vers des plateformes spécifiques (Duck Creek, Salesforce, Workday, SAP) avec validation du processus de chargement.
- **Transparency** : « *No black box effect* », avec versioning de tous les documents et exécutables.
- **Experience** : +25 ans, +200 projets de migration, expertise fonctionnelle et technique.
- **Data Reconciliation** : 2 niveaux de rapports de validation, multiples KPIs et monitoring.
- **Data Quality** : audit technique des données source en amont, contrôles de non-régression continus, vérifications d'intégrité et gestion des exceptions.
- **Infrastructure** : SaaS ou On-Premise, compatible avec de grands volumes de données, sans coût de licence.
- **Data Security** : application des normes de sécurité des données les plus strictes d'Accenture.

3.1.3.4 Architecture end-to-end : le flux ETL ADMP




FIGURE 3.7 – Architecture end-to-end du flux ETL ADMP (Extract → Transform → Load)

Pour comprendre la valeur réelle d'ADMP, il convient de suivre le parcours d'une donnée depuis son système source jusqu'au système cible, en traversant chaque composant de la plateforme. Cette architecture, illustrée par la Figure ??, s'inscrit dans le modèle classique **Extract-Transform-Load (ETL)**, mais chaque phase est enrichie de composants propriétaires ADMP qui automatisent et sécurisent le processus. Il est important de noter que la plateforme distingue deux catégories de composants : les **outils ADMP** (développés et maîtrisés par Accenture) qui constituent le cœur de la valeur ajoutée, et les **outils non-ADMP** (spécifiques aux systèmes source et cible du client) qui assurent les interfaces d'entrée et de sortie.

Phase 1 : Extract — La collecte sécurisée des données sources. Le processus débute par l'extraction des données depuis les systèmes legacy du client. Ces données peuvent provenir de sources hétérogènes : bases de données relationnelles (Oracle, SQL Server, DB2, Mainframe), fichiers Excel fournis par les équipes métier, ou environnements Salesforce existants. À ce stade, les programmes d'*unload* utilisés sont des outils **non-ADMP** : chaque système legacy dispose de son propre mécanisme d'export, que l'équipe adapte au contexte du projet.

Une fois extraits, les fichiers (généralement au format TXT ou CSV) sont pris en charge par le composant **Data Ingestion**, premier composant **ADMP** du pipeline. Celui-ci ingère les données dans la plateforme via un protocole de transfert sécurisé (SFTP, VPN), garantissant la confidentialité et l'intégrité des données dès leur entrée dans le périmètre Accenture.

Phase 2 : Transform — Le cœur de valeur d'ADMP. La phase de transformation est celle où ADMP déploie l'essentiel de son intelligence. Elle s'articule en deux couches fonctionnelles complémentaires.

La *première couche* est dédiée à l'**audit et à la définition des règles**. Le composant **Source Data Audit** procède à un audit technique automatique et exhaustif de chaque table, enregistrement et champ source : il valide la complétude de l'extraction, détecte les anomalies de format et produit un état des lieux précis des données disponibles. C'est sur cette base que l'équipe de design commence son travail. Les **Business Rules** (règles métier fonctionnelles, correspondant aux documents RC — *Record Creation*) et les **Smart Designs** (l'ensemble des documents de spécification SDS, IDS, TDS, DS, DP, TT) constituent la *source unique de vérité* du projet : le moteur ADMP lit ces documents et génère automatiquement les programmes de transformation, sans aucun développement ETL manuel. Chaque exécution produit un **Run Report**, rapport automatique de statistiques, d'erreurs et de volumétrie.

La *deuxième couche* assure le **nettoyage et le contrôle qualité**. Les **Technical Rules** appliquent les transformations techniques (formats, longueurs, types de données). Le composant **Automated Cleansing (TT)** exploite les Tables de Transcodification pour normaliser automatiquement les valeurs source vers les valeurs cibles (mappings de codes, constantes, règles de substitution). Enfin, les **Data Integrity Checks** vérifient la cohérence référentielle entre tables, l'absence de doublons et la complétude des relations, avant que les données ne soient présentées au chargement.

Phase 3 : Load — Le chargement encadré vers la cible. La phase de chargement est délibérément encadrée par deux niveaux de validation. La **Pre-load Validation** constitue une ultime vérification de conformité, d'intégrité et de volumétrie avant que les données ne quittent la plateforme ADMP vers le système cible. Elle permet de détecter en amont tout écart susceptible de provoquer une erreur lors du chargement.

Le chargement lui-même s'effectue via des composants **non-ADMP**, propres à chaque système cible : chargement vers des fichiers ou bases de données génériques (*Target Data Load*), chargement spécifique vers Salesforce via Data Loader ou Bulk API, ou vers Guidewire via ses APIs d'import métier. Cette architecture intentionnellement ouverte permet à ADMP d'interfacer avec n'importe quelle plateforme cible du marché (Duck Creek, SAP, Vitech, Workday, etc.) sans dépendance technologique.

Le cycle se clôt par la **Post-load Validation**, composant ADMP qui effectue la réconciliation entre les volumes de données sources et cibles, contrôle la complétude du chargement et produit les rapports de migration finaux. C'est ce dernier rapport qui constitue la preuve de bonne exécution présentée au client.

Synthèse : quatre niveaux de validation intégrés. L'une des forces distinctives de l'architecture ADMP réside dans l'intégration systématique de quatre niveaux de validation tout au long du

pipeline : l'**audit source** (avant le design), les **contrôles d'intégrité** (durant la transformation), la **validation pré-chargement** et la **validation post-chargement**. Cette approche élimine l'*effet boîte noire* des solutions ETL traditionnelles et garantit une traçabilité complète, de la donnée source jusqu'à la donnée migrée dans le système cible.

3.1.3.5 Smart Designs vs ETL standard




FIGURE 3.8 – Comparaison visuelle ADMP Smart Designs vs Standard ETL

La comparaison entre l'approche ADMP Smart Designs et l'approche ETL traditionnelle met en évidence des avantages structurels significatifs, synthétisés dans le Tableau ??.

TABLE 3.5 – Comparaison ADMP Smart Designs vs ETL standard

Domaine	ETL Standard	ADMP Smart Designs
Build	Équipe technique requise (Talend, Informatica, BODS)	Aucun développeur ETL requis
Rapports	Développés en supplément de l'ETL	Générés automatiquement depuis les Smart Designs
Scalabilité	Contrainte par l'équipe technique et les outils	Gérée par design, templates hautement distribués
Réutilisabilité	Compétences techniques avancées requises	Personnalisation facile (Word/Excel)
Mises à jour des règles	Mise à jour simultanée des documents <i>et</i> de l'ETL	Mise à jour du Smart Design uniquement
Traçabilité	Impossible de valider design vs implémentation	Une seule source de vérité, traçabilité complète
Licence	Coût de licence requis	Aucun coût de licence

3.1.3.6 La méthodologie ADMP : notre approche détaillée

La méthodologie ADMP structure la migration en quatre phases, chacune impliquant des rôles précis côté client et côté Accenture.

Our approach

Data Extract phase – Data extract management



CLIENT personnel
Accenture personnel

1 Data Extraction from Source System

Data output is a list of TXT or CSV files following data scope definition. It is then encrypted and sent to the ADMP platform via a secure transfer protocol (SFTP, VPN, ...)

Name	Date modified	Type	Size
[initial]_sum_IACCOUNTI_5224_1_1.dat	25/04/2024 14:17	DAT File	15 KB
[initial]_sum_IACCOUNTI_5224_1_2.dat	25/04/2024 14:17	DAT File	3 KB
[initial]_sum_IACCOUNTI_5224_1_3.dat	25/04/2024 14:17	DAT File	15 KB
[initial]_sum_ICLIENTI_18644_1_9.dat	25/04/2024 14:17	DAT File	17 KB
[initial]_sum_ITRANI_6272_1_1.dat	25/04/2024 14:17	DAT File	15 KB
[initial]_sum_ITRANI_6272_1_2.dat	25/04/2024 14:17	DAT File	7 KB
[initial]_sum_ITRANI_6272_1_3.dat	25/04/2024 14:17	DAT File	15 KB

2 Source Data scope definition & load

Define the exact boundaries and content of the raw data tables to be extracted, including a detailed data dictionary with field names, order, formats, descriptions, domains, and source systems.

Table Name	Field Name	Field Type	Field Order	Description
ACCOUNTI	ACCOUNTI_ID	INT	1	Account ID
ACCOUNTI	ACCOUNTI_NAME	VARCHAR	2	Account Name
ACCOUNTI	ACCOUNTI_ADDRESS	VARCHAR	3	Account Address
ACCOUNTI	ACCOUNTI_CITY	VARCHAR	4	Account City
ACCOUNTI	ACCOUNTI_COUNTRY	VARCHAR	5	Account Country
ACCOUNTI	ACCOUNTI_PHONE	VARCHAR	6	Account Phone
ACCOUNTI	ACCOUNTI_EMAIL	VARCHAR	7	Account Email
ACCOUNTI	ACCOUNTI_PASSWORD	VARCHAR	8	Account Password
ACCOUNTI	ACCOUNTI_USERNAME	VARCHAR	9	Account Username
ACCOUNTI	ACCOUNTI_LASTNAME	VARCHAR	10	Account Last Name
ACCOUNTI	ACCOUNTI_FIRSTNAME	VARCHAR	11	Account First Name
ACCOUNTI	ACCOUNTI_MIDDLENAME	VARCHAR	12	Account Middle Name
ACCOUNTI	ACCOUNTI_SUFFIX	VARCHAR	13	Account Suffix
ACCOUNTI	ACCOUNTI_PREFIX	VARCHAR	14	Account Prefix
ACCOUNTI	ACCOUNTI_INITIALS	VARCHAR	15	Account Initials
ACCOUNTI	ACCOUNTI_NICKNAME	VARCHAR	16	Account Nickname
ACCOUNTI	ACCOUNTI_DISPLAYNAME	VARCHAR	17	Account Display Name
ACCOUNTI	ACCOUNTI_FULLNAME	VARCHAR	18	Account Full Name
ACCOUNTI	ACCOUNTI_SHORTNAME	VARCHAR	19	Account Short Name
ACCOUNTI	ACCOUNTI_ALIAS	VARCHAR	20	Account Alias
ACCOUNTI	ACCOUNTI_DISPLAYNAME	VARCHAR	21	Account Display Name
ACCOUNTI	ACCOUNTI_FULLNAME	VARCHAR	22	Account Full Name
ACCOUNTI	ACCOUNTI_SHORTNAME	VARCHAR	23	Account Short Name
ACCOUNTI	ACCOUNTI_ALIAS	VARCHAR	24	Account Alias
ACCOUNTI	ACCOUNTI_DISPLAYNAME	VARCHAR	25	Account Display Name
ACCOUNTI	ACCOUNTI_FULLNAME	VARCHAR	26	Account Full Name
ACCOUNTI	ACCOUNTI_SHORTNAME	VARCHAR	27	Account Short Name
ACCOUNTI	ACCOUNTI_ALIAS	VARCHAR	28	Account Alias
ACCOUNTI	ACCOUNTI_DISPLAYNAME	VARCHAR	29	Account Display Name
ACCOUNTI	ACCOUNTI_FULLNAME	VARCHAR	30	Account Full Name
ACCOUNTI	ACCOUNTI_SHORTNAME	VARCHAR	31	Account Short Name
ACCOUNTI	ACCOUNTI_ALIAS	VARCHAR	32	Account Alias
ACCOUNTI	ACCOUNTI_DISPLAYNAME	VARCHAR	33	Account Display Name
ACCOUNTI	ACCOUNTI_FULLNAME	VARCHAR	34	Account Full Name
ACCOUNTI	ACCOUNTI_SHORTNAME	VARCHAR	35	Account Short Name
ACCOUNTI	ACCOUNTI_ALIAS	VARCHAR	36	Account Alias
ACCOUNTI	ACCOUNTI_DISPLAYNAME	VARCHAR	37	Account Display Name
ACCOUNTI	ACCOUNTI_FULLNAME	VARCHAR	38	Account Full Name
ACCOUNTI	ACCOUNTI_SHORTNAME	VARCHAR	39	Account Short Name
ACCOUNTI	ACCOUNTI_ALIAS	VARCHAR	40	Account Alias
ACCOUNTI	ACCOUNTI_DISPLAYNAME	VARCHAR	41	Account Display Name
ACCOUNTI	ACCOUNTI_FULLNAME	VARCHAR	42	Account Full Name
ACCOUNTI	ACCOUNTI_SHORTNAME	VARCHAR	43	Account Short Name
ACCOUNTI	ACCOUNTI_ALIAS	VARCHAR	44	Account Alias
ACCOUNTI	ACCOUNTI_DISPLAYNAME	VARCHAR	45	Account Display Name
ACCOUNTI	ACCOUNTI_FULLNAME	VARCHAR	46	Account Full Name
ACCOUNTI	ACCOUNTI_SHORTNAME	VARCHAR	47	Account Short Name
ACCOUNTI	ACCOUNTI_ALIAS	VARCHAR	48	Account Alias
ACCOUNTI	ACCOUNTI_DISPLAYNAME	VARCHAR	49	Account Display Name
ACCOUNTI	ACCOUNTI_FULLNAME	VARCHAR	50	Account Full Name
ACCOUNTI	ACCOUNTI_SHORTNAME	VARCHAR	51	Account Short Name
ACCOUNTI	ACCOUNTI_ALIAS	VARCHAR	52	Account Alias
ACCOUNTI	ACCOUNTI_DISPLAYNAME	VARCHAR	53	Account Display Name
ACCOUNTI	ACCOUNTI_FULLNAME	VARCHAR	54	Account Full Name
ACCOUNTI	ACCOUNTI_SHORTNAME	VARCHAR	55	Account Short Name
ACCOUNTI	ACCOUNTI_ALIAS	VARCHAR	56	Account Alias
ACCOUNTI	ACCOUNTI_DISPLAYNAME	VARCHAR	57	Account Display Name
ACCOUNTI	ACCOUNTI_FULLNAME	VARCHAR	58	Account Full Name
ACCOUNTI	ACCOUNTI_SHORTNAME	VARCHAR	59	Account Short Name
ACCOUNTI	ACCOUNTI_ALIAS	VARCHAR	60	Account Alias
ACCOUNTI	ACCOUNTI_DISPLAYNAME	VARCHAR	61	Account Display Name
ACCOUNTI	ACCOUNTI_FULLNAME	VARCHAR	62	Account Full Name
ACCOUNTI	ACCOUNTI_SHORTNAME	VARCHAR	63	Account Short Name
ACCOUNTI	ACCOUNTI_ALIAS	VARCHAR	64	Account Alias
ACCOUNTI	ACCOUNTI_DISPLAYNAME	VARCHAR	65	Account Display Name
ACCOUNTI	ACCOUNTI_FULLNAME	VARCHAR	66	Account Full Name
ACCOUNTI	ACCOUNTI_SHORTNAME	VARCHAR	67	Account Short Name
ACCOUNTI	ACCOUNTI_ALIAS	VARCHAR	68	Account Alias
ACCOUNTI	ACCOUNTI_DISPLAYNAME	VARCHAR	69	Account Display Name
ACCOUNTI	ACCOUNTI_FULLNAME	VARCHAR	70	Account Full Name
ACCOUNTI	ACCOUNTI_SHORTNAME	VARCHAR	71	Account Short Name
ACCOUNTI	ACCOUNTI_ALIAS	VARCHAR	72	Account Alias
ACCOUNTI	ACCOUNTI_DISPLAYNAME	VARCHAR	73	Account Display Name
ACCOUNTI	ACCOUNTI_FULLNAME	VARCHAR	74	Account Full Name
ACCOUNTI	ACCOUNTI_SHORTNAME	VARCHAR	75	Account Short Name
ACCOUNTI	ACCOUNTI_ALIAS	VARCHAR	76	Account Alias
ACCOUNTI	ACCOUNTI_DISPLAYNAME	VARCHAR	77	Account Display Name
ACCOUNTI	ACCOUNTI_FULLNAME	VARCHAR	78	Account Full Name
ACCOUNTI	ACCOUNTI_SHORTNAME	VARCHAR	79	Account Short Name
ACCOUNTI	ACCOUNTI_ALIAS	VARCHAR	80	Account Alias
ACCOUNTI	ACCOUNTI_DISPLAYNAME	VARCHAR	81	Account Display Name
ACCOUNTI	ACCOUNTI_FULLNAME	VARCHAR	82	Account Full Name
ACCOUNTI	ACCOUNTI_SHORTNAME	VARCHAR	83	Account Short Name
ACCOUNTI	ACCOUNTI_ALIAS	VARCHAR	84	Account Alias
ACCOUNTI	ACCOUNTI_DISPLAYNAME	VARCHAR	85	Account Display Name
ACCOUNTI	ACCOUNTI_FULLNAME	VARCHAR	86	Account Full Name
ACCOUNTI	ACCOUNTI_SHORTNAME	VARCHAR	87	Account Short Name
ACCOUNTI	ACCOUNTI_ALIAS	VARCHAR	88	Account Alias
ACCOUNTI	ACCOUNTI_DISPLAYNAME	VARCHAR	89	Account Display Name
ACCOUNTI	ACCOUNTI_FULLNAME	VARCHAR	90	Account Full Name
ACCOUNTI	ACCOUNTI_SHORTNAME	VARCHAR	91	Account Short Name
ACCOUNTI	ACCOUNTI_ALIAS	VARCHAR	92	Account Alias
ACCOUNTI	ACCOUNTI_DISPLAYNAME	VARCHAR	93	Account Display Name
ACCOUNTI	ACCOUNTI_FULLNAME	VARCHAR	94	Account Full Name
ACCOUNTI	ACCOUNTI_SHORTNAME	VARCHAR	95	Account Short Name
ACCOUNTI	ACCOUNTI_ALIAS	VARCHAR	96	Account Alias
ACCOUNTI	ACCOUNTI_DISPLAYNAME	VARCHAR	97	Account Display Name
ACCOUNTI	ACCOUNTI_FULLNAME	VARCHAR	98	Account Full Name
ACCOUNTI	ACCOUNTI_SHORTNAME	VARCHAR	99	Account Short Name
ACCOUNTI	ACCOUNTI_ALIAS	VARCHAR	100	Account Alias

3 Source Data Audit

A technical source data audit for each table, record, and field is performed automatically by ADMP to validate data extraction, ensure data integrity and completeness before the start of design systems.

Table Name	Field Name	Field Type	Field Order	Description
ACCOUNTI	ACCOUNTI_ID	INT	1	Account ID
ACCOUNTI	ACCOUNTI_NAME	VARCHAR	2	Account Name
ACCOUNTI	ACCOUNTI_ADDRESS	VARCHAR	3	Account Address
ACCOUNTI	ACCOUNTI_CITY	VARCHAR	4	Account City
ACCOUNTI	ACCOUNTI_COUNTRY	VARCHAR	5	Account Country
ACCOUNTI	ACCOUNTI_PHONE	VARCHAR	6	Account Phone
ACCOUNTI	ACCOUNTI_EMAIL	VARCHAR	7	Account Email
ACCOUNTI	ACCOUNTI_PASSWORD	VARCHAR	8	Account Password
ACCOUNTI	ACCOUNTI_USERNAME	VARCHAR	9	Account Username
ACCOUNTI	ACCOUNTI_LASTNAME	VARCHAR	10	Account Last Name
ACCOUNTI	ACCOUNTI_FIRSTNAME	VARCHAR	11	Account First Name
ACCOUNTI	ACCOUNTI_MIDDLENAME	VARCHAR	12	Account Middle Name
ACCOUNTI	ACCOUNTI_SUFFIX	VARCHAR	13	Account Suffix
ACCOUNTI	ACCOUNTI_PREFIX	VARCHAR	14	Account Prefix
ACCOUNTI	ACCOUNTI_INITIALS	VARCHAR	15	Account Initials
ACCOUNTI	ACCOUNTI_NICKNAME	VARCHAR	16	Account Nickname
ACCOUNTI	ACCOUNTI_DISPLAYNAME	VARCHAR	17	Account Display Name
ACCOUNTI	ACCOUNTI_FULLNAME	VARCHAR	18	Account Full Name
ACCOUNTI	ACCOUNTI_SHORTNAME	VARCHAR	19	Account Short Name
ACCOUNTI	ACCOUNTI_ALIAS	VARCHAR	20	Account Alias
ACCOUNTI	ACCOUNTI_DISPLAYNAME	VARCHAR	21	Account Display Name
ACCOUNTI	ACCOUNTI_FULLNAME	VARCHAR	22	Account Full Name
ACCOUNTI	ACCOUNTI_SHORTNAME	VARCHAR	23	Account Short Name
ACCOUNTI	ACCOUNTI_ALIAS	VARCHAR	24	Account Alias
ACCOUNTI	ACCOUNTI_DISPLAYNAME	VARCHAR	25	Account Display Name
ACCOUNTI	ACCOUNTI_FULLNAME	VARCHAR	26	Account Full Name
ACCOUNTI	ACCOUNTI_SHORTNAME	VARCHAR	27	Account Short Name
ACCOUNTI	ACCOUNTI_ALIAS	VARCHAR	28	Account Alias
ACCOUNTI	ACCOUNTI_DISPLAYNAME	VARCHAR	29	Account Display Name
ACCOUNTI	ACCOUNTI_FULLNAME	VARCHAR	30	Account Full Name
ACCOUNTI	ACCOUNTI_SHORTNAME	VARCHAR	31	Account Short Name
ACCOUNTI	ACCOUNTI_ALIAS	VARCHAR	32	Account Alias
ACCOUNTI	ACCOUNTI_DISPLAYNAME	VARCHAR	33	Account Display Name
ACCOUNTI	ACCOUNTI_FULLNAME	VARCHAR	34	Account Full Name
ACCOUNTI	ACCOUNTI_SHORTNAME	VARCHAR	35	Account Short Name
ACCOUNTI	ACCOUNTI_ALIAS	VARCHAR	36	Account Alias
ACCOUNTI	ACCOUNTI_DISPLAYNAME	VARCHAR	37	Account Display Name
ACCOUNTI	ACCOUNTI_FULLNAME	VARCHAR	38	Account Full Name
ACCOUNTI	ACCOUNTI_SHORTNAME	VARCHAR	39	Account Short Name
ACCOUNTI	ACCOUNTI_ALIAS	VARCHAR	40	Account Alias
ACCOUNTI	ACCOUNTI_DISPLAYNAME	VARCHAR	41	Account Display Name
ACCOUNTI	ACCOUNTI_FULLNAME	VARCHAR	42	Account Full Name
ACCOUNTI	ACCOUNTI_SHORTNAME	VARCHAR	43	Account Short Name
ACCOUNTI	ACCOUNTI_ALIAS	VARCHAR	44	Account Alias
ACCOUNTI	ACCOUNTI_DISPLAYNAME	VARCHAR	45	Account Display Name
ACCOUNTI	ACCOUNTI_FULLNAME	VARCHAR	46	Account Full Name
ACCOUNTI	ACCOUNTI_SHORTNAME	VARCHAR	47	Account Short Name
ACCOUNTI	ACCOUNTI_ALIAS	VARCHAR	48	Account Alias
ACCOUNTI	ACCOUNTI_DISPLAYNAME	VARCHAR	49	Account Display Name
ACCOUNTI	ACCOUNTI_FULLNAME	VARCHAR	50	Account Full Name
ACCOUNTI	ACCOUNTI_SHORTNAME	VARCHAR	51	Account Short Name
ACCOUNTI	ACCOUNTI_ALIAS	VARCHAR	52	Account Alias
ACCOUNTI	ACCOUNTI_DISPLAYNAME	VARCHAR	53	Account Display Name
ACCOUNTI	ACCOUNTI_FULLNAME	VARCHAR	54	Account Full Name
ACCOUNTI	ACCOUNTI_SHORTNAME	VARCHAR	55	Account Short Name
ACCOUNTI	ACCOUNTI_ALIAS	VARCHAR	56	Account Alias
ACCOUNTI	ACCOUNTI_DISPLAYNAME	VARCHAR	57	Account Display Name
ACCOUNTI	ACCOUNTI_FULLNAME	VARCHAR	58	Account Full Name
ACCOUNTI	ACCOUNTI_SHORTNAME	VARCHAR	59	Account Short Name
ACCOUNTI	ACCOUNTI_ALIAS	VARCHAR	60	Account Alias
ACCOUNTI	ACCOUNTI_DISPLAYNAME	VARCHAR	61	Account Display Name
ACCOUNTI	ACCOUNTI_FULLNAME	VARCHAR	62	Account Full Name
ACCOUNTI	ACCOUNTI_SHORTNAME	VARCHAR	63	Account Short Name
ACCOUNTI	ACCOUNTI_ALIAS	VARCHAR	64	Account Alias
ACCOUNTI	ACCOUNTI_DISPLAYNAME	VARCHAR	65	Account Display Name
ACCOUNTI	ACCOUNTI_FULLNAME	VARCHAR	66	Account Full Name
ACCOUNTI	ACCOUNTI_SHORTNAME	VARCHAR	67	Account Short Name
ACCOUNTI	ACCOUNTI_ALIAS	VARCHAR	68	Account Alias
ACCOUNTI	ACCOUNTI_DISPLAYNAME	VARCHAR	69	Account Display Name
ACCOUNTI	ACCOUNTI_FULLNAME	VARCHAR	70	Account Full Name
ACCOUNTI	ACCOUNTI_SHORTNAME	VARCHAR	71	Account Short Name
ACCOUNTI	ACCOUNTI_ALIAS	VARCHAR	72	Account Alias
ACCOUNTI	ACCOUNTI_DISPLAYNAME	VARCHAR	73	Account Display Name
ACCOUNTI	ACCOUNTI_FULLNAME	VARCHAR	74	Account Full Name
ACCOUNTI	ACCOUNTI_SHORTNAME	VARCHAR	75	Account Short Name
ACCOUNTI	ACCOUNTI_ALIAS	VARCHAR	76	Account Alias
ACCOUNTI	ACCOUNTI_DISPLAYNAME	VARCHAR	77	Account Display Name
ACCOUNTI	ACCOUNTI_FULLNAME	VARCHAR	78	Account Full Name
ACCOUNTI	ACCOUNTI_SHORTNAME	VARCHAR	79	Account Short Name
ACCOUNTI	ACCOUNTI_ALIAS	VARCHAR	80	Account Alias
ACCOUNTI	ACCOUNTI_DISPLAYNAME	VARCHAR	81	Account Display Name
ACCOUNTI	ACCOUNTI_FULLNAME	VARCHAR	82	Account Full Name
ACCOUNTI	ACCOUNTI_SHORTNAME	VARCHAR	83	Account Short Name
ACCOUNTI	ACCOUNTI_ALIAS	VARCHAR	84	Account Alias
ACCOUNTI	ACCOUNTI_DISPLAYNAME	VARCHAR	85	Account Display Name
ACCOUNTI	ACCOUNTI_FULLNAME	VARCHAR	86	Account Full Name
ACCOUNTI	ACCOUNTI_SHORTNAME	VARCHAR	87	Account Short Name
ACCOUNTI	ACCOUNTI_ALIAS	VARCHAR	88	Account Alias
ACCOUNTI	ACCOUNTI_DISPLAYNAME	VARCHAR	89	Account Display Name
ACCOUNTI	ACCOUNTI_FULLNAME	VARCHAR	90	Account Full Name
ACCOUNTI	ACCOUNTI_SHORTNAME	VARCHAR	91	Account Short Name
ACCOUNTI	ACCOUNTI_ALIAS	VARCHAR	92	Account Alias
ACCOUNTI	ACCOUNTI_DISPLAYNAME	VARCHAR	93	Account Display Name
ACCOUNTI	ACCOUNTI_FULLNAME	VARCHAR	94	Account Full Name
ACCOUNTI	ACCOUNTI_SHORTNAME	VARCHAR	95	Account Short Name
ACCOUNTI	ACCOUNTI_ALIAS	VARCHAR	96	Account Alias
ACCOUNTI	ACCOUNTI_DISPLAYNAME	VARCHAR	97	Account Display Name
ACCOUNTI	ACCOUNTI_FULLNAME	VARCHAR	98	Account Full Name
ACCOUNTI	ACCOUNTI_SHORTNAME	VARCHAR	99	Account Short Name
ACCOUNTI	ACCOUNTI_ALIAS	VARCHAR	100	Account Alias

Key Roles (illustrative)

IT Source expert /
Technical BA

ADMP Data
Analysts

ADMP Platform
specialist

ADMP Methodology

Copyright © 2026 Accenture. All rights reserved. 10

FIGURE 3.9 – Phase d'extraction – Rôles et activités ADMP

Phase 1 — Extraction des données. Cette phase comprend trois étapes : (1) la **définition du périmètre et chargement** des données source, incluant un dictionnaire de données détaillé (noms de champs, formats, descriptions, domaines et systèmes source) ; (2) l'**extraction** des données depuis le système source vers des fichiers TXT ou CSV, chiffrés et transmis via SFTP/VPN ; (3) l'**audit technique automatique** des données source par table, enregistrement et champ.

Our approach

Transformation phase - Design




CLIENT personnel
Accenture personnel

1 Data analysis


Table mapping

Source and target tables description and mapping. Major gaps identification between source and target tables.



Data mapping

Source and data mapping (source fields that are necessary to populate target fields). Major gaps identification between source and target data.



Key Decisions


Major gaps are identified and gathered in "Key decisions" document, that is used to design and to validate with business solutions to these gaps



2 Detailed design


Migration steps

The migration steps document details workflows by activity domain, specifying dependencies, execution order, and strategies like parallelization for improved performance, aiding efficient planning and execution




Data migration units:

- **Data Structure:** Data relationship between tables using a hierarchical data model
- **Records creation rules:** Functional data migration rules to be applied for creation of target records from source tables
- **Data population rules:** Rules for populating target fields for each tables




Transcodification tables


Rules for populating one target field with one or more source fields or with constants.



IT workshop



Business workshop




ADMP Methodology


FIGURE 3.10 – Phase de design – Analyse et conception détaillée ADMP

Phase 2 — Design (Analyse et Conception détaillée). Organisée en deux volets : (1) l'**analyse de données** (Table Mapping, Data Mapping, Key Decisions pour les écarts majeurs), validée en workshops IT et Business ; (2) la **conception détaillée** comprenant les Migration Steps (workflows par domaine avec dépendances et stratégies de parallélisation), les Transcodification Tables, et les Data Migration Units (Data Structure, Record Creation, Data Population).

Transformation phase - Build



ADMP automates the creation of data migration programs by directly retrieving and processing design documents from the design team's repository, ensuring accuracy and efficiency.



This phase involves rigorous testing to identify and rectify any technical issues, ensuring the migration system's reliability with minimal manual intervention.

[illegible]

FIGURE 3.11 – Phase de build – Automatisation complète depuis les Smart Designs

Phase 3 — Build. ADMP automatise intégralement la création des programmes de migration depuis les documents de design : (1) **Full Build Automation** – le moteur récupère et traite directement les documents depuis le dépôt de l'équipe design ; (2) **Assembly Test** – tests rigoureux pour identifier et corriger les problèmes techniques avec un minimum d'intervention manuelle ; (3) **Stabilisation** – raffinement continu du processus à l'aide des rapports, pour aligner les données migrées avec les standards métier et de conformité.




FIGURE 3.12 – Phase de test et déploiement – Cycle itératif ADMP

Phase 4 — Test et Déploiement. La phase suit un cycle itératif organisé autour de : (1) **Post-build issues reporting** – identification des anomalies, distinguant les correctifs immédiats des sujets nécessitant l'input des équipes IT ou Business ; (2) **Livraisons itératives de releases test** – une nouvelle version toutes les 2 à 4 semaines (refresh des données source, corrections, mises à jour des règles) ; (3) **Test support** – analyse et support lors des tests, identification des causes de défauts et affinement des règles ; (4) **Rehearsal & Rollout** – gestion complète du processus lors des répétitions (*rehearsals*) et exécution du plan de bascule (*cutover*).

3.1.4 Intelligence artificielle et intégration de données

3.1.4.1 LLM et génération de code (GPT, Mistral, fine-tuning, LoRA)

Les **Large Language Models (LLM)** ont révolutionné le domaine de la génération automatique de code et de la compréhension du langage naturel. Des modèles comme GPT-4, Llama 3, Claude et Mistral sont capables de générer du code SQL, Python ou PySpark à partir de spécifications en langage naturel, ouvrant des perspectives considérables pour l'automatisation des processus de migration.

La technique de **LoRA (Low-Rank Adaptation)**, introduite par Hu et al. (2021), a transformé l'approche du fine-tuning en permettant d'adapter des modèles de plusieurs milliards de paramètres avec une fraction des ressources habituellement nécessaires. LoRA gèle les poids du modèle pré-entraîné et injecte des matrices de rang faible entraînables dans chaque couche,

réduisant les paramètres entraînables de **99%+** tout en atteignant **95-98% de la performance** d'un fine-tuning complet.

Concrètement, le fine-tuning d'un modèle Llama 3.1 70B passe de **8 GPU A100 pendant 48 heures (~15 000 \$)** en fine-tuning complet à **1 GPU A100 pendant 4 heures (~500 \$)** avec LoRA. Cette démocratisation rend le fine-tuning accessible pour des cas d'usage spécifiques à un domaine, comme la génération de règles de transformation de données.

La variante **QLoRA** combine LoRA avec une quantification 4-bit, permettant le fine-tuning sur du matériel grand public, une avancée particulièrement pertinente pour les équipes ne disposant pas d'infrastructure GPU dédiée.




FIGURE 3.13 – Principe du fine-tuning avec LoRA (Low-Rank Adaptation)

3.1.4.2 RAG (Retrieval-Augmented Generation)

Le **RAG (Retrieval-Augmented Generation)**, introduit par Lewis et al. (2020), est une architecture qui enrichit les LLM en les couplant avec des sources de connaissances externes au moment de l'inférence. Plutôt que de s'appuyer uniquement sur les connaissances intériorisées lors de l'entraînement, le RAG récupère dynamiquement des passages pertinents depuis une base documentaire et les injecte dans le contexte du modèle pour générer des réponses factuellement ancrées.

L'architecture RAG se décompose en deux composants principaux :

- **Le composant de récupération** : les requêtes sont encodées en vecteurs denses, puis comparées aux vecteurs de documents pré-encodés dans une base vectorielle (FAISS, pgvector, Pinecone). Les passages les plus pertinents sont extraits.
- **Le composant de génération** : les documents récupérés sont combinés avec la requête pour produire une réponse contextuelle et précise via le LLM.

Microsoft propose une architecture RAG de référence dans Azure Architecture Center, intégrant Azure AI Search, Semantic Kernel et des modèles de langage pour construire des applications d'entreprise robustes.

Dans le contexte de la migration de données, le RAG permet d'exploiter la documentation existante (SDS, TDS, RC, DP) comme base de connaissances pour assister les spécificateurs dans la rédaction de règles, la résolution de questions fonctionnelles, et la validation des designs.




FIGURE 3.14 – Architecture Retrieval-Augmented Generation (RAG)

3.1.4.3 Agents IA et automatisation de workflows

Les **agents IA** représentent une évolution majeure par rapport à l'automatisation traditionnelle. Contrairement aux systèmes RPA (*Robotic Process Automation*) qui suivent des scripts prédéfinis, les agents IA combinent perception, raisonnement et action pour accomplir des objectifs de manière autonome.

Leurs caractéristiques distinctives incluent :

- **Autonomie** : fonctionnement indépendant sans supervision constante.
- **Conscience contextuelle** : compréhension des scénarios métier nuancés.
- **Raisonnement multi-étapes** : décomposition de tâches complexes en sous-tâches exécutables.
- **Auto-correction** : identification et rectification des erreurs en cours d'exécution.
- **Intégration d'outils** : connexion transparente avec APIs, bases de données et systèmes d'entreprise.

Le marché mondial des agents IA est estimé à **5,1 milliards USD en 2024**, avec une projection à **47,1 milliards USD d'ici 2030** (CAGR de 44,8%). Toutefois, selon Gartner (2025), moins de **5% des applications d'entreprise intègrent de véritables agents IA** à ce stade, la majorité n'utilisant que des assistants basiques.

3.1.4.4 Applications de l'IA dans la migration de données

L'application de l'IA au domaine spécifique de la migration de données est un champ émergent mais prometteur, avec cinq cas d'usage à fort impact identifiés par Blackburn (2025) :

- **Mapping automatique de schémas** : les modèles ML analysent la structure, le contenu et les métadonnées des sources pour suggérer des correspondances source-cible, réduisant le temps de mapping de **30-60%**.
- **Évaluation et nettoyage de la qualité** : les LLM détectent les anomalies que les règles statiques ne capturent pas, et peuvent suggérer des actions de nettoyage automatiques.
- **Génération de données synthétiques de test** : les modèles génératifs produisent des jeux de test réalistes préservant les propriétés statistiques sans exposer de données réelles.
- **Planification intelligente de la migration** : le reinforcement learning optimise l'ordonnement des lots de migration en fonction des dépendances et des contraintes de fenêtre.
- **Monitoring et détection d'anomalies en production** : des pipelines de détection identifient les écarts en temps réel et accélèrent le triage des erreurs.

La plateforme **MAiGRATE** de Compliance Group illustre cette tendance : elle combine IA, ML et LLM pour automatiser l'ingestion, la transformation, le mapping de champs, la déduplication, la détection d'anomalies et la validation, avec un apprentissage continu améliorant la précision à chaque cycle de migration.

3.1.5 Limites de l'existant et opportunités

3.1.5.1 Limites des outils de design actuels

Les Design Tools actuels d'ADMP reposent sur des **plugins VBA intégrés à Word et Excel**. Si cette approche a l'avantage d'utiliser des outils familiers aux équipes fonctionnelles, elle présente des limitations de plus en plus critiques :

- **Technologie vieillissante** : VBA est un langage de macro datant des années 1990, dont le support et l'évolutivité sont limités.
- **Pas de collaboration en temps réel** : contrairement aux outils web modernes, les documents Word/Excel ne permettent pas l'édition simultanée avec traçabilité fine.
- **Intégration IA impossible** : l'architecture VBA ne permet pas d'intégrer nativement des appels à des API d'IA (OpenAI, Bedrock) pour assister la rédaction.
- **Maintenance complexe** : les macros VBA sont fragiles, sensibles aux versions d'Office, et difficiles à déboguer.

3.1.5.2 Rédaction manuelle des spécifications

La rédaction des spécifications de migration (RC, DP, DS, TT) reste un processus **largement manuel et chronophage**. Chaque document nécessite une compréhension approfondie du modèle source, du modèle cible, et des règles métier spécifiques. Comme le souligne la présentation d'évolution ADMP, l'un des objectifs stratégiques de la modernisation est de « *Optimize and*

accelerate the time needed to write specifications » et de « *Create a true wizard for specifiers and reduce the overall burden* ».

Le rapport PFE de Abbad el andalousi, Larbi estime que l'automatisation de la génération des livrables de migration permettrait une **réduction de 50 à 60% du temps** nécessaire à leur production, tout en minimisant les risques d'erreurs humaines.

3.1.5.3 Absence d'IA dans le processus de migration

Malgré les avancées considérables de l'IA dans d'autres domaines de l'IT, le processus de migration ADMP reste **dépourvu d'intelligence artificielle**. Aucun module IA n'assiste actuellement les spécificateurs dans la rédaction des règles, la détection des incohérences, ou la validation automatique des designs. Cette absence représente une opportunité majeure d'amélioration.

3.1.5.4 Dépendance à l'expertise humaine

La qualité de la migration repose fortement sur l'expertise individuelle des Data Analysts. L'**onboarding** de nouveaux membres nécessite une formation intensive (la CIDS dure **2 semaines (80 heures)**) et l'acquisition de la maturité opérationnelle prend plusieurs mois supplémentaires. Cette dépendance crée un risque de perte de connaissances (*knowledge drain*) lors des rotations d'équipe et limite la scalabilité des opérations.

3.1.6 Synthèse et positionnement de la contribution

3.1.6.1 Tableau de synthèse des gaps identifiés

Le Tableau ?? synthétise les principaux gaps identifiés et les opportunités associées.

TABLE 3.6 – Synthèse des gaps identifiés et opportunités

Gap identifié	Impact	Opportunité
Outils de design VBA obso- lètes	Pas de collaboration, pas d'IA	→ ADMP Studio (outil web mo- derne)
Rédaction manuelle des spéci- fications	Chronophage, risque d'erreur	→ ADMP AI Engine (généra- tion assistée)
Absence d'IA dans le proces- sus	Aucune assistance intelligente	→ Intégration LLM + RAG
Dépendance à l'expertise hu- maine	Onboarding long, scalabilité limitée	→ Assistant IA pour spécifica- teurs
Pas de génération automa- tique de code	Build manuel des pro- grammes	→ Bundle Databricks (notre contribution)

3.1.6.2 Positionnement du PFE

L'analyse de l'état de l'art révèle que la plateforme ADMP, malgré sa maturité et ses avantages concurrentiels significatifs, se trouve à un tournant stratégique. Les outils existants ont prouvé leur efficacité pendant plus de 25 ans, mais l'absence d'intelligence artificielle dans le processus constitue désormais un frein à l'innovation et à la compétitivité.

Le programme d'évolution d'ADMP, articulé autour de l'**ADMP AI Engine**, de l'**ADMP Studio** et de l'amélioration des outils de design, vise à combler ces gaps.

Notre contribution, le **développement du module de génération du bundle Databricks**, s'inscrit précisément dans cet axe d'industrialisation. Ce module vise à automatiser la création des artefacts de migration en s'appuyant sur des technologies de traitement distribué (Apache Spark / Databricks) et d'intelligence artificielle générative, transformant ainsi les Smart Designs en programmes exécutables sur des infrastructures cloud modernes.

Ce positionnement se situe à l'intersection de trois tendances identifiées dans l'état de l'art : l'**automatisation du cycle Design-Build** (section ??), l'**application de l'IA à la migration** (section ??), et le besoin de **modernisation des outils** (section ??). Le chapitre suivant présentera le cadre méthodologique et organisationnel dans lequel ce travail a été réalisé.

Chapitre 4

Cadre Méthodologique et Gestion de Projet

Le chapitre précédent a identifié les fondements théoriques, les solutions existantes et les opportunités d'amélioration qui positionnent notre contribution. Avant de détailler la conception de notre solution (chapitre 5), il est essentiel de présenter le cadre méthodologique et organisationnel dans lequel s'inscrit ce travail. Ce chapitre décrit comment l'équipe ADMP s'organise au quotidien pour mener à bien ses projets de migration : la méthodologie Agile adoptée, le cycle de vie des tickets, les processus de validation des données, et les pratiques collaboratives qui assurent la cohésion et l'efficacité de l'équipe.

4.1 Méthodologie Agile adoptée

4.1.1 Principes Scrum appliqués au projet

Le cadre de travail adopté au sein de l'équipe ADMP s'inspire du framework **Scrum**, la méthodologie Agile la plus répandue au monde, utilisée par près de **87 %** des équipes Agile selon le *State of Agile Report* [digitalai2024]. Scrum repose sur trois piliers fondamentaux — transparence, inspection et adaptation — et s'articule autour de la règle « 3-5-3 », synthétisée dans le Tableau ??.

TABLE 4.1 – Le framework Scrum : règle 3-5-3

Composant	Éléments	Fonction
3 Rôles	Product Owner, Scrum Master, Développeurs	Définir les responsabilités et permettre l'auto-organisation
5 Événements	Sprint, Sprint Planning, Daily Scrum, Sprint Review, Sprint Retrospective	Créer la régularité et permettre l'inspection-adaptation
3 Artefacts	Product Backlog, Sprint Backlog, Incrément	Maximiser la transparence et mesurer la progression

Dans le contexte spécifique de la migration de données, ces principes sont adaptés aux réalités du projet. Le **Product Owner** est représenté par le chef de projet migration, qui priorise les lots fonctionnels à migrer en fonction des besoins métier et des dépendances techniques. Le **Scrum Master** est incarné par le Team Lead ADMP, qui facilite les cérémonies, lève les blocages et veille au respect de la méthodologie. Les **Développeurs** correspondent aux Data Analysts ADMP, qui rédigent les spécifications (RC, DP, DS), analysent les données et valident les résultats de migration.

Les cinq valeurs Scrum — engagement, courage, focus, ouverture et respect — guident les interactions quotidiennes au sein de l'équipe, particulièrement dans les échanges avec le client lors des phases de validation et de prise de décision.

4.1.2 Organisation des sprints de migration

L'approche ADMP structure le processus de migration en **sprints itératifs** d'une durée de 2 à 4 semaines, chacun livrant un nouveau jeu de données migré intégrant les corrections, les rafraîchissements de données source et les mises à jour des règles. Cette cadence régulière constitue le rythme fondamental du projet.

Chaque sprint de migration suit un enchaînement rigoureux de quatre phases :

— **Phase 1 — Design / Build (Static Tests)** : les Data Analysts rédigent ou mettent à jour

les spécifications (RC, DP, DS, TT), versionnées via IDMF Explorer. Le Core Engine génère automatiquement les programmes de migration. Des tests statiques valident la cohérence des règles avant toute exécution.

- **Phase 2 — Test Support** : l'équipe analyse les défauts identifiés, identifie leurs causes racines et affine les règles de migration pour garantir la stabilité des versions livrées à l'environnement de test.
- **Phase 3 — Stabilisation et livraison itérative** : des versions successives (V1, V2, V3, V4, V5...) sont produites, chacune intégrant les corrections issues des cycles de test précédents, convergeant progressivement vers la qualité attendue.
- **Phase 4 — Rehearsal & Rollout** : l'équipe gère le processus complet de migration durant les répétitions générales (*rehearsals*), en se concentrant sur l'automatisation de la migration, l'exécution du plan de bascule (*cutover*) et le déploiement dans les délais impartis.

Le cycle complet d'un projet type suit la progression illustrée en Figure ??.




FIGURE 4.1 – Cycle de progression d'un projet de migration ADMP

Cette organisation permet de découvrir et de résoudre les problèmes de manière incrémentale, plutôt que de les accumuler jusqu'à un « Big Bang » final risqué. L'approche Agile appliquée à la migration de données réduit considérablement les risques grâce à la validation précoce et continue, par opposition à l'approche traditionnelle où les tests ne sont conduits qu'après l'exécution complète [datavail2025].

4.1.3 Outils de pilotage

L'outil central de pilotage du projet est **Azure DevOps**, une plateforme Microsoft conçue pour faciliter la collaboration entre les équipes de développement et d'exploitation dans l'esprit DevOps [microsoft2025devops]. Le composant principal utilisé est **Azure Boards**, qui assure la gestion agile à travers les fonctionnalités suivantes :

- **Backlogs** : priorisation et planification du travail à venir au niveau des Epics, Features et User Stories.
- **Boards (Kanban)** : visualisation du flux de travail avec des colonnes représentant les états des tickets (*New, Active, Resolved, Closed*).

- **Sprints** : planification des itérations avec distribution des tâches entre les membres de l'équipe.
- **Burndown Charts** : graphiques de suivi montrant le travail restant vs. la ligne idéale de progression, permettant de détecter rapidement les écarts et d'ajuster l'effort.
- **Dashboards** : tableaux de bord personnalisables agréant les métriques clés du projet (vélocité, tendances de défauts, couverture de test).
- **Queries** : requêtes personnalisées pour filtrer et grouper les tickets selon différents critères (sévérité, assignation, état, sprint).

Azure Boards supporte les processus Agile, Scrum et CMMI, avec des types de *work items* prédéfinis (Epic, Feature, User Story, Task, Bug) et des transitions d'état configurables [**microsoft2025boards**].

4.2 Gestion des tickets et cycle de vie des défauts

4.2.1 Typologie des tickets

Dans le contexte d'un projet de migration ADMP, les tickets Azure DevOps se déclinent en plusieurs types organisés hiérarchiquement, comme le résume le Tableau ??.

TABLE 4.2 – Hiérarchie des types de tickets Azure DevOps en contexte ADMP

Type	Description	Exemple en migration
Epic	Initiative stratégique de haut niveau	« Migration du domaine Opérations »
Feature	Fonctionnalité regroupant plusieurs User Stories	« Migration des Work Orders »
User Story	Besoin métier décrit du point de vue utilisateur	« Migrer les compétences des ressources de service »
Task	Tâche technique unitaire	« Rédiger le RC du lot SKL01 »
Bug / Defect	Anomalie identifiée lors des tests	« Team Leader name vide pour certains contrats »

Cette hiérarchie (Epic → Feature → User Story → Task) permet une traçabilité complète depuis les objectifs stratégiques jusqu'aux tâches individuelles, et assure que chaque action est reliée à un besoin métier identifié.

4.2.2 Workflow d'un ticket de défaut

Le cycle de vie d'un ticket de défaut dans le contexte ADMP suit un processus structuré en cinq étapes, illustré par la Figure ??.




FIGURE 4.2 – Cycle de vie d'un ticket de défaut ADMP (5 états)

Étape 1 — Création. Le testeur ou le client identifie une anomalie dans les données migrées et crée un ticket avec une description détaillée (étapes de reproduction, résultat attendu vs. résultat obtenu, captures d'écran). Le ticket est assigné au Data Analyst responsable du domaine fonctionnel concerné.

Étape 2 — Analyse (Root Cause). Le Data Analyst identifie la cause racine du défaut en examinant les spécifications de migration. Cette analyse s'appuie sur une méthodologie rigoureuse : consultation du SDS/IDS/TDS pour vérifier les noms exacts des champs, du DS pour la structure hiérarchique et les clés de jointure, du RC pour les règles de création d'enregistrements, et du DP pour les règles de peuplement des champs.

Étape 3 — Résolution. Le Data Analyst implémente la correction dans les Smart Designs. Celle-ci peut prendre la forme d'une modification de règle RC/DP, d'un ajout de transcodification, d'un *data patch* SQL, ou d'une mise à jour de la structure DS. La résolution est documentée dans le champ « *Resolution Action* » du ticket.

Étape 4 — Validation. Après génération d'un nouveau snapshot de données, le testeur vérifie que le défaut est corrigé et qu'aucune régression n'a été introduite dans les données précédemment validées.

Étape 5 — Clôture. Une fois la validation réussie, le ticket est marqué « Closed » avec les commentaires de validation confirmant la correction effective.

4.2.3 Priorisation et classification

Les défauts sont classifiés selon deux axes complémentaires qui déterminent l'ordre de traitement, comme le précise le Tableau ??.

TABLE 4.3 – Axes de classification des défauts

Axe	Niveaux	Description
Sévérité	Critical / High / Medium / Low	Impact technique du défaut sur le système : données corrompues, perte d'enregistrements, incohérence référentielle...
Priorité	P1 (Urgente) / P2 (Haute) / P3 (Moyenne) / P4 (Basse)	Urgence de résolution du point de vue métier : périmètre fonctionnel impacté, criticité pour le Go Live...

La distinction entre **sévérité** et **priorité** est essentielle : un défaut peut être techniquement critique (données corrompues) mais de priorité moyenne s'il ne concerne qu'un périmètre limité, ou inversement. Des réunions de triage hebdomadaires permettent à l'équipe de réévaluer les priorités en fonction de l'avancement du projet et des retours du client.

4.2.4 Exemple de cycle complet d'un défaut

Pour illustrer concrètement le processus, considérons un défaut typique rencontré en projet de migration. Le Tableau ?? détaille le cycle complet du ticket suivant : « Le champ Team Leader est vide pour certains Work Orders alors qu'il devrait être renseigné. »

TABLE 4.4 – Exemple de cycle complet d'un ticket de défaut

Étape	Action	Détail
1. Création	Ticket créé par le testeur	Pour un contrat donné, 6 Work Orders ont le champ CER_TEAMLEADER__C vide
2. Analyse	Identification de la root cause	Le RC du lot WRK01 filtre les Work Orders par flag (Y/N), mais ne couvre pas le cas où le flag est Y et le champ source correspondant est NULL
3. Résolution	Modification du RC/DP	Ajout d'une condition dans le RC pour gérer le cas <code>Flag = Y AND Source_TL IS NULL</code> , avec fallback vers le Service Resource principal
4. Validation	Nouveau snapshot P20.3	Requête SQL de vérification : 0 cas KO dans le nouveau snapshot (vs. 132 dans P20.1 et 32 dans P20.2)
5. Clôture	Ticket fermé	Commentaire : « Fix validé — régression zéro — confirmé par comparaison P20.1 → P20.2 → P20.3 »

Ce cycle illustre l'approche systématique de l'équipe : chaque défaut est tracé de bout en bout, avec une documentation complète de l'analyse, de la correction et de la validation.

4.3 Processus de validation des données

4.3.1 Snapshots et cycles de test

Le processus de validation repose sur un mécanisme de **snapshots** — des extractions complètes des données à un instant donné — qui servent de base aux cycles de test successifs. Chaque snapshot est identifié par un code de version (P20.1, P20.2, P20.3...) et représente l'état des données après application des dernières corrections.

La progression entre les snapshots suit une logique de convergence vers la qualité cible, illustrée par la Figure ?? . À chaque nouveau snapshot, l'équipe vérifie que les défauts précédemment identifiés sont corrigés (test de non-régression) et qu'aucun nouveau défaut n'a été introduit par les corrections.




FIGURE 4.3 – Convergence progressive des snapshots vers la qualité cible

4.3.2 Stratégie de test

La stratégie de test adoptée dans les projets de migration ADMP couvre trois niveaux complémentaires [datagaps2025, quinnnox2025] :

1. **Tests unitaires (par lot de migration)** — Chaque lot de migration (ex. : SKL01, WRK01, RES01) est testé individuellement pour vérifier que les règles de création (RC) et de peuplement (DP) produisent les résultats attendus. Les Data Analysts rédigent des requêtes SQL ciblées pour contrôler les cas nominaux et les cas limites.
2. **Tests d'intégration (inter-lots)** — Les relations entre les lots de migration sont vérifiées pour garantir l'intégrité référentielle. Par exemple, un Work Order doit pointer vers un Service Contract existant, et un ServiceResourceSkill doit référencer un ServiceResource et un Skill valides. Ces tests détectent les incohérences de clés étrangères et les enregistrements orphelins.
3. **Tests de réconciliation** — La réconciliation compare les volumes de données entre la source et la cible à plusieurs niveaux de granularité : nombre total d'enregistrements par table, sommes de contrôle sur les champs numériques, et vérification d'échantillons aléatoires. L'objectif est de garantir qu'aucune donnée n'a été perdue, dupliquée ou altérée durant le processus [datafold2025].

4.3.3 Rapports de validation et KPIs

La plateforme ADMP génère automatiquement plusieurs types de rapports de validation, consultables via l'**ADMP Portal**, synthétisés dans le Tableau ??.

TABLE 4.5 – Rapports de validation automatiques de la plateforme ADMP

Rapport	Phase	Contenu
Load Report	Post-extraction	Confirmation du chargement réussi des fichiers source dans la base SQL Server
Data Audit	Post-extraction	KPIs sur les données sources : complétude, distribution des valeurs, détection d'anomalies
DS Audit	Post-design	Validation de la cohérence des Data Structures (relations hiérarchiques)
Integrity Check	Post-transformation	Vérification de l'intégrité référentielle entre les tables cibles
Run Report	Post-transformation	Statistiques d'exécution : enregistrements traités, créés, rejetés, avec détail des erreurs

En complément des rapports automatiques, l'équipe utilise des requêtes SQL sur la base SQL Server pour des analyses *ad hoc* plus fines — lister tous les cas KO d'un ticket, vérifier la présence de doublons, ou valider une logique de déduplication spécifique.

4.3.4 Communication avec le client

La communication avec le client s'articule autour de deux livrables transversaux fondamentaux :

- **Key Decisions (KD)** : ce document recense les écarts majeurs identifiés entre le système source et le système cible, ainsi que les décisions prises conjointement avec le métier pour les résoudre. Chaque Key Decision suit un processus formel de proposition, discussion et validation. Les KD sont critiques car elles engagent à la fois l'équipe technique et le client sur des choix qui impactent directement les données migrées.
- **Questions & Answers (Q&A)** : ce document sert de canal structuré pour les échanges techniques et fonctionnels entre l'équipe ADMP et le client. Les questions sont formalisées, numérotées et suivies jusqu'à résolution. Elles couvrent aussi bien des clarifications sur les modèles de données que des demandes de validation de règles métier spécifiques.

Au-delà de ces documents formels, des **revues de validation régulières** sont organisées avec

le client pour présenter les résultats des derniers snapshots, discuter des défauts ouverts et aligner les priorités pour le sprint suivant.

4.4 Collaboration et communication

4.4.1 Organisation de l'équipe projet

L'équipe projet ADMP est structurée en deux grandes composantes complémentaires. Le **Front Office** (Tableau ??) regroupe les équipes de design fonctionnel en contact direct avec le client, focalisées sur les règles métier. Le **Back Office** (Tableau ??) rassemble les équipes techniques et de support, responsables de l'infrastructure et de la plateforme.

TABLE 4.6 – Composition du Front Office — équipes de design

Rôle	Responsabilité
Project Manager (PM)	Pilotage global, relation client, priorisation du backlog
Team Lead	Coordination technique, facilitation Scrum, revue des designs
Data Analyst (DA)	Rédaction des spécifications (RC, DP, DS), analyse de données, résolution de tickets
Data Analyst Junior / Stagiaire	Contribution aux analyses, tests et documentation sous supervision

TABLE 4.7 – Composition du Back Office — équipes techniques

Rôle	Responsabilité
ADMP Platform Specialist	Configuration et maintenance du Core Engine, gestion des environnements
Architecture Team	Conception technique, intégration système, performance
IT Experts (Source/Target)	Expertise sur les systèmes source et cible du client
Security & Infrastructure	Sécurité des transferts de données, gestion des accès, infrastructure

Cette organisation distingue clairement le Front Office du Back Office, tout en assurant une communication fluide entre les deux via les rituels d'équipe.

4.4.2 Rituels d'équipe

Les rituels agiles adoptés par l'équipe ADMP sont adaptés au contexte spécifique de la migration de données, comme le résume le Tableau ??.

TABLE 4.8 – Rituels Agile de l'équipe ADMP

Rituel	Fréquence	Durée	Participants	Objectif
Daily Stand-up	Quotidien	15 min	Équipe DA + Team Lead	Avancement, blo-cages, objectifs du jour
Sprint Planning	Début de sprint	2–4 h	Équipe + PM	Définir les ob-jectifs, distri-buer les tickets
Sprint Review	Fin de sprint	1–2 h	Équipe + Client	Présenter les ré-sultats, re-cueillir le feed-back
Sprint Retrospective	Fin de sprint	1 h	Équipe interne	Identifier amélio-rations, plan d'ac-tions
Backlog Refinement	Hebdomadaire	1 h	PM + Team Lead + DA seniors	Affiner les User Stories, estimer l'effort
Triage des défauts	Hebdomadaire	30 min	Équipe + PM	Réévaluer les prio-rités des tickets ouverts

Le **Daily Stand-up** est le rituel le plus structurant : chaque membre partage en 2–3 minutes son avancement, ses blocages éventuels et ses objectifs de la journée. La **Sprint Retrospective** mérite une attention particulière : structurée autour des trois questions « Qu'est-ce qui a bien fonctionné ? », « Qu'est-ce qui peut être amélioré ? » et « Quelles actions concrètes prenons-nous ? », elle alimente un plan d'amélioration continue.

4.4.3 Outils collaboratifs

L'écosystème d'outils collaboratifs de l'équipe ADMP couvre l'ensemble des besoins de communication, de stockage et de versioning, comme le synthétise le Tableau ??.

TABLE 4.9 – Écosystème d'outils collaboratifs de l'équipe ADMP

Outil	Usage principal
Microsoft Teams	Communication instantanée, réunions virtuelles, canaux thématiques par projet
SharePoint	Stockage et partage des documents de design, rapports et livrables client
IDMF Explorer	Versioning des documents de migration — check-out exclusif, développement, check-in avec historique complet
Azure DevOps	Gestion des tickets, backlogs, sprints, dashboards, burndown charts
SQL Server Management Studio	Requêtage, analyse ad hoc, data patch, optimisation des requêtes de validation
ADMP Portal	Lancement des traitements ETL, consultation des rapports, analyse interactive des erreurs
Outlook / Email	Communication formelle avec le client, partage des Key Decisions et Q&A

L'**IDMF Explorer** mérite une mention spéciale : son mécanisme de *check-out* / *check-in* garantit qu'un seul Data Analyst modifie un fichier à la fois, évitant les conflits d'édition et assurant la traçabilité complète des modifications apportées aux Smart Designs.

4.5 Bilan méthodologique

L'organisation décrite dans ce chapitre apporte des bénéfices concrets et mesurables au projet de migration. Sur le plan de l'**approche Agile**, quatre apports sont particulièrement significatifs :

- **Détection précoce des problèmes** : les cycles itératifs courts (2–4 semaines) permettent d'identifier et de corriger les défauts au plus tôt, réduisant leur coût de correction de manière significative. Un défaut détecté en phase de test coûte en moyenne 15 fois moins qu'un défaut découvert en production [quinnox2025].
- **Visibilité et transparence** : les dashboards Azure DevOps, les burndown charts et les rapports automatiques ADMP offrent une visibilité en temps réel sur l'état du projet, tant pour l'équipe interne que pour le client.
- **Adaptabilité** : la priorisation dynamique du backlog permet de réagir rapidement aux changements de périmètre, aux nouvelles exigences du client, ou aux découvertes réalisées en cours de migration.
- **Qualité progressive et vérifiable** : la comparaison systématique entre snapshots (P20.1 → P20.2 → P20.3) fournit une preuve tangible de la convergence vers la qualité cible.

Trois **enseignements clés** se dégagent de la pratique terrain :

- La **rigueur dans la documentation des tickets** (description complète, root cause, resolution action) est un facteur clé de succès : elle facilite le transfert de connaissances et accélère la résolution des défauts similaires.
- La **communication structurée avec le client** (Key Decisions, Q&A) est indispensable pour éviter les malentendus et garantir l'alignement entre les attentes métier et l'implémentation technique.
- **L'équilibre entre autonomie et collaboration** — chaque Data Analyst travaille de manière autonome sur ses lots tout en partageant ses découvertes lors des dailys — constitue le mode de fonctionnement le plus efficace pour une équipe de migration distribuée.

Ce cadre méthodologique constitue le socle opérationnel sur lequel s'appuie notre contribution technique. Le chapitre suivant présentera la conception et l'architecture de la solution IA développée dans ce contexte.

Chapitre 5

Conception et Architecture de la Solution

La conception d'une solution à vocation industrielle exige une démarche rigoureuse qui transforme des exigences métier en une architecture concrète, cohérente et maintenable. Fort du cadre méthodologique Agile décrit au chapitre 4 et des fondements posés dans l'état de l'art, ce chapitre présente, dans un premier temps, la plateforme **ADMP AI Studio** dans son ensemble : sa vision de modernisation, ses acteurs, ses exigences et sa modélisation UML. Dans un second temps, il détaille la **contribution spécifique de ce PFE** : le module de génération Databricks, dont l'architecture technique, le pipeline de compilation et les décisions de conception sont exposés avec précision.

5.1 Vue d'ensemble de la modernisation

La modernisation opérée par ADMP AI Studio constitue une rupture architecturale profonde avec l'approche classique de la migration de données. Cette section présente la trajectoire de cette évolution, puis décrit l'organisation de la plateforme cible.

5.1.1 De ADMP Classique à ADMP AI Studio

La plateforme ADMP, dans sa version classique, représente déjà une avancée significative par rapport aux approches ETL traditionnelles : le paradigme *Smart Design* permet de rédiger les règles de migration dans un langage métier structuré, puis de les compiler automatiquement. Cependant, le moteur d'exécution historique — le **ADMP Core Engine (IDMF)**, solution ETL propriétaire on-premise développée par Accenture — présente des limites structurelles : scalabilité contrainte par un modèle scale-up, coûts d'infrastructure fixes, et intégration difficile avec les architectures cloud-native modernes.

La Figure ?? illustre la transformation opérée par la modernisation : de l'**ADMP Classique**, dont la compilation est semi-automatique et la cible est un système transactionnel on-premise, à l'**ADMP AI Studio**, où la plateforme web centralise le cycle de migration, le moteur Databricks offre une exécution massivement parallèle, et les agents IA assistent la conception.




FIGURE 5.1 – Modernisation ADMP : état classique versus ADMP AI Studio

Le Tableau ?? synthétise cette évolution selon sept critères structurants.

TABLE 5.1 – Analyse comparative : ADMP Classique vs ADMP AI Studio

Critère	ADMP Classique	ADMP AI Studio
Moteur ETL	ADMP Core Engine (IDMF) — propriétaire on-premise	Apache Spark sur Databricks Runtime 14+
Intelligence artificielle	Aucune	Claude API (Anthropic) — assistance à la conception
Génération de code	Semi-automatique, intervention manuelle fréquente	Automatisée (100%) depuis les documents ADMP
Scalabilité	Scale-up : nœud unique, capacité limitée	Scale-out : clusters élastiques, 1 à 100+ nœuds
Stockage cible	Bases relationnelles (Oracle, SQL Server)	Delta Lake + Unity Catalog (ACID, Time Travel)
Interface de conception	ADMP Design Tools (Word / Excel)	Plateforme web unifiée, gestion projet intégrée
Format de sortie	Smart Designs (programmes exécutables)	8 formats : Databricks, SQL Server, ADF, Python...

5.1.2 Présentation de la plateforme ADMP AI Studio

ADMP AI Studio est la concrétisation de cette modernisation. La plateforme web centralise l'ensemble du cycle de migration autour d'une interface moderne, structurée en **sept modules fonctionnels** et **huit phases** de projet. Elle produit des artefacts dans **huit formats de sortie** couvrant les principales plateformes cloud et on-premise.

Sept modules fonctionnels

TABLE 5.2 – Modules fonctionnels d'ADMP AI Studio

Module	Fonctionnalité principale
Création de projet	Configuration d'un projet : Industry, Target, Source, Data Scope, équipe
Gestion des utilisateurs	Administration des accès, des rôles (RBAC) et des équipes projet
Agents IA	Configuration et supervision des agents IA (Claude API) — roadmap plateforme
Journaux système	Consultation des logs et monitoring des opérations de compilation
Formation	Module de formation intégré à destination des équipes de migration
Apprentissage	Base de connaissances et ressources documentaires de la plateforme
Paramètres	Configuration globale de la plateforme et des préférences utilisateur

Huit phases du cycle de migration

TABLE 5.3 – Les huit phases du cycle de migration dans ADMP AI Studio

#	Phase	Description
1	Project Management	Pilotage global, planning, gouvernance et suivi de l'avancement
2	Data Scope	Définition du périmètre des données : SDS (source), TDS (cible), IDS (intermédiaire)
3	Extract	Configuration et gestion de l'extraction des données sources
4	Data Profiling & Cleansing	Audit qualité, statistiques et nettoyage des données extraites
5	Transform	Conception des règles RC / DP et génération automatique des bundles
6	Load	Chargement des données transformées dans le système cible
7	Validation	Réconciliation et contrôle d'intégrité post-chargement
8	Cutover	Plan de basculement final en production et bilan go-live

Huit formats de sortie

TABLE 5.4 – Formats de sortie du module Package Generation d'ADMP AI Studio

Format	Description
ADMP Native	Export ZIP complet : documents Excel/Word (DS, DP, RC, TT, paramètres, steps)
SQL Server	Stored procedures T-SQL autonomes avec orchestration, déployables sur SQL Server / Azure SQL
Snowflake	SQL Scripting ou Snowpark Python, stored procedures avec Task DAG
Azure Data Factory	Pipelines ADF avec stored procedures ou Data Flows natifs
Python	Scripts Python autonomes avec flat files CSV, connecteur DB optionnel
Databricks	Bundle Python (.whl) avec notebooks PySpark et Unity Catalog — objet de ce PFE
AWS Glue	Jobs PySpark AWS Glue avec workflow et triggers, déployables sur AWS
PowerShell	Scripts PS1 cross-platform, compatibles PowerShell 5.1+ et 7+

5.2 Spécification des besoins

Cette section présente les exigences de la plateforme ADMP AI Studio dans son ensemble : acteurs, exigences fonctionnelles par phase, exigences non fonctionnelles et contraintes techniques. Ces spécifications constituent le référentiel à partir duquel ont été conçues l'architecture et la modélisation UML décrites dans les sections suivantes.

5.2.1 Identification des acteurs

La plateforme ADMP AI Studio implique sept profils d'acteurs distincts, dont les rôles et responsabilités couvrent l'ensemble du cycle de migration. Le Tableau ?? les décrit.

TABLE 5.5 – Acteurs de la plateforme ADMP AI Studio

Acteur	Type	Rôle et responsabilités
Administrator	Interne	Gère la plateforme : création des projets, attribution des accès, configuration globale et supervision du système
Migration Designer	Interne	Conçoit les règles de migration (RC, DP, TT), pilote les phases Transform et valide les spécifications fonctionnelles
Data Analyst	Interne	Analyse la qualité des données sources (profilage, nettoyage), définit le data scope et prépare les rapports de profilage
Test Engineer	Interne	Conçoit et exécute les cas de test, gère les tickets de validation et rédige les rapports de réconciliation
Business Reviewer	Client	Valide la conformité fonctionnelle des données migrées par rapport aux exigences métier
Cutover Manager	Interne	Planifie et orchestre la bascule en production : jalons, séquences de cutover, gestion des risques
Client	Externe	Représente l'organisation bénéficiaire de la migration ; participe aux jalons de validation et aux revues go/no-go

5.2.2 Exigences fonctionnelles

Les exigences fonctionnelles de la plateforme ont été élicitées à travers l'analyse des huit phases du cycle de migration. Le Tableau ?? synthétise les exigences fonctionnelles critiques par phase.

TABLE 5.6 – Exigences fonctionnelles par phase — ADMP AI Studio

ID	Phase	Description
EF-01	Project Management	Créer et configurer un projet de migration avec les paramètres Industry, Target, Source et les membres d'équipe
EF-02	Project Management	Gérer les rôles et les droits d'accès de chaque membre via un contrôle RBAC granulaire
EF-03	Data Scope	Définir le périmètre des données (SDS / TDS / IDS) avec verrouillage de section par phase
EF-04	Data Scope	Exporter le périmètre vers le format natif ADMP et les outils de conception
EF-05	Extract	Configurer les sources d'extraction et importer les fichiers de données dans la plateforme
EF-06	Extract	Monitorer l'avancement des extractions et gérer les erreurs de chargement
EF-07	Data Profiling & Cleansing	Générer des rapports de profilage automatiques (statistiques, nullité, distributions) par entité
EF-08	Data Profiling & Cleansing	Documenter les règles de nettoyage et valider la conformité qualité avant transformation
EF-09	Transform	Concevoir et versionner les règles de transformation (RC, DP, TT) dans l'éditeur intégré
EF-10	Transform	Générer automatiquement le bundle cible (ex. Databricks .whl) à partir des documents ADMP
EF-11	Load	Configurer et exécuter le chargement des données transformées dans le système cible
EF-12	Load	Monitorer l'avancement du chargement en temps réel et alerter en cas d'anomalie
EF-13	Validation	Exécuter les contrôles de réconciliation quantitative et qualitative (source-cible)
EF-14	Validation	Générer un rapport de rapprochement consolidé incluant les écarts et leur analyse
EF-15	Cutover	Créer et suivre un plan de cutover structuré : tâches, jalons, responsables, délais
EF-16	Cutover	Documenter le bilan de go-live et archiver le dossier de migration

5.2.3 Exigences non fonctionnelles

TABLE 5.7 – Exigences non fonctionnelles de la plateforme ADMP AI Studio

ID	Catégorie	Description
ENF-01	Performance	Temps de réponse inférieur à 2 secondes pour toutes les opérations CRUD standard
ENF-02	Performance	Génération d'un bundle complet (10 unités, 500 branches SQL) en moins de 30 secondes
ENF-03	Disponibilité	SLA 99,5 % garantissant au plus 3,6 heures d'interruption mensuelle
ENF-04	Sécurité	Authentification multi-facteurs (MFA) obligatoire et contrôle d'accès basé sur les rôles (RBAC)
ENF-05	Traçabilité	Journalisation complète (horodatée et immuable) de toutes les actions critiques sur les données
ENF-06	Scalabilité	Support simultané de 50+ projets de migration actifs sans dégradation de performance
ENF-07	Maintenabilité	Couverture de tests automatisés supérieure à 80 % sur les modules critiques (compilateur, API)
ENF-08	Déterminisme	Deux compilations successives à partir des mêmes inputs produisent un output binaire identique
ENF-09	Compatibilité	Support des navigateurs Chrome 90+, Edge 90+ et Firefox 88+ sans plugin supplémentaire

5.2.4 Contraintes techniques

TABLE 5.8 – Contraintes techniques de la plateforme ADMP AI Studio

ID	Type	Contrainte
CT-01	Langage & framework	Serveur Node.js 18+ en TypeScript ; interface web React ; API REST JSON
CT-02	Base de données	PostgreSQL 15+ pour la persistance des métadonnées projet et des documents de migration
CT-03	Runtime cible	Bundle Databricks compatible Databricks Runtime 14.x (Python 3.11, PySpark 3.5, Delta Lake 3.x)
CT-04	Gouvernance des données	Tables Delta cibles gérées par Unity Catalog ; toute référence inclut les trois niveaux (<i>catalog.schema.table</i>)
CT-05	Versioning	Code versionné sur Bitbucket ; livraisons sur la branche dev via commits atomiques et documentés
CT-06	Formats documentaires	Documents ADMP au format TXT (RC), JSON (DP, DS, MS), XML (TT, IC, PARAM, SDS, IDS, TDS, SDEF)
CT-07	Isolation des formats	L'ajout du format Databricks ne doit pas affecter les autres formats de sortie existants
CT-08	Secrets	Aucune credential ne doit être embarquée dans le bundle généré ; les secrets transitent via Databricks Secrets

5.3 Modélisation UML

La modélisation UML de la plateforme ADMP AI Studio s'appuie sur trois niveaux de représentation complémentaires : les diagrammes de cas d'utilisation pour capturer les interactions acteurs-système, les diagrammes de séquence pour décrire les flux dynamiques les plus critiques, et le diagramme de classes pour exposer la structure des données persistées. L'ensemble des diagrammes a été réalisé avec la bibliothèque `tikz-uml`.

5.3.1 Diagrammes de cas d'utilisation

La modélisation des cas d'utilisation est organisée en neuf diagrammes : un diagramme de **configuration initiale du projet** (création et paramétrage), puis un diagramme par phase du cycle de migration. Chaque diagramme est suivi des fiches descriptives des cas d'utilisation dont la complexité fonctionnelle et la représentativité du cycle justifient une description détaillée. Les cas d'utilisation restants sont décrits en Annexe A.

Configuration initiale d'un projet

La création d'un projet passe par un assistant en six étapes (*wizard*) qui collecte toutes les informations nécessaires à l'initialisation du projet et de son périmètre de données.





FIGURE 5.2 – Diagramme UC : Configuration initiale d'un projet (assistant 6 étapes)

Créer un nouveau projet de migration

Acteur(s)	Administrator
Préconditions	Utilisateur authentifié avec le rôle Administrator ; référentiels d'industrie et de systèmes disponibles
Déclencheur	L'administrateur clique sur <i>New Project</i> depuis le tableau de bord global
Scénario nominal	Étape 1 — L'administrateur sélectionne l'industrie et le secteur d'activité dans la liste proposée. Étape 2 — Il choisit le système cible (ex. Workday, SAP, Oracle Fusion) parmi les packages disponibles. Étape 3 — Il spécifie le système source (nom, type, version). Étape 4 — Il renseigne les détails du projet : nom, nom du client, description, utilisateur administrateur. Étape 5 — Il configure le volume d'infrastructure : taille de stockage, taille de base de données, spécifications techniques. Étape 6 — Il initialise le périmètre de données : sélection des tables initiales et type de scope. Fin — Le projet est créé ; les 8 phases sont initialisées ; l'administrateur est redirigé vers le tableau de bord du projet.
Alt. / Erreurs	Système cible non disponible : message d'invitation à contacter l'équipe ADMP. Champ obligatoire vide : validation inline avant passage à l'étape suivante. Nom de projet déjà utilisé : suggestion de nom disponible.
Postconditions	Projet créé avec les 8 phases initialisées ; l'administrateur dispose d'un accès complet ; Quick Start disponible pour un démarrage guidé

Phase 1 — Project Management

La phase Project Management couvre le pilotage global du projet : rapports hebdomadaires, gestion des parties prenantes, planification Gantt, organisation des workshops et suivi des prérequis.

**FIGURE 5.3** – Diagramme UC : Phase 1 — Project Management

Créer et publier un rapport hebdomadaire

Acteur(s)	Migration Designer, Cutover Manager
Préconditions	Projet actif ; semaine de référence écoulée
Déclencheur	Le Migration Designer clique sur <i>New Report</i> dans la section Weekly Reports
Scénario nominal	1. Il sélectionne la semaine et l'année du rapport (versionnage v00.01). 2. Il renseigne les sections du rapport : risques actifs, blocages, livrables, prochaines étapes. 3. Il ajoute les métriques de santé du projet (nombre de risques, tickets ouverts, avancement). 4. Il sauvegarde en brouillon ; le rapport est visible en mode <i>Draft</i>. 5. Après validation interne, il publie le rapport ; il devient visible pour toutes les parties prenantes. 6. Il exporte le rapport publié en PowerPoint pour présentation au client.
Alt. / Erreurs	Rapport déjà existant pour la semaine : avertissement ; possibilité de créer une nouvelle version. Export PowerPoint échoué : retry automatique.
Postconditions	Rapport publié ; archivé dans l'historique des versions ; disponible pour export et partage

Planifier via Gantt et jalons de livraison

Acteur(s)	Migration Designer
Préconditions	Projet initialisé ; équipe projet définie (parties prenantes)
Déclencheur	Le Migration Designer accède à la section Planning pour structurer la feuille de route
Scénario nominal	1. Il crée les éléments de planning : jalons, tâches, dépendances, dates de début et fin. 2. Il visualise la feuille de route sur le diagramme de Gantt. 3. Il crée les <i>Delivery Releases</i> : nom de la release, date cible, périmètre livré. 4. Il associe les tâches aux releases. 5. Il ajuste les dépendances entre tâches en cas de retard détecté. 6. Il exporte le planning pour partage avec le comité de pilotage.
Alt. / Erreurs	Dépendance circulaire entre tâches : détection automatique et avertissement. Date de release impossible compte tenu des dépendances : recalcul proposé.
Postconditions	Planning structuré et partagé ; jalons visibles sur le tableau de bord ; équipe notifiée des échéances

Phase 2 — Data Scope

Le Data Scope définit le périmètre complet de la migration en trois couches : tables sources (SDS), tables intermédiaires (IDS), et tables cibles (TDS). Il constitue la référence pour toutes les phases suivantes.





FIGURE 5.4 – Diagramme UC : Phase 2 — Data Scope

Définir le périmètre des données (SDS / IDS / TDS)

Acteur(s)	Data Analyst, Migration Designer
Préconditions	Projet initialisé ; système source et cible identifiés
Déclencheur	Le Data Analyst accède à l'onglet <i>Data Scope</i> pour définir les trois couches
Scénario nominal	1. Il sélectionne l'onglet <i>Source</i> et crée les tables sources : nom, domaine, système, liste des colonnes (nom, type, longueur, contraintes). 2. Il passe à l'onglet <i>Intermediary</i> et définit les tables intermédiaires utilisées dans la transformation. 3. Il passe à l'onglet <i>Target</i> et définit les tables cibles avec leur structure dans le nouveau système. 4. Pour accélérer la saisie, il importe un fichier Excel ; la plateforme auto-détecte les colonnes et types. 5. Il corrige les anomalies détectées lors de l'import (types incohérents, colonnes manquantes). 6. Il publie le périmètre ; il devient disponible comme référence pour les phases Extract et Transform.
Alt. / Erreurs	Format Excel invalide : message d'erreur avec détail des colonnes attendues. Table en doublon : avertissement et option de fusion. Publication avec tables incomplètes : validation requise.
Postconditions	Périmètre de données versionnée ; SDS/IDS/TDS disponibles pour toutes les phases suivantes

Phase 3 — Extract

La phase Extract couvre la collecte des données auprès du client et leur chargement dans la plateforme : configuration des sources d'extraction, upload de fichiers, auto-détection de structure et alignement avec le SDS.


**FIGURE 5.5** – Diagramme UC : Phase 3 — Extract

Charger un fichier source et aligner avec le SDS

Acteur(s)	Data Analyst
Préconditions	Data scope source (SDS) défini ; fichier d'extraction disponible (CSV, Excel, TXT)
Déclencheur	Le Data Analyst dispose des fichiers bruts fournis par le client et souhaite les intégrer dans la plateforme
Scénario nominal	1. Le Data Analyst crée une nouvelle extraction : nom, description, source associée. 2. Il téléverse le fichier via la zone de glisser-déposer (drag & drop). 3. Si le fichier est un Excel multi-onglets, la plateforme liste les feuilles ; il sélectionne les feuilles à importer. 4. Il lance l'<i>auto-detect</i> : la plateforme analyse la structure (colonnes, types, séparateurs) et propose un mapping automatique. 5. Il compare la structure détectée avec le SDS correspondant et corrige les écarts. 6. Il valide l'alignement ; les données sont indexées et disponibles pour la phase Profiling.
Alt. / Erreurs	Structure non reconnue (encodage, séparateur inconnu) : l'utilisateur configure manuellement les paramètres de parsing. Colonne SDS introuvable dans le fichier : marquage comme manquante avec alerte.
Postconditions	Fichier source intégré et aligné avec le SDS ; disponible pour l'audit de qualité (Phase 4)

Phase 4 — Profiling & Cleansing

Cette phase audit la qualité des données sources, détecte et résout les doublons, puis définit et applique des règles de nettoyage et de standardisation avant la transformation.

**FIGURE 5.6** – Diagramme UC : Phase 4 — Profiling & Cleansing

Auditer la qualité des données sources


Acteur(s)	Data Analyst
Préconditions	Données sources chargées et alignées avec le SDS (Phase 3)
Déclencheur	Le Data Analyst lance un audit depuis la section <i>Source Data Audit</i>
Scénario nominal	1. Il sélectionne les tables et champs à profiler. 2. La plateforme exécute l'analyse : taux de remplissage, valeurs min/max, valeurs distinctes, distributions, patterns de format. 3. Les anomalies détectées sont listées : valeurs manquantes, outliers, incohérences de format, valeurs hors plage. 4. Le Data Analyst consulte les statistiques par champ dans le rapport de profilage. 5. Il documente les anomalies critiques à corriger avant la transformation. 6. Les résultats alimentent automatiquement le tableau de bord qualité.
Alt. / Erreurs	Données insuffisantes pour le calcul statistique : résultats partiels avec indicateur. Timeout d'analyse sur un volume important : reprise incrémentale.
Postconditions	Rapport de profilage disponible ; anomalies classifiées ; base pour les règles de nettoyage et de déduplication

Dédupliquer les enregistrements

Acteur(s)	Data Analyst
Préconditions	Données sources importées ; rapport de profilage indiquant des doublons potentiels
Déclencheur	Le Data Analyst accède à la section <i>Data Deduplication</i> pour traiter les doublons
Scénario nominal	1. Il sélectionne la table source à dédupliquer. 2. Il configure les règles de correspondance : type (exact, phonétique, approximatif), champs de comparaison, seuils de similarité. 3. Il lance le moteur de déduplication ; les clusters de doublons potentiels sont générés. 4. Pour chaque cluster, il examine les enregistrements et choisit : fusionner (golden record), conserver séparément, ou ignorer le cluster. 5. Il valide les fusions ; un enregistrement <i>golden</i> est produit par cluster. 6. Le jeu de données nettoyé est disponible pour la phase Transform.
Alt. / Erreurs	Cluster trop large (> 50 enregistrements) : revue paginée obligatoire avant fusion. Règle de correspondance trop permissive : ajustement du seuil proposé après aperçu des faux positifs.
Postconditions	Jeu de données déduplicué ; golden records créés ; taux de déduplication tracé dans le tableau de bord qualité

Phase 5 — Transform

La phase Transform est le cœur intellectuel de la migration : analyse des domaines, conception des unités de migration (RC/DP), configuration des paramètres et tables de transco, génération de packages, exécution et simulation.

**FIGURE 5.7** – Diagramme UC : Phase 5 — Transform

Concevoir les unités de migration (RC / DP)

Acteur(s)	Migration Designer
Préconditions	Analyse des domaines complète ; Data Scope validé ; tables de transco configurées
Déclencheur	Le Migration Designer ouvre une unité de migration dans la section <i>Design</i> pour rédiger les règles
Scénario nominal	1. Il sélectionne un domaine fonctionnel (ex. <i>Customers</i>) et ouvre l'éditeur d'unités de migration. 2. Il crée l'unité et renseigne le Record Creation (RC) : pseudo-code avec instructions IF/ELSE, callWriteFile, callDataPopulate, variables et exceptions. 3. Il renseigne le Data Population (DP) : pour chaque champ cible, il définit la source, la formule de transformation et le format. 4. Il configure les paramètres run-time et les Q&A associés à l'unité. 5. Il sauvegarde ; une nouvelle version du document est créée automatiquement. 6. Il exporte les documents RC/DP au format Excel ou ZIP ADMP natif pour revue externe.
Alt. / Erreurs	Erreur de syntaxe dans le RC : validation inline avec localisation de l'erreur. Import ZIP échoué (format non reconnu) : message descriptif avec liste des formats attendus.
Postconditions	Unité de migration versionnée et prête pour la génération de package

Générer le package de migration

Acteur(s)	Migration Designer, Test Engineer
Préconditions	Unités de migration conçues et validées ; format de sortie sélectionné
Déclencheur	Le Migration Designer accède à <i>Package Generation</i> et lance la génération
Scénario nominal	1. Il sélectionne le format de sortie parmi les 8 disponibles (Databricks, SQL Server, ADF, Snowflake...). 2. Il configure les paramètres de génération : catalog cible, schéma, version de runtime. 3. Il lance la compilation ; le serveur déclenche le moteur TypeScript correspondant au format. 4. La progression est affichée en temps réel (unités traitées, branches générées). 5. En cas de succès, le package est disponible au téléchargement (ex. .whl pour Databricks). 6. L'historique des compilations est archivé dans le <i>Dashboard & Reporting</i>.
Alt. / Erreurs	Erreur de compilation : log détaillé avec numéro de ligne du document RC fautif. Timeout > 60 s : notification et retry automatique.
Postconditions	Package généré et archivé ; prêt pour déploiement et exécution (UC : Lancer l'exécution)

Phase 6 — Load

La phase Load configure et exécute le chargement des données transformées dans le système cible, avec validation des contraintes d'intégrité avant et pendant le chargement.




FIGURE 5.8 – Diagramme UC : Phase 6 — Load

Définir et exécuter les contrôles d'intégrité

Acteur(s)	Migration Designer
Préconditions	Données transformées disponibles ; tables cibles créées dans le système cible
Déclencheur	Le Migration Designer accède à <i>Integrity Checks</i> pour valider les contraintes avant chargement
Scénario nominal	1. Il importe les règles d'intégrité depuis Excel (types : PK, FK, NOT NULL, unicité, règles métier). 2. Il filtre les règles par table ou type de contrôle. 3. Il lance l'exécution des contrôles sur les données cibles. 4. Les résultats sont affichés : contrôles passés (vert), avertissements (orange), violations (rouge). 5. Pour chaque violation, il consulte le détail des enregistrements incriminés. 6. Il exporte les résultats en Excel pour documentation et résolution.
Alt. / Erreurs	Volume de violations élevé : pagination et export par lot. Règle invalide (expression SQL incorrecte) : message d'erreur avec suggestion de correction.
Postconditions	Contrôles d'intégrité validés et archivés ; violations documentées ; décision go/no-go pour le chargement prise

Phase 7 — Validation

La phase Validation garantit la conformité des données migrées : tickets de test fonctionnels et réconciliation volumétrique à trois niveaux (comptages, agrégats, ligne par ligne).




FIGURE 5.9 – Diagramme UC : Phase 7 — Validation

Configurer et exécuter la réconciliation (L1 / L2 / L3)

Acteur(s)	Test Engineer
Préconditions	Données chargées dans le système cible ; données sources accessibles
Déclencheur	Le Test Engineer accède à la section <i>Reconciliation</i> pour valider la complétude et la conformité
Scénario nominal	1. Il configure les règles de réconciliation : Niveau 1 — Comparaison des comptages d'enregistrements source vs cible par table. Niveau 2 — Comparaison des agrégats sur les champs clés (sommes, moyennes, MAX/MIN). Niveau 3 — Comparaison ligne par ligne sur les champs sélectionnés. 2. Il lance l'exécution des règles ; la plateforme interroge les deux systèmes. 3. Les résultats sont affichés : pourcentage de concordance, écarts identifiés, statut (passed / warning / failed). 4. Il analyse les écarts ; chaque écart est rattaché à une cause (règle de transformation, donnée manquante...). 5. Il génère le rapport de réconciliation consolidé ; il est soumis au Business Reviewer.
Alt. / Erreurs	Écarts bloquants (L1 > 5 %) : alerte critique ; la phase Cutover est bloquée. Timeout L3 sur grand volume : exécution en mode sampling avec extrapolation.
Postconditions	Rapport de réconciliation archivé ; statut des trois niveaux tracé ; Business Reviewer notifié pour validation

Créer et gérer des tickets de test

Acteur(s)	Test Engineer, Business Reviewer
Préconditions	Données chargées ; critères d'acceptation définis avec le client
Déclencheur	Le Test Engineer crée les tickets pour organiser la campagne de tests fonctionnels
Scénario nominal	1. Il crée un ticket : titre, description, équipe, responsable, release, priorité, catégorie. 2. Il importe en masse les tickets depuis un template Excel. 3. Il groupe les tickets par catégorie et objet métier pour une vue organisée. 4. Il met à jour le statut au fil de l'exécution : <i>Open, In Progress, Passed, Failed</i>. 5. Le Business Reviewer valide les tickets passés et commente les tickets échoués. 6. Il consulte le tableau de bord analytics : taux de résolution, tickets par unité, progression par release.
Alt. / Erreurs	Synchronisation Jira/Mantis indisponible : mode offline avec synchronisation différée. Ticket sans responsable : alerte dans le tableau de bord.
Postconditions	Campagne de tests documentée ; taux d'acceptation calculé ; prérequis pour go-live validés

Phase 8 — Cutover

La phase Cutover planifie et exécute la bascule en production : création de plans avec tâches et dépendances, simulation (dry-run), et exécution en temps réel avec suivi des blocages.




FIGURE 5.10 – Diagramme UC : Phase 8 — Cutover

Exécuter le cutover en temps réel

Acteur(s)	Cutover Manager, Client
Préconditions	Plan de cutover approuvé et simulé (dry-run réussi) ; critères go/no-go définis ; équipes mobilisées
Déclencheur	La fenêtre de cutover s'ouvre ; le Cutover Manager démarre l'exécution depuis le tableau de bord
Scénario nominal	1. Le Cutover Manager ouvre le tableau de bord d'exécution et démarre le plan. 2. Les tâches s'affichent avec leur statut en temps réel : <i>Pending</i>, <i>In Progress</i>, <i>Done</i>, <i>Blocked</i>. 3. Chaque responsable marque ses tâches comme terminées depuis son interface. 4. En cas de blocage, le Cutover Manager documente l'incident et décide : contournement ou activation du plan de rollback. 5. Le chemin critique est mis en évidence ; tout retard sur une tâche critique déclenche une alerte immédiate. 6. À la validation de la dernière tâche, le Cutover Manager prononce officiellement le go-live. 7. Le Client valide la bascule ; le journal d'exécution horodaté est archivé.
Alt. / Erreurs	Tâche critique bloquée : escalade automatique au Cutover Manager. Incident majeur : activation du plan de rollback ; le système source est remis en production. Dépassement de la fenêtre de cutover : go/no-go décision escaladée au comité de pilotage.
Postconditions	Go-live prononcé et documenté ; journal d'exécution archivé ; projet marqué <i>Completed</i> ; certificat de mise en production généré

5.3.2 Diagrammes de séquence

Les cinq diagrammes de séquence suivants modélisent les flux dynamiques les plus critiques de la plateforme ADMP AI Studio.

SD-01 — Création d'un projet de migration




FIGURE 5.11 – SD-01 : Création et initialisation d'un projet de migration

SD-02 — Génération d'un package Databricks




FIGURE 5.12 – SD-02 : Génération d'un package Databricks (vue plateforme)

SD-03 — Verrouillage d'une section (checkout)




FIGURE 5.13 – SD-03 : Verrouillage et édition d'une section (checkout / check-in)

SD-04 — Réconciliation source-cible




FIGURE 5.14 – SD-04 : Réconciliation source-cible

SD-05 — Exécution du cutover




FIGURE 5.15 – SD-05 : Exécution du cutover et validation go-live

5.3.3 Diagramme de classes

Le diagramme de classes (Figure ??) modélise les quinze entités principales de la plateforme ADMP AI Studio persistées dans la base de données PostgreSQL.




FIGURE 5.16 – Diagramme de classes — entités principales d'ADMP AI Studio

5.4 Contribution PFE — Module de génération Databricks

Parmi les huit formats de sortie d'ADMP AI Studio, le format **Databricks** constitue la contribution principale de ce projet de fin d'études. Il repose sur un moteur de compilation entièrement nouveau, développé en TypeScript, qui transforme automatiquement les documents ADMP en un package Python exécutable sur Databricks Runtime.

Périmètre IA : la contribution de ce PFE porte exclusivement sur le module de génération du bundle Databricks. Aucune composante d'intelligence artificielle n'a été développée dans ce cadre. L'ADMP AI Engine et les agents IA font partie de la roadmap globale de la plateforme et sont présentés en section ?? pour contextualiser la vision ; ils ne relèvent pas du périmètre de cette contribution.

5.4.1 Databricks : plateforme et écosystème

Présentation

Databricks est une plateforme unifiée de traitement de données et d'intelligence artificielle (*Data + AI Platform*), fondée en 2013 par les créateurs originaux d'Apache Spark à l'Université de Californie Berkeley (AMPLab). Elle implémente le paradigme **Lakehouse**, une architecture qui réconcilie les avantages des *data warehouses* (performances analytiques, gouvernance stricte) et des *data lakes* (flexibilité de format, coût de stockage faible, traitement massif).

La plateforme repose sur plusieurs composants clés :

- **Delta Lake** : couche de stockage open-source au-dessus de fichiers Parquet, apportant les transactions ACID, le *Time Travel* (historique des versions), et la gestion des schémas.
- **Unity Catalog** : système de gouvernance unifié à trois niveaux (`catalog.schema.table`), gérant les accès, la traçabilité et la qualité des données à l'échelle de l'organisation.
- **Databricks Runtime (DBR)** : distribution optimisée d'Apache Spark incluant des bibliothèques pré-installées, des optimisations de connectivité cloud et le moteur **Photon** (implémentation C++ vectorisée pour des performances jusqu'à 4× supérieures).
- **Databricks Asset Bundles (DAB)** : format de déploiement déclaratif (`databricks.yml`) pour la gestion des jobs, pipelines et artefacts en tant que code (*Infrastructure as Code*).

Architecture Databricks

La Figure ci-après (à préparer par l'auteur) illustre l'architecture Lakehouse de Databricks : une couche de stockage objet (Azure ADLS Gen2, AWS S3, GCS) sur laquelle reposent Delta Lake et Unity Catalog, au-dessus desquels s'exécutent les clusters Spark via Databricks Runtime, exposés aux utilisateurs et aux pipelines via le portail web, les API REST, ou des outils tiers (dbt, Fivetran, Airbyte).

Adoption et statistiques

Databricks s’est imposé comme la plateforme Lakehouse dominante du marché. Les indicateurs d’adoption 2024 confirment sa pertinence pour les projets de migration de données à grande échelle :

TABLE 5.9 – Indicateurs d’adoption de Databricks (2024)

Indicateur	Valeur
Clients dans le monde	Plus de 12 000 organisations
Fortune 500	Utilisé par plus de 60 % des entreprises du Fortune 500
Volume traité	Plus d’1 exaoctet de données par mois
Requêtes Spark/jour	Plus de 900 millions de jobs Spark exécutés quotidiennement
Valorisation	62 milliards USD (levée de fonds série J, 2024)
Contribution open-source	Créateurs d’Apache Spark, Delta Lake et MLflow

Comparatif : ADMP Legacy (IDMF) vs moteur Databricks

L’ADMP Classique reposait sur l’IDMF (*Interactive Data Migration Framework*) : un ensemble d’outils basés sur VBA, SharePoint, Excel et Word, avec exécution sur SQL Server ou Oracle en mode transactionnel. Cette approche héritée présente des limitations structurelles que le nouveau moteur Databricks adresse directement.

TABLE 5.10 – Comparatif : ADMP Legacy (IDMF) vs nouveau moteur Databricks

Critère	ADMP Legacy (IDMF)	Moteur Databricks (ADMP AI Studio)
Base technologique	VBA, SharePoint, Excel/Word	TypeScript (Node.js) + Python/PySpark
Traitement des données	Séquentiel : lecture/écriture SQL rangée par rangée	Distribué : DataFrames Spark avec plans d'exécution Catalyst, exécution columnar Photon
Stockage résultats	Tables relationnelles (SQL Server, Oracle)	Delta Lake : ACID, Time Travel, Z-Ordering, compaction automatique
Scalabilité	Scale-up : nœud unique, contrainte matérielle	Scale-out : clusters élastiques 1 à 100+ nœuds, Serverless disponible
Gouvernance	Manuelle (fichiers SharePoint, permissions SQL)	Unity Catalog natif : lineage, audit, contrôle d'accès granulaire
Génération de code	Semi-automatique : intervention manuelle sur les Smart Designs	100 % automatisée depuis les documents ADMP (RC, DP, TT...)
Format de sortie	Smart Designs propriétaires (exécutables IDMF)	3 formats : Notebooks, Python Wheel (.whl), Asset Bundle (DAB)
Déploiement	Manuel (FTP, script SQL, intervention DBA)	Automatisé : Generate & Deploy via API Databricks
Traçabilité données	Logs SQL Server, fichiers journaux	Delta Lake Time Travel : historique complet de chaque table migrée

TABLE 5.11 – Comparaison des plateformes d'exécution pour la migration de données

Critère	ADMP Legacy (Core Engine)	Azure Data Factory	Databricks (retenu)
Scalabilité	Nœud unique ; scale-up limité	Scale-out managé, coût élevé	Scale-out élastique (1–100+ nœuds)
Volumétrie	Téra-octets max	Multi-téra, latence élevée	Péta-octets, Photon Engine optimisé
Modèle de données	Tables SQL Server / Oracle	Blob / ADF datasets	Delta Lake ACID + Time Travel
Gouvernance	Manuelle	Azure Purview (externe)	Unity Catalog natif
Débogage	ADMP Design Tools	Monitoring ADF pipeline	Notebooks interactifs, Spark UI
Coût idle	Infrastructure fixe	Facturation à l'activité	Serverless compute (zéro si inactif)
Format de code	Smart Designs (propriétaire)	Pipelines JSON	Python / PySpark (lisible, testable)

5.4.2 Architecture technique

La Figure ?? illustre le positionnement du module de génération Databricks dans l'architecture d'ensemble d'ADMP AI Studio. Le module s'inscrit dans la couche *Compilation* et communique avec les autres couches via des interfaces bien définies.




FIGURE 5.17 – Positionnement du module de génération Databricks dans l'architecture ADMP AI Studio (5 couches)

Documents d'entrée

Le compilateur consomme onze types de documents de spécification ADMP, listés dans le Tableau ?? . Ces documents sont la **seule source de vérité** du compilateur : il ne dépend d'aucun état partagé avec les autres formats de sortie.

TABLE 5.12 – Documents de spécification consommés par le compilateur Databricks

Document	Format	Rôle dans la compilation
RC (Record Creation)	TXT	Instructions de création de données : IF/ELSE, callWrite-File, callDataPopulate
DP (Data Population)	JSON	Règles de peuplement : sources, jointures, filtres et assignations
DS (Data Structure)	JSON	Structure des tables sources et cibles ; types et contraintes de colonnes
TT (Transco Table)	XML	Tables de transcodification ; clés et valeurs de mapping
MS (Mapping Sheet)	JSON	Correspondances champ-à-champ entre entités source et cible
IC (Integrity Checks)	XML	Règles de contrôle d'intégrité référentielle (PK, FK, unicité)
PARAM	XML	Paramètres run-time injectés dans les expressions de calcul
SDS / IDS / TDS / SDEF	XML	Périmètre des données : définitions des entités sources, intermédiaires, cibles et structurées

Options de génération

Avant de lancer la compilation, le Migration Designer configure les paramètres de génération via le formulaire de la Figure ???. Ces paramètres sont transmis au compilateur TypeScript et influencent directement la structure et le contenu du package produit.

TABLE 5.13 – Paramètres du formulaire de génération Databricks

Champ	Type	Description	Défaut
dbkOutputFormat	enum	Format de sortie : <i>Notebooks</i> (scripts plats), <i>Wheel</i> (.whl), <i>Bundle</i> (wheel + DAB config)	notebooks
catalog	string	Catalog Unity Catalog cible — niveau 1 de la hiérarchie <code>catalog.schema.table</code>	main
databricksSchema	string	Schéma Unity Catalog cible — niveau 2 de la hiérarchie	default
workspaceHost	string	URL du workspace Databricks; optionnel, utilisé pour le déploiement automatisé	—
packageName	string	Nom du package Python (wheel/bundle uniquement); minuscules et underscores	admp_migration
packageVersion	string	Version du package au format <i>semver</i> (wheel/bundle)	1.0.0
computeMode	enum	Mode de calcul : <i>Serverless</i> , <i>Existing Cluster</i> , <i>New Cluster</i> (wheel/bundle)	serverless
includeSourceDDL	boolean	Génère le dossier <code>source_ddl/</code> avec les CREATE TABLE d'après le Data Scope	false
includeTestData	boolean	Génère le dossier <code>test_data/</code> avec des DataFrames d'exemple d'après le Data Scope	false

Formats de sortie

La compilation produit l'un des trois formats de package suivants, selon le paramètre `dbkOutputFormat`. Le Tableau ?? décrit les fichiers générés pour chaque format.

TABLE 5.14 – Fichiers générés selon le format de sortie

Fichier / Répertoire	Type	Contenu	Format
units/mig_*.py	Unités PySpark	Un fichier par unité : logique UNION ALL, jointures transco, insertions Delta	Tous
config/parameters.py	Configuration	Paramètres runtime : catalog, schéma, références métier	Tous
config/transco.py	Transco	Chargement et broadcast des tables de transcodification	Tous
run_all.py	Orchestrateur	Exécution séquentielle des unités; paramétrage runtime	Notebooks
<pkg>/runner.py	Orchestrateur	Même rôle que run_all.py, packagé comme module Python installable	Wheel / Bundle
framework/unit_base.py	Framework	Classe de base : logging, compteurs, gestion des erreurs	Tous
reports/generate_reports.py	Rapports	Génération des rapports Excel de contrôle d'intégrité	Tous
pyproject.toml	Packaging	Manifeste Python PEP 517 pour la construction du fichier .whl	Wheel / Bundle
Manifeste KACHMAR	DAB config	Manifeste Databricks Asset Bundle : jobs, clusters, artefacts, permissions	Bundle unique

5.4.3 Conception du pipeline

Le module de génération Databricks opère selon un **pipeline de compilation en quatre étapes**, implémentées par quatre émetteurs TypeScript spécialisés. Cette architecture garantit la séparation des responsabilités et la testabilité indépendante de chaque module.

Description fonctionnelle

Étape 1 — Parsing et validation. Le compilateur lit les documents d'entrée (RC, DP, DS, TT, MS, IC, PARAM, SDS/IDS/TDS/SDEF), les valide structurellement, et construit l'arbre syntaxique abstrait (AST) des instructions RC. Toute anomalie est signalée via une erreur de compilation détaillée avant toute génération de code.

Étape 2 — Extraction des chemins (extractPaths). La fonction `extractPaths` parcourt l'AST selon un algorithme DFS avec accumulation de contexte. À chaque nœud conditionnel (IF/ELSE), le contexte est dupliqué : la branche vraie accumule la condition, la branche fausse sa négation. Les nœuds feuilles (`callWriteFile`, `callDataPopulate`) cristallisent le contexte accumulé en un objet `SqlPath` autonome, contenant tables, conditions, assignations et tables cibles. Chaque `SqlPath` est auto-suffisant : il ne dépend d'aucun état externe.

Étape 3 — Génération des blocs SELECT (generateSelectBlock). Pour chaque `SqlPath`, la génération suit une séquence en six sous-étapes :

1. **Résolution des variables de design** : les variables Python `v_x_*` sont résolues via la table `expandedVars` construite à partir des assignations précédentes.
2. **Injection des jointures transco** : les vues broadcast `_tv_TT_*` sont injectées en `LEFT JOIN`, avec filtrage des clés contenant des références Python non résolues.
3. **Guérison des clés de jointure** : une passe de reconstruction ré-évalue les clés de jointure précédemment filtrées, traitant le cas des jointures multi-clés partiellement résolues.
4. **Tri topologique des tables** : les tables de la branche sont réordonnées de façon à ce que chaque `JOIN ON` ne référence que des tables apparaissant antérieurement dans le `FROM`.
5. **Génération des colonnes** : les assignations sont converties en expressions Spark SQL avec castings défensifs (`TRY_CAST`, `NULLIF`).
6. **Sérialisation** : le bloc `SELECT ...FROM ...JOIN ...WHERE ...` est sérialisé en texte Python dans le fichier d'unité.

Les `SqlPath` partageant la même table cible sont agrégés par un `UNION ALL`.

Étape 4 — Assemblage du bundle. L'émetteur de framework génère les fichiers de support (`unit_base.py`, `runner.py`, `validate.py`), l'émetteur d'intégrité produit `generate_reports.py`, et l'émetteur DDL construit `create_tables.py`. L'ensemble est assemblé en package `.whl` par l'orchestrateur de compilation.

Diagramme du pipeline de compilation






FIGURE 5.18 – Pipeline de compilation : des spécifications ADMP au bundle Databricks

Diagramme d'activité : génération d'un bundle**FIGURE 5.19** – Diagramme d'activité : génération d'un bundle Databricks**5.4.4 Modélisation UML spécifique Databricks****Cas d'utilisation spécifiques au module Databricks**

Le diagramme de la Figure ?? modélise les cas d'utilisation du module de génération Databricks. Le **Migration Designer** orchestre l'ensemble du cycle : configuration du formulaire de génération (format, catalog, options), compilation, et déploiement. Le **Test Engineer** valide le bundle en environnement de test.

**FIGURE 5.20** – Diagramme UC : Module de génération Databricks

Les fiches suivantes décrivent les cas d'utilisation dont la complexité fonctionnelle est la plus représentative du module.

Configurer le formulaire de génération

Acteur(s)	Migration Designer
Préconditions	Unités de migration conçues et validées ; Data Scope disponible (pour les options DDL/test data)
Déclencheur	Le Migration Designer accède à <i>Package Generation</i> et ouvre le formulaire de configuration Databricks
Scénario nominal	1. Il sélectionne le format de sortie parmi les trois options disponibles : Notebooks : scripts Python plats directement importables dans un workspace Databricks. Python Wheel (.whl) : package Python installable, adapté aux environnements CI/CD. Asset Bundle : wheel + fichier databricks.yml (DAB config), pour un déploiement piloté par code. 2. Il renseigne le catalog Unity Catalog cible (ex. main) et le schéma (ex. default). 3. Il saisit optionnellement le <i>Workspace Host</i> (URL du workspace Databricks) pour le déploiement automatisé. 4. Pour les formats wheel/bundle, il configure le nom et la version du package, et choisit le mode de calcul (Serverless, Existing Cluster, New Cluster). 5. Il active ou désactive les options : <i>Include Source DDL</i> (CREATE TABLE depuis le Data Scope) et <i>Include test data</i> (DataFrames d'exemple). 6. Il valide la configuration ; le formulaire est prêt pour le lancement de la compilation.
Alt. / Erreurs	Nom de package invalide (espaces, majuscules) : validation inline avant soumission. Workspace Host mal formaté : message d'erreur avec exemple attendu.
Postconditions	Configuration sauvegardée ; paramètres transmis au compilateur TypeScript pour génération

Compiler une unité de migration

Acteur(s)	Migration Designer
Préconditions	Formulaire de génération configuré ; documents ADMP disponibles (RC, DP, TT, DS, MS...)
Déclencheur	Le Migration Designer clique sur <i>Generate</i> dans le formulaire de génération
Scénario nominal	1. La plateforme soumet une requête au service de compilation : <code>GET /api/codegen/download-databricks-package/:projectId</code> avec les paramètres de configuration. 2. Le compilateur TypeScript charge les documents ADMP (RC, DP, TT, DS, MS, IC, PARAM, SDS/IDS/TDS/SDEF). 3. Il parse les instructions RC et construit l'AST ; toute erreur de syntaxe interrompt la compilation avec un message localisé. 4. Il extrait les <code>SqlPath</code> via DFS, génère les blocs SELECT Spark SQL et les agrège par table cible (UNION ALL). 5. Il assemble le package selon le format choisi (Notebooks / Wheel / Bundle) et produit le fichier téléchargeable. 6. La progression est visible en temps réel ; le package est disponible au téléchargement en cas de succès.
Alt. / Erreurs	Erreur de parsing RC : log détaillé avec numéro de ligne et instruction fautive. Timeout > 60 s : notification et retry automatique. Document ADMP manquant : liste des fichiers absents affichée avant tout traitement.
Postconditions	Package compilé et archivé dans l'historique ; disponible pour téléchargement et déploiement

Déployer le bundle sur Databricks

Acteur(s)	Migration Designer
Préconditions	Bundle compilé disponible ; Workspace Host configuré ; token d'API Databricks valide
Déclencheur	Le Migration Designer clique sur <i>Deploy</i> après une compilation réussie
Scénario nominal	1. La plateforme téléverse le fichier <code>.whl</code> sur le workspace via l'API Databricks (<code>dbfs :/FileStore/...</code>). 2. Elle installe la bibliothèque sur le cluster cible ; le cluster redémarre si nécessaire. 3. Pour le format Asset Bundle, elle exécute <code>databricks bundle deploy</code> : création des ressources déclarées dans <code>databricks.yml</code> (jobs, clusters, permissions). 4. Le statut de déploiement est affiché : succès, avertissements ou erreurs. 5. Le bundle déployé est prêt pour l'exécution (<i>Run Bundle</i>).
Alt. / Erreurs	Token expiré ou invalide : message d'erreur et invitation à régénérer le token. Cluster indisponible : suggestion de basculer en mode Serverless. Conflit de version de package : option de forcer la mise à jour.
Postconditions	Bundle installé sur le workspace Databricks ; jobs/ressources créés (format Bundle) ; prêt pour exécution

SD-DB01 — Détail interne de la compilation

Ce diagramme (Figure ??) décrit les interactions internes entre les composants TypeScript du compilateur lors du traitement d'une instruction RC.




FIGURE 5.21 – SD-DB01 : Détail interne de la compilation TypeScript

SD-DB02 — Déploiement et exécution du bundle




FIGURE 5.22 – SD-DB02 : Déploiement et exécution du bundle sur Databricks

Diagramme de classes du compilateur Databricks

La Figure ?? modélise l'architecture orientée objet du compilateur TypeScript. La hiérarchie des nœuds AST implémente le pattern **Visitor** ; les émetteurs héritent d'une interface commune `IEmitter` permettant le pattern **Strategy**. La propriété `dbkOutputFormat` est propagée jusqu'au `BundleAssembler`, qui sélectionne la stratégie d'assemblage selon le format choisi.




FIGURE 5.23 – Diagramme de classes du compilateur Databricks (TypeScript)

5.4.5 Décisions architecturales et patterns

Patterns de conception

La conception du compilateur s'appuie sur des patterns éprouvés de l'ingénierie logicielle, décrits dans le Tableau ??.

TABLE 5.15 – Patterns de conception appliqués dans le compilateur Databricks

Pattern	Famille	Application dans le compilateur
Visitor	Comportemental	Parcours de l'AST des instructions RC ; chaque type de nœud (IF, callWriteFile, assignation) est délégué à un handler dédié
Builder	Créationnel	Construction incrémentale des objets <code>SqlPath</code> ; le builder accumule tables, conditions et assignations au fil du parcours DFS
Strategy	Comportemental	Sélection du backend d'émission (SQL Server vs. Databricks) via injection d'une interface <code>IEmitter</code> dans le moteur de compilation
Template Method	Comportemental	<code>generateSelectBlock</code> définit le squelette algorithmique ; les étapes spécifiques (casting, transco, conditions) sont des méthodes spécialisées
Factory	Créationnel	<code>dbkIntegrityEmitter</code> instancie le bon type de vérification (PK, FK, unicité) selon le type de la table cible
Pipeline	Architectural	Les quatre émetteurs s'enchaînent de manière linéaire ; la sortie de chacun est l'entrée du suivant, facilitant les tests unitaires par étape

Décisions architecturales clés

Moteur indépendant. Le compilateur Databricks est un moteur entièrement nouveau, développé spécifiquement pour ADMP AI Studio. Il n'hérite d'aucun composant du Core Engine IDMF : il parse directement les documents ADMP comme source de vérité, garantissant l'indépendance technologique et la liberté d'évolution.

Branches auto-suffisantes. Chaque objet `SqlPath` encapsule l'intégralité du contexte nécessaire à sa génération. Cette propriété d'auto-suffisance rend la compilation parallélisable et simplifie les tests unitaires : chaque branche peut être générée et validée indépendamment.

Rejet de `makePathsExclusive`. Une tentative d'automatiser l'exclusivité des branches UNION ALL (en ajoutant des conditions NOT) s'est révélée trop générique : après trois itérations, des régressions apparaissaient sur d'autres tables, révélant que la distinction sémantique entre branches ne peut être inférée mécaniquement. La correction ciblée dans la spécification de migration est la

seule approche robuste. Cela illustre un principe fondamental : **la complexité métier ne doit pas être résolue dans le compilateur, mais dans les documents de design.**

Conclusion

Ce chapitre a établi la double dimension de la solution conçue : d’une part, la plateforme **ADMP AI Studio** dans son ensemble, dont la vision de modernisation, les exigences fonctionnelles et la modélisation UML ont été présentées de façon exhaustive ; d’autre part, la **contribution spécifique de ce PFE** : le module de génération Databricks, moteur de compilation TypeScript entièrement nouveau.

La mise en perspective de l’ADMP Legacy (IDMF/VBA/SharePoint) face au nouveau moteur Databricks illustre la rupture technologique opérée : traitement séquentiel sur-premise versus exécution distribuée sur clusters Spark ; gestion manuelle de fichiers versus Unity Catalog et Delta Lake. Les trois formats de sortie (Notebooks, Wheel, Asset Bundle) couvrent un spectre allant du script exploratoire au déploiement industriel piloté par *Infrastructure as Code*.

L’architecture du compilateur — fondée sur les patterns Visitor, Builder, Strategy et Pipeline — garantit la séparation des responsabilités, la testabilité indépendante de chaque émetteur et l’extensibilité vers de futurs formats. Le rejet délibéré du partage d’état entre branches (*SqlPath* auto-suffisants) et la décision d’implémenter un moteur indépendant du Core Engine constituent les décisions architecturales les plus structurantes de cette contribution.

Le chapitre suivant décrit la réalisation concrète de cette conception : les défis d’implémentation rencontrés, les solutions apportées, et les résultats obtenus en environnement de production Databricks.

Chapitre 6

Implementation

6.1 Implementation

Documents the development process in detail — tools, languages, frameworks, version control strategy, and key modules built. Students should describe the most technically significant parts of their work and explain how they overcame difficulties. Code snippets can be included but should be kept concise.

6.1.1 Development Environment

6.1.2 Key Modules and Components

6.1.3 Difficulties and Solutions

6.2 Results and Evaluation

Presents what was produced and how well it works. Students should include :

1. Test cases and their outcomes
2. Performance metrics, benchmarks, or user feedback
3. Screenshots or figures illustrating the final product
4. A honest discussion comparing results against the initial objectives

6.2.1 Testing and Validation

6.2.2 Discussion

6.3 Conclusions and Future Work

The closing chapter with two subsections :

1. Conclusions — what was accomplished, whether objectives were met, and personal reflections on the internship experience
2. Future Work — what could not be done due to time or scope constraints, and concrete suggestions for whoever continues the project

6.3.1 Conclusions

6.3.2 Future Work

.1 Annexe A — Fiches des cas d'utilisation

Cette annexe complète la section ?? du chapitre 5 en fournissant les fiches descriptives des 24 cas d'utilisation non développés dans le corps du document.

Phase 1 — Project Management

UC-01 — Créer un projet de migration

Acteur(s)	Administrator
Préconditions	Utilisateur authentifié avec le rôle Administrator
Déclencheur	L'administrateur souhaite initier un nouveau projet de migration de données
Scénario nominal	1. L'administrateur accède au tableau de bord global. 2. Il clique sur "Nouveau projet". 3. Il renseigne les informations : nom, Industry, Target platform, Source system. 4. Il valide la création. 5. La plateforme initialise les huit phases et génère l'identifiant projet.
Alt. / Erreurs	Nom de projet déjà existant : message d'erreur et suggestion d'un nom disponible. Champs obligatoires manquants : validation inline.
Postconditions	Projet créé avec les huit phases initialisées ; l'administrateur est automatiquement ajouté comme membre owner

UC-02 — Configurer les paramètres du projet

Acteur(s)	Administrator
Préconditions	Projet créé (UC-01) ; au moins un membre de l'équipe défini (UC-03)
Déclencheur	L'administrateur souhaite modifier ou affiner les paramètres d'un projet existant
Scénario nominal	1. L'administrateur ouvre les paramètres du projet. 2. Il modifie les informations disponibles : description, dates cibles, options d'affichage. 3. Il sauvegarde les modifications. 4. Un historique des changements est enregistré.
Alt. / Erreurs	Champs protégés en mode lecture seule si le projet est verrouillé : notification à l'administrateur. Sauvegarde concurrente : résolution par timestamp.
Postconditions	Paramètres mis à jour ; historique des modifications disponible dans les logs projet

UC-04 — Suivre l'avancement du projet

Acteur(s)	Migration Designer, Cutover Manager
Préconditions	Projet actif avec au moins une phase démarrée
Déclencheur	L'utilisateur consulte le tableau de bord pour suivre l'avancement global du projet
Scénario nominal	1. L'utilisateur ouvre le tableau de bord du projet. 2. Il visualise le statut de chaque phase (Non démarré, En cours, Terminé, Bloqué). 3. Il consulte les métriques d'avancement : pourcentage de complétion, jalons atteints, alertes en cours. 4. Il peut naviguer directement vers une phase en cliquant dessus.
Alt. / Erreurs	Données non disponibles pour une phase non initialisée : indicateur grisé. Alertes critiques : bandeau rouge en haut du tableau de bord.
Postconditions	Vue d'avancement consultée ; aucune modification de l'état du projet

UC-05 — Archiver un projet finalisé

Acteur(s)	Administrator
Préconditions	Projet en statut “Completed” ; validation go-live effectuée (UC-29)
Déclencheur	L'administrateur archive le projet pour libérer les ressources actives et conserver le dossier
Scénario nominal	1. L'administrateur sélectionne le projet finalisé. 2. Il déclenche l'action “Archiver”. 3. La plateforme génère une archive complète : documents, bundles, rapports, logs. 4. Le projet passe en mode lecture seule ; les ressources computationnelles sont libérées.
Alt. / Erreurs	Projet avec des tâches cutover ouvertes : archivage refusé jusqu'à clôture complète. Erreur d'archivage : rollback et notification.
Postconditions	Projet archivé en lecture seule ; archive téléchargeable pendant 12 mois

Phase 2 — Data Scope**UC-06 — Définir le périmètre des données**

Acteur(s)	Data Analyst, Migration Designer
Préconditions	Projet initialisé (UC-01) ; phase Data Scope débloquée
Déclencheur	Le Data Analyst définit les entités sources, intermédiaires et cibles du périmètre de migration
Scénario nominal	1. Le Data Analyst accède à la phase Data Scope. 2. Il importe ou crée manuellement les définitions SDS (entités sources), TDS (entités cibles) et IDS (entités intermédiaires). 3. Pour chaque entité, il renseigne les attributs : nom, colonnes, types, clés. 4. Il sauvegarde ; une version du data scope est créée.
Alt. / Erreurs	Entité en doublon : avertissement et possibilité de fusion. Format invalide : message d'erreur détaillé avec localisation.
Postconditions	Data scope versionnée ; entités disponibles pour les phases suivantes ; verrouillage activable (UC-07)

UC-07 — Verrouiller une section du data scope

Acteur(s)	Data Analyst
Préconditions	Data scope défini (UC-06) ; section non verrouillée par un autre utilisateur
Déclencheur	Le Data Analyst verrouille une section du data scope pour l'éditer exclusivement
Scénario nominal	1. Le Data Analyst sélectionne une entité ou un groupe d'entités. 2. Il clique sur "Checkout". 3. La plateforme vérifie qu'aucun verrou concurrent n'existe. 4. Le verrou est posé ; les autres utilisateurs voient la section en lecture seule. 5. Après édition, le Data Analyst effectue le "Check-in" pour libérer le verrou.
Alt. / Erreurs	Section déjà verrouillée : affichage du nom du détenteur et heure de prise du verrou. Verrou expiré (> 4h) : relâchement automatique après confirmation.
Postconditions	Verrou libéré ; nouvelle version du data scope enregistrée ; section disponible pour d'autres éditeurs

UC-08 — Exporter le data scope

Acteur(s)	Data Analyst
Préconditions	Data scope finalisé et validé (UC-06)
Déclencheur	Le Data Analyst exporte le périmètre vers le format natif ADMP pour utilisation dans les outils de conception
Scénario nominal	1. Le Data Analyst accède à la phase Data Scope. 2. Il sélectionne le format d'export : ADMP Native (Excel/Word) ou JSON structuré. 3. La plateforme génère les fichiers correspondants (SDS, TDS, IDS). 4. L'export est téléchargeable directement ou envoyé par email.
Alt. / Erreurs	Entités incomplètes : avertissement avec liste des champs manquants avant export. Timeout d'export : retry automatique.
Postconditions	Fichiers SDS/TDS/IDS disponibles en téléchargement ; date d'export enregistrée dans les métadonnées

Phase 3 — Extract**UC-09 — Configurer une source d'extraction**

Acteur(s)	Data Analyst
Préconditions	Phase Extract initialisée ; data scope défini (UC-06)
Déclencheur	Le Data Analyst configure les paramètres de connexion à une source de données à extraire
Scénario nominal	1. Le Data Analyst accède à la phase Extract. 2. Il ajoute une nouvelle source : type (Oracle, SQL Server, CSV, VSAM), paramètres de connexion (hôte, port, base). 3. Il teste la connexion. 4. Il associe la source aux entités correspondantes du data scope. 5. Il sauvegarde la configuration.
Alt. / Erreurs	Test de connexion échoué : message d'erreur technique et suggestions de diagnostic. Entité non trouvée dans la source : avertissement et option d'alignement manuel.
Postconditions	Source configurée et associée aux entités ; prête pour l'import de fichiers (UC-10)

Phase 4 — Profiling & Cleansing**UC-12 — Générer un rapport de profilage**

Acteur(s)	Data Analyst
Préconditions	Audit de données lancé (UC-11) ; résultats disponibles
Déclencheur	Le Data Analyst génère un rapport formel de profilage statistique par entité
Scénario nominal	1. Le Data Analyst accède aux résultats d'audit (UC-11). 2. Il sélectionne les entités à inclure dans le rapport. 3. Il choisit le format : PDF, Excel, HTML interactif. 4. La plateforme génère le rapport avec : distributions, taux de nullité, cardinalités, exemples d'anomalies. 5. Le rapport est archivé dans le dossier projet.
Alt. / Erreurs	Données insuffisantes pour une entité : section correspondante marquée "Données insuffisantes". Génération longue : notification par email.
Postconditions	Rapport archivé ; disponible pour partage avec le Business Reviewer ; base pour les règles de nettoyage (UC-13)

UC-13 — Documenter les règles de nettoyage

Acteur(s)	Data Analyst
Préconditions	Rapport de profilage disponible (UC-12) ; anomalies identifiées
Déclencheur	Le Data Analyst documente les règles de nettoyage à appliquer aux données identifiées comme non conformes
Scénario nominal	1. Le Data Analyst consulte les anomalies du rapport de profilage. 2. Pour chaque anomalie, il crée une règle de nettoyage : type (substitution, suppression, normalisation), expression, entités concernées. 3. Il documente la justification métier. 4. Il sauvegarde les règles ; elles sont versionnées et traçables.
Alt. / Erreurs	Règle en conflit avec une règle existante : avertissement et possibilité de remplacement ou fusion. Expression invalide : validation en temps réel.
Postconditions	Règles de nettoyage documentées ; prêtes pour soumission (UC-15) et validation métier (UC-16)

UC-14 — Valider la conformité qualité des données

Acteur(s)	Business Reviewer
Préconditions	Règles de nettoyage appliquées ; rapport de profilage post-nettoyage disponible
Déclencheur	Le Business Reviewer évalue la conformité des données nettoyées par rapport aux exigences métier
Scénario nominal	1. Le Business Reviewer reçoit une notification de disponibilité. 2. Il consulte le rapport de profilage post-nettoyage. 3. Il vérifie la conformité entité par entité. 4. Pour chaque entité, il renseigne son avis (Conforme, Non conforme + commentaire). 5. Il soumet sa validation.
Alt. / Erreurs	Entité non conforme : commentaire obligatoire ; renvoi au Data Analyst pour correction. Délai dépassé (> 48h sans réponse) : escalade automatique vers le Migration Designer.
Postconditions	Validation métier enregistrée ; phase Profiling débloquée pour passage à Transform si toutes entités conformes

UC-15 — Soumettre les règles pour validation

Acteur(s)	Data Analyst
Préconditions	Règles de nettoyage documentées (UC-13) ; phase Profiling en cours
Déclencheur	Le Data Analyst soumet les règles de nettoyage au Business Reviewer pour approbation
Scénario nominal	1. Le Data Analyst finalise les règles de nettoyage dans l'éditeur. 2. Il clique sur "Soumettre pour validation". 3. La plateforme notifie le ou les Business Reviewers assignés. 4. Les règles passent en statut "En attente de validation".
Alt. / Erreurs	Aucun Business Reviewer assigné : blocage avec message demandant l'assignation via UC-03. Règles incomplètes : validation inline avant soumission.
Postconditions	Règles soumises ; Business Reviewer notifié ; Data Analyst informé de la prise en charge

UC-16 — Approuver les règles de nettoyage

Acteur(s)	Business Reviewer
Préconditions	Règles soumises (UC-15) ; Business Reviewer notifié
Déclencheur	Le Business Reviewer approuve ou rejette les règles de nettoyage soumises par le Data Analyst
Scénario nominal	1. Le Business Reviewer ouvre la liste des règles en attente. 2. Il examine chaque règle : description, entités concernées, justification métier. 3. Il approuve (vert) ou rejette (rouge + commentaire) chaque règle. 4. Il soumet sa décision. 5. Le Data Analyst est notifié.
Alt. / Erreurs	Règle ambiguë : possibilité de demander une clarification au Data Analyst via commentaire. Approbation partielle : les règles approuvées sont validées ; les rejetées retournent en édition.
Postconditions	Règles approuvées enregistrées ; règles rejetées renvoyées au Data Analyst ; journal d'approbation tracé

Phase 5 — Transform

UC-19 — Configurer les tables de transcodification

Acteur(s)	Migration Designer
Préconditions	Data scope finalisé ; phase Transform débloquée
Déclencheur	Le Migration Designer configure les tables de transcodification (TT) pour une unité de migration
Scénario nominal	1. Le Migration Designer accède à la gestion des transco. 2. Il importe un fichier TT (XML) ou crée les entrées manuellement. 3. Il définit les clés et valeurs de mapping. 4. Il associe la TT aux unités de migration qui l'utilisent. 5. Il valide et sauvegarde.
Alt. / Erreurs	Clé dupliquée dans la TT : avertissement et proposition de merge. Format XML invalide : erreur de validation avant import.
Postconditions	Tables de transco disponibles pour les règles RC/DP ; vues broadcast générées automatiquement lors de la compilation

UC-20 — Valider le bundle généré

Acteur(s)	Test Engineer
Préconditions	Bundle généré et disponible (UC-18)
Déclencheur	Le Test Engineer exécute des tests de validation sur le bundle généré avant déploiement en production
Scénario nominal	1. Le Test Engineer accède au bundle dans la phase Transform. 2. Il lance l'exécution sur un cluster de test Databricks. 3. Il vérifie les compteurs (lignes lues, écrites, rejetées). 4. Il consulte les rapports d'intégrité Excel générés. 5. Il documente le résultat : approuvé ou rejeté avec détail des anomalies.
Alt. / Erreurs	Erreur d'exécution sur le cluster : log Spark UI disponible pour diagnostic. Compteurs inattendus : comparaison avec la baseline de référence.
Postconditions	Résultat de validation enregistré ; si approuvé, bundle prêt pour déploiement (UC-21)

UC-21 — Publier le bundle sur Databricks

Acteur(s)	Migration Designer
Préconditions	Bundle validé (UC-20) ; cluster Databricks de production accessible
Déclencheur	Le Migration Designer déploie le bundle validé sur le cluster Databricks de production
Scénario nominal	1. Le Migration Designer sélectionne le bundle validé. 2. Il choisit le cluster cible et les paramètres de déploiement. 3. La plateforme appelle l'API Databricks : upload du .whl, installation de la librairie. 4. Un test de smoke est exécuté automatiquement (import du module). 5. La plateforme confirme le déploiement réussi.
Alt. / Erreurs	Cluster indisponible : notification et retry programmé. Test de smoke échoué : rollback de l'installation et notification.
Postconditions	Bundle installé sur le cluster ; disponible pour l'exécution du chargement (UC-23)

Phase 6 — Load**UC-22 — Configurer le chargement cible**

Acteur(s)	Migration Designer
Préconditions	Bundle déployé (UC-21) ; système cible accessible (Delta Lake / Unity Catalog)
Déclencheur	Le Migration Designer configure les paramètres d'exécution du chargement vers le système cible
Scénario nominal	1. Le Migration Designer accède à la phase Load. 2. Il sélectionne le bundle déployé. 3. Il renseigne les paramètres run-time : catalog, schéma, paramètres métier, mode d'exécution (full/delta). 4. Il configure l'ordre d'exécution des unités. 5. Il sauvegarde la configuration de run.
Alt. / Erreurs	Catalog ou schéma introuvable : vérification via Unity Catalog API ; message d'erreur détaillé. Paramètre manquant : validation inline.
Postconditions	Configuration de chargement sauvegardée ; prête pour exécution (UC-23)

Phase 7 — Validation

UC-24 — Définir les cas de test

Acteur(s)	Test Engineer
Préconditions	Chargement exécuté (UC-23) ; données présentes dans le système cible
Déclencheur	Le Test Engineer définit les cas de test et les critères d'acceptation pour la réconciliation
Scénario nominal	1. Le Test Engineer accède à la phase Validation. 2. Il crée les cas de test : entités à vérifier, type de contrôle (count, spot-check, intégrité), valeurs attendues. 3. Il associe chaque cas à une entité du data scope. 4. Il sauvegarde et documente la justification des critères.
Alt. / Erreurs	Entité non chargée : avertissement ; cas de test créé en statut "En attente de données". Critère sans valeur attendue : validation requise avant exécution.
Postconditions	Cas de test définis ; prêts pour exécution de la réconciliation (UC-25)

UC-25 — Exécuter les contrôles de réconciliation

Acteur(s)	Test Engineer
Préconditions	Cas de test définis (UC-24) ; données sources et cibles disponibles
Déclencheur	Le Test Engineer exécute les contrôles de réconciliation pour comparer les données source et cible
Scénario nominal	1. Le Test Engineer sélectionne les cas de test à exécuter. 2. Il lance la réconciliation. 3. La plateforme interroge les systèmes source et cible : comptages, spot-checks, vérifications d'intégrité. 4. Les résultats sont comparés aux valeurs attendues. 5. Les écarts sont classifiés (bloquant / majeur / mineur).
Alt. / Erreurs	Connexion source perdue : résultats partiels marqués ; retry programmé. Timeout de contrôle : reprise incrémentale possible.
Postconditions	Résultats disponibles ; écarts classifiés ; rapport de réconciliation générable (UC-26)

Phase 8 — Cutover

UC-27 — Créer le plan de cutover

Acteur(s)	Cutover Manager
Préconditions	Rapport de réconciliation approuvé ; phase Cutover débloquée
Déclencheur	Le Cutover Manager crée un plan de cutover structuré pour orchestrer la bascule en production
Scénario nominal	1. Le Cutover Manager accède à la phase Cutover. 2. Il crée un plan : nom, description, date cible de go-live. 3. Il ajoute les tâches : titre, responsable, durée estimée, ordre, dépendances. 4. Il définit les jalons et critères go/no-go. 5. Il soumet le plan pour revue par l'équipe.
Alt. / Erreurs	Dépendance circulaire entre tâches : détection et avertissement ; résolution requise. Date cible incompatible avec les dépendances : recalcul de la date proposé.
Postconditions	Plan de cutover créé et versionné ; partagé avec l'équipe ; tâches assignées aux responsables

UC-28 — Exécuter les tâches de cutover

Acteur(s)	Cutover Manager
Préconditions	Plan de cutover approuvé (UC-27) ; équipe notifiée ; fenêtre de cutover ouverte
Déclencheur	Le Cutover Manager pilote l'exécution des tâches du plan de cutover en temps réel
Scénario nominal	1. Le Cutover Manager ouvre la vue d'exécution du plan. 2. Il démarre les tâches selon leur séquence et dépendances. 3. Chaque responsable marque ses tâches comme terminées au fil de l'exécution. 4. Le Cutover Manager suit l'avancement global sur le tableau de bord. 5. Les incidents sont documentés en temps réel.
Alt. / Erreurs	Tâche bloquée ou en retard : alerte immédiate avec escalade optionnelle. Incident critique : activation du plan de rollback.
Postconditions	Toutes les tâches complétées ; journal d'exécution horodaté ; bascule technique effectuée ; prêt pour go-live (UC-29)

Modules transverses

UC-30 — Gérer la base de connaissances

Acteur(s)	Administrator
Préconditions	Accès Administrator à la plateforme
Déclencheur	L'administrateur met à jour la base de connaissances utilisée par les agents IA et les équipes
Scénario nominal	1. L'administrateur accède au module Apprentissage. 2. Il crée, modifie ou supprime des articles : titre, contenu (Markdown), tags, catégorie. 3. Il indexe le contenu pour la recherche vectorielle (RAG). 4. Il publie ou archive les articles. 5. Les agents IA disposent de la nouvelle connaissance lors de la prochaine requête.
Alt. / Erreurs	Conflit de version : édition concurrente détectée ; fusion manuelle requise. Indexation échouée : notification ; retry automatique toutes les 5 minutes.
Postconditions	Articles publiés ; base de connaissances mise à jour ; agents IA bénéficiant de la nouvelle connaissance

UC-31 — Consulter les journaux système

Acteur(s)	Administrator
Préconditions	Accès Administrator ; journaux disponibles
Déclencheur	L'administrateur consulte les journaux système pour diagnostiquer des incidents ou auditer des actions
Scénario nominal	1. L'administrateur accède au module Journaux. 2. Il filtre par : projet, utilisateur, type d'opération, plage de dates, niveau de log (INFO, WARNING, ERROR). 3. Il consulte les entrées : horodatage, acteur, action, payload, résultat. 4. Il peut exporter les logs filtrés en CSV.
Alt. / Erreurs	Volume de logs élevé : pagination et chargement progressif. Export > 10 000 lignes : génération asynchrone avec notification email.
Postconditions	Journaux consultés ; export disponible ; aucune modification de l'état du système

UC-32 — Configurer les agents IA

Acteur(s)	Administrator
Préconditions	Accès Administrator ; clé API Claude disponible
Déclencheur	L'administrateur configure les paramètres des agents IA (modèle, contexte, permissions)
Scénario nominal	1. L'administrateur accède au module Agents IA. 2. Il configure les paramètres globaux : modèle Claude (Opus/Sonnet), température, longueur max de contexte. 3. Il définit les permissions par rôle : quels agents sont accessibles à quels acteurs. 4. Il active ou désactive les agents par projet. 5. Il sauvegarde ; les changements prennent effet immédiatement.
Alt. / Erreurs	Clé API invalide : message d'erreur ; test de connectivité disponible. Modèle non disponible : fallback vers le modèle par défaut avec notification.
Postconditions	Configuration des agents sauvegardée ; agents disponibles pour les acteurs autorisés dans leurs projets

2 Annexe B — Structure complète du bundle Databricks

Cette annexe détaille la structure complète d'un bundle Databricks généré par ADMP AI Studio, à titre d'exemple pour un projet de migration standard composé de trois unités de migration (CUS01, ACC00, APD).

Arborescence du bundle

```
poc_project_YYYYMMDD_bundle/  
poc_project_YYYYMMDD/  
runner.py  
validate.py  
MANIFEST.json  
units/  
mig_cus01.py  
mig_acc00.py  
mig_apd.py  
framework/  
unit_base.py  
config/  
parameters.py  
transco.py  
source_ddl/  
create_tables.py  
generate.py  
reports/  
generate_reports.py  
integrity_checks.json  
poc_project_YYYYMMDD.whl
```

Rôle de chaque composant

TABLE 1 – Description des composants du bundle Databricks

Fichier	Type	Rôle
runner.py	Orchestrateur	Point d'entrée principal ; exécute les unités dans l'ordre configuré ; passe les paramètres run-time (catalog, schéma, run_id)
validate.py	Validation pré-run	Vérifie l'existence des tables cibles dans Unity Catalog ; contrôle la cohérence des paramètres avant toute écriture
MANIFEST.json	Méta-données	Contient la version du bundle, les unités incluses, la date de génération et la version du compilateur
units/mig_*.py	Unités PySpark	Chaque fichier contient la logique de migration d'une entité : DataFrame Spark, UNION ALL des branches, LEFT JOIN transco, INSERT INTO Delta
framework/unit_base.py	Classe de base	Fournit les mécanismes de logging (compteurs lignes lues/écrites/rejetées), gestion des erreurs et accès aux paramètres
config/parameters.py	Paramètres	Dictionnaire typé des paramètres métier et des références catalog/schéma, modifiable avant chaque run
config/transco.py	Transcodification	Charge les tables de transco depuis les fichiers de référence et les diffuse en broadcast Spark pour optimiser les jointures
source_ddl/create_tables.py	DDL source	Recrée les tables sources en mémoire (tables Delta temporaires) pour permettre une exécution offline sans connexion aux systèmes sources
Mohamed KACHMAR		139 / ??
source_ddl/generate.py	Données de test	Génère des données de test synthétiques pour les tables sources ; utilisé dans les environnements de validation (UC-20)

.3 Annexe C — Modèle de données PostgreSQL

Cette annexe présente les principales tables de la base de données PostgreSQL d'ADMP AI Studio, telles que définies dans les migrations Flyway du dépôt. Les colonnes de verrouillage de section (checkout) sont détaillées car elles constituent un mécanisme architectural clé.

TABLE 2 – Table migration_units — colonnes de verrouillage de section

Colonne	Type	Description
id	UUID	Identifiant unique de l'unité de migration
project_id	UUID	Référence au projet parent (FK)
name	VARCHAR	Nom de l'unité (ex. CUS01, ACC00)
data_structure_locked_by	UUID	ID utilisateur détenant le verrou sur la section Data Structure ; NULL si section libre
record_creation_locked_by	UUID	ID utilisateur détenant le verrou sur la section RC
data_population_locked_by	UUID	ID utilisateur détenant le verrou sur la section DP
checkout_baseline	INTEGER	Numéro de version de référence au moment du checkout ; utilisé pour détecter les conflits
created_at	TIMESTAMPTZ	Date de création de l'unité
updated_at	TIMESTAMPTZ	Date de dernière modification

Le mécanisme de verrouillage garantit l'exclusivité d'édition par section : chaque colonne *_locked_by peut être NULL (section libre) ou contenir l'UUID de l'utilisateur qui détient le verrou. La colonne checkout_baseline permet de détecter les modifications concurrentes : si la version courante de l'unité diffère de la baseline au moment du check-in, un conflit est signalé et une résolution manuelle est demandée.