

RAPPORT DE STAGE DE FIN D'ÉTUDES

Cycle Ingénieur — 5^{ème} Année

Spécialité Big Data & Intelligence Artificielle

ADMP AI Studio : Modernisation et automatisation des pipelines ETL de migration de données via une architecture d'IA agentique

Mohamed KACHMAR

127418

Sous la direction de :

Encadrant Académique

Ilias TOUGUI

Anouar RIAD SOLH

Université Internationale de Rabat

Tutrice en Entreprise

Amal Mesbah

AFD.tech Part of Accenture

Ce stage a été effectué au sein de :

AFD.tech Part of Accenture — Rabat, Maroc

2025 – 2026

Remerciements

Avant d'entamer la présentation de ce travail, je tiens à exprimer ma profonde gratitude à toutes les personnes qui, de près ou de loin, ont contribué à la réussite de ce stage de fin d'études et à la réalisation de ce rapport.

Je souhaite tout d'abord adresser mes sincères remerciements à mon maître de stage chez AFD.Tech, Mme Amal Mesbah, pour son accueil, sa disponibilité et la confiance qu'il m'a témoignée tout au long de cette mission de migration de données. Ses conseils techniques et sa vision stratégique ont été essentiels à ma progression.

Mes remerciements s'adressent également à l'ensemble de l'équipe ADMP pour leur intégration chaleureuse et leur soutien au quotidien. Évoluer au sein d'un environnement aussi stimulant que celui d'Accenture a été une opportunité d'apprentissage inestimable.

Je tiens à exprimer ma reconnaissance envers mon encadrant pédagogique à l'Université Internationale de Rabat UIR, professeur Tougui, pour son suivi attentif et le temps qu'il a consacré à l'orientation de mon projet.

Enfin, je ne saurais clore ces remerciements sans exprimer ma gratitude la plus profonde à ma famille. À mes parents, pour leur soutien inconditionnel et leurs encouragements constants durant toutes ces années d'études. À mon frère et à ma sœur, pour leur présence et leur complicité. Ce travail est aussi le fruit de leur amour et de leur confiance.

Que tous ceux qui ont contribué à faire de ce projet une expérience enrichissante trouvent ici l'expression de ma haute considération.

Abstract

Traditional data migration processes, particularly during the analysis and design phases, suffer from a heavy reliance on manual tasks and fragmented management tools (such as spreadsheets and decentralized office documents). This classic approach, prone to human error, results in extended delays and a lack of traceability that limits overall project efficiency.

The objective of this project is to design and develop the ADMP AI Studio, an intelligent platform aimed at modernizing system architecture and automating data migration ETL (Extract, Transform, Load) pipelines within the Accenture group. The goal is to drastically reduce manual intervention while standardizing the generation of transformation rules.

The adopted methodology relies on deploying an innovative Agentic Artificial Intelligence architecture. A multi-agent system, orchestrated via LangGraph and integrating advanced Large Language Models (LLMs) using "Chain of Thought" reasoning, was implemented. Technically, the architecture transitions toward centralized storage under PostgreSQL leveraging the JSON format. Various specialized agents (Scope, Design, Validation) work in synergy to ingest data models, autonomously perform Gap Analysis, and validate the consistency of operations.

The main results highlight the successful automation of critical design deliverables (Data Mapping, Table Mapping, SDS, TDS). The new infrastructure establishes a continuous, secure, and auditable data flow, thereby ensuring data quality before injection into target systems, and paving the way for the automation of complex transformation phases.

Keywords : Data migration, Agentic Artificial Intelligence, ETL pipeline, System architecture, Automation.

Résumé

Les processus traditionnels de migration de données, notamment lors de la phase d'analyse et de conception, souffrent d'une forte dépendance aux tâches manuelles et d'une fragmentation des outils de gestion (tableurs, documents bureautiques décentralisés). Cette approche classique, sujette aux erreurs humaines, entraîne des délais prolongés et un manque de traçabilité limitant l'efficacité globale des projets.

L'objectif de ce projet est de concevoir et développer l'ADMP AI Studio, une plateforme intelligente visant à moderniser l'architecture système et à automatiser les pipelines ETL (Extract, Transform, Load) de migration de données au sein du groupe Accenture. Le but est de réduire drastiquement l'intervention manuelle tout en standardisant la production des règles de transformation.

La méthode adoptée repose sur le déploiement d'une architecture novatrice d'Intelligence Artificielle agentique. Un système multi-agents, orchestré via LangGraph et intégrant des modèles de langage avancés (LLMs) utilisant le raisonnement "Chain of Thought", a été mis en place. Techniquement, l'architecture transitionne vers un stockage centralisé sous PostgreSQL exploitant le format JSON. Différents agents spécialisés (Scope, Design, Validation) travaillent en synergie pour ingérer les modèles de données, effectuer des analyses d'écarts (Gap Analysis) de manière autonome, et valider la cohérence des opérations.

Les principaux résultats mettent en évidence l'automatisation réussie de la génération des livrables critiques de conception (Data Mapping, Table Mapping, SDS, TDS). La nouvelle infrastructure établit un flux de données continu, sécurisé et auditable, fiabilisant ainsi la qualité des données avant leur injection vers les systèmes cibles, et préparant le terrain pour l'automatisation des phases de transformation complexes.

Mots-clés : Migration de données, Intelligence Artificielle agentique, Pipeline ETL, Architecture système, Automatisation.

Table des matières

Table des figures

Liste des tableaux

List of Abbreviations

A two-column table listing every acronym or abbreviation used in the report (e.g. API, REST, UML, DB) alongside its full meaning. List them in alphabetical order. Only include abbreviations actually used in the document.

API	Application Programming Interface
DB	Database

Chapitre 1

Introduction Générale

1.1 Introduction Générale

La transformation numérique des entreprises impose aujourd'hui des défis sans précédent en matière de gestion et d'intégration des données. Parmi ces défis, la migration de données, processus consistant à transférer de manière sécurisée et contrôlée les données d'un système source vers un système cible, constitue un enjeu stratégique majeur. C'est dans ce contexte que s'inscrit le présent Projet de Fin d'Études (PFE), réalisé au sein de l'équipe ADMP (Accenture Data Migration Platform) d'Accenture, et portant sur le développement d'une plateforme de migration de données basée sur l'intelligence artificielle pour l'amélioration et l'optimisation des processus d'intégration des données.

1.2 Organisme d'accueil

1.2.1 Présentation d'Accenture

Accenture plc est une entreprise multinationale de services professionnels, fondée en 1989 sous le nom d'Andersen Consulting avant de devenir Accenture en 2001, et dont le siège social est situé à Dublin, en Irlande. Cotée à la Bourse de New York (NYSE : ACN), Accenture figure parmi les plus grandes entreprises mondiales de conseil et de services technologiques. En termes de performance financière, l'exercice fiscal 2025 (clos le 31 août 2025) témoigne de la solidité et de l'envergure du groupe, comme l'illustre le Tableau ??.

Indicateur	Valeur (FY 2025)
Chiffre d'affaires	69,7 milliards USD (+7%)
Résultat net (GAAP)	7,83 milliards USD
Nouvelles commandes (<i>bookings</i>)	80,6 milliards USD
Effectif mondial	≈ 779 000 collaborateurs
Clients servis	≈ 9 000 dans plus de 120 pays
Bureaux et opérations	200+ villes dans 52 pays

TABLE 1.1 – Indicateurs clés d'Accenture pour l'exercice fiscal 2025



FIGURE 1.1 – Logo du groupe Accenture

L'entreprise s'articule autour de plusieurs domaines d'activité complémentaires : Strategy & Consulting, Technology, Operations, Accenture Song (ex-Interactive) et Industry X. Sa stratégie repose sur l'ambition d'être le *reinvention partner of choice* de ses clients, en combinant expertise sectorielle approfondie, partenariats écosystémiques et investissements massifs dans l'innovation.

L'intelligence artificielle occupe une place centrale dans la stratégie d'Accenture. En 2023, le groupe a annoncé un investissement de **3 milliards de dollars sur trois ans** dans sa practice *Data & AI*, visant à doubler ses effectifs IA à 80 000 professionnels et à créer des accélérateurs pour 19 secteurs industriels distincts. Les résultats de cet investissement sont déjà visibles : en FY 2025, le chiffre d'affaires lié à l'IA avancée (GenAI, IA agentique, IA physique) a triplé pour atteindre **2,7 milliards USD**, avec des commandes GenAI de **5,9 milliards USD** et plus de **6 000 projets d'IA avancée** livrés au cours de l'exercice. L'effectif *Data & AI* est passé de 40 000 à **77 000 professionnels**, et plus de 550 000 collaborateurs ont été formés aux fondamentaux de l'IA générative.

1.2.2 Accenture au Maroc

Au Maroc, Accenture est implantée à Casablanca, au sein du parc technologique **Casanear-shore** (Sidi Maarouf), Shore 10, Park 1100, Boulevard Al Qods. Sous les entités **Accenture Morocco** et **Accenture Maghreb**, la filiale marocaine fournit des prestations de services en conseil en management, en télécommunications et en technologies de l'information. Le centre de Casablanca sert de hub nearshore pour les projets européens et africains, offrant un accès à un vivier de talents qualifiés et à un environnement opérationnel compétitif.

Le site de **Rabat, Meditech** accueille également des équipes Accenture, dont l'équipe ADMP au sein de laquelle ce PFE a été réalisé. Ce positionnement géographique permet une collaboration étroite avec les équipes européennes (principalement basées en France et en Espagne) tout en bénéficiant de la proximité culturelle et linguistique avec les clients francophones.

1.2.3 Positionnement de l'équipe ADMP au sein d'Accenture

L'**Accenture Data Migration Platform (ADMP)** est une capacité de migration propriétaire développée par Accenture depuis plus de **25 ans**, dédiée à l'accélération, l'automatisation et la sécurisation des projets de migration de données à grande échelle.

L'équipe ADMP se positionne au sein de la practice **Technology, Data & AI** et constitue un centre d'expertise spécialisé dans la migration de systèmes legacy vers des plateformes modernes. Son périmètre d'intervention est mondial et couvre trois géographies : North America, APAC et EMEA.

Les chiffres clés de l'ADMP, présentés dans le Tableau ??, illustrent sa maturité et son envergure.

TABLE 1.2 – Indicateurs clés de la plateforme ADMP

Indicateur	Valeur
Années d'expérience	+25 ans
Migrations gérées	+200 projets
Objets métier migrés	+75 millions
Spécialistes techniques et fonctionnels	+55
Géographies couvertes	3 (NA, APAC, EMEA)
Coût de licence	Aucun
Réduction des coûts vs approche non industrielle	Jusqu'à 66%

L'ADMP a servi des clients majeurs dans des secteurs variés, principalement l'assurance (Generali, AXA, Chubb, QBE, MMA, Allianz, AG2R La Mondiale), les utilities (SAUR) et l'industrie (Legrand, Bureau Veritas), avec des systèmes cibles tels que Duck Creek, Guidewire, Salesforce, Vitech et SAP.

La plateforme repose sur trois piliers fondamentaux :

- **Smart Designs** : des documents structurés (Word/Excel) qui décrivent les règles de transformation, les mappings de champs, les relations entre tables et les contraintes métier. Ces documents sont lisibles par les équipes fonctionnelles tout en étant interprétables automatiquement par la plateforme pour générer les programmes de migration.
- **Cycle ETL automatisé** : à partir des Smart Designs, ADMP génère automatiquement les programmes d'extraction, transformation et chargement, sans nécessiter de développeurs ETL traditionnels.
- **Qualité et traçabilité** : la plateforme intègre des modules de validation (pre-load et post-load), des contrôles d'intégrité, des tableaux de bord de suivi et des rapports d'anomalies facilitant les itérations entre équipes techniques et fonctionnelles.

Dans le cadre de son programme d'évolution stratégique, l'équipe ADMP a initié l'intégration de l'intelligence artificielle au sein de la plateforme, articulée autour de trois axes majeurs : l'**ADMP AI Engine** (moteur d'IA pour l'automatisation de la validation, la génération de règles et les suggestions en temps réel), l'**ADMP Studio** (outil web de design remplaçant les plugins VBA) et l'amélioration des **outils de design existants** par infusion de GenAI. C'est précisément dans ce programme d'innovation que s'inscrit le présent PFE.

1.3 Présentation d'AFDTech

Fondée en 1998 par Jérôme Picard, **AFD.Tech** est une société française de conseil et d'ingénierie qui s'est progressivement imposée comme un acteur incontournable du marché des infrastructures informatiques, des réseaux et des télécommunications. Initialement positionnée sur le conseil de haut niveau dans le domaine télécom, au point d'avoir longtemps été qualifiée de « *Pure Player Télécom* », l'entreprise a su, au fil des années, élargir son champ d'expertise pour accompagner les grandes entreprises dans l'ensemble de leur transformation digitale : ingénierie réseau, cybersécurité, cloud computing, gestion des données, automatisation et intelligence artificielle.

Avec une croissance annuelle soutenue, AFD.Tech intervient aujourd'hui sur des projets complexes auprès de clients majeurs des secteurs bancaire, assurance, énergie, transport, télécommunications et services publics. Son implantation géographique s'étend sur trois pays (France, Belgique et Maroc) et compte aujourd'hui une dizaine de bureaux répartis entre Paris, Bruxelles, Rabat, Lyon, Strasbourg, Lille, Nantes, Toulouse, Marseille et Rennes.

Le tableau ?? synthétise les principales informations relatives à l'entreprise.



FIGURE 1.2 – Logo d'AFD.Tech Part of Accenture

Attribut	Valeur
Raison sociale	AFD.Tech Part of Accenture
Année de création	1998
Fondateur	Jérôme Picard
Siège social	Paris, France
Présence internationale	France, Belgique, Maroc
Implantation au Maroc	Depuis 2014 (Rabat)
Effectif global	Plus de 1 600 collaborateurs
Effectif au Maroc	Plus de 900 collaborateurs
Secteurs d'activité	Télécoms, IT, Cloud, Cybersécurité, Data, IA
Site web	https://afd.tech

TABLE 1.3 – Informations clés sur AFD.Tech Part of Accenture

1.3.1 Le rapprochement avec Accenture

L'année 2022 marque un tournant majeur dans l'histoire de l'entreprise. Le **1^{er} avril 2022**, AFD.Tech rejoint officiellement le groupe **Accenture**, leader mondial des services aux entreprises et administrations, à l'issue d'une opération de rachat à 100 % du capital annoncée le 15 décembre 2021. Cette acquisition, motivée par la volonté d'Accenture de renforcer ses capacités en services réseaux autour des technologies 5G, fibre et *cloud-first networks*, s'est traduite par l'intégration de plus de 1 600 professionnels hautement qualifiés au sein du groupe.

Désormais désignée sous la dénomination **AFD.Tech Part of Accenture**, l'entreprise a conservé sa culture d'expertise technique tout en bénéficiant de la dimension internationale, des moyens et de l'écosystème d'innovation d'Accenture. Cette intégration stratégique a permis à AFD.Tech d'élargir significativement son périmètre commercial : alors que ses clients étaient historiquement basés en France (à hauteur de 90 %) et en Belgique, l'entreprise travaille aujourd'hui également avec des clients au Benelux, en Italie et au Royaume-Uni.

1.3.2 AFD.Tech au Maroc : MEDITECH et MEDxp

L'implantation marocaine d'AFD.Tech, démarrée en **2014** avec une équipe de quelques dizaines d'ingénieurs, a connu une croissance exponentielle pour devenir aujourd'hui l'un des piliers du développement nearshore du groupe. Cette dynamique s'est concrétisée par la création successive de deux centres d'excellence dédiés aux nouvelles technologies à Rabat.

MEDITECH. Inauguré en 2021, MEDITECH a été le premier centre d'innovation d'AFD.Tech au Maroc. Construit sur **2 000 m²** et accueillant aujourd'hui **plus de 300 ingénieurs**, il a été conçu dès l'origine comme un lieu d'excellence technologique, ouvert et collaboratif, capable d'incarner l'identité innovante du groupe. Il a posé les fondations de la stratégie d'expansion marocaine et constitue toujours le cœur opérationnel des activités locales.

MEDxp. Ouvert en avril 2023, MEDxp prolonge cette dynamique avec une vocation encore plus orientée vers les technologies de pointe. Ce second pôle, également de 2 000 m², est dédié aux nouvelles technologies et accueille plus de 300 ingénieurs experts en **5G, intelligence artificielle et data science**. Au-delà de sa dimension technique, MEDxp se veut un espace de culture et de partage, centré sur l'expérience offerte aux candidats et aux collaborateurs.

L'équipe marocaine compte aujourd'hui **plus de 900 experts** et joue un rôle crucial dans l'évolution du groupe. Elle est dirigée par **Amine El Rhayour**, *Director of the Service Delivery Center Morocco*, dont le parcours d'ingénieur incarne la trajectoire d'excellence technique portée par l'entreprise au Maroc. L'organisation interne s'articule autour de plusieurs pôles stratégiques, comme illustré par la figure ??.



FIGURE 1.3 – Le centre d'excellence MEDITECH à Rabat

FIGURE 1.4 – Organigramme du centre AFD.Tech Maroc

L'expertise déployée à Rabat couvre un périmètre étendu : ingénierie réseau et télécoms, transformation digitale, cloud computing, intelligence artificielle, data science et migration de données. C'est précisément dans ce dernier domaine, au sein de l'équipe ADMP, que s'inscrit le présent stage de fin d'études.

1.4 Contexte académique

1.4.1 Présentation de l'Université Internationale de Rabat

L'**Université Internationale de Rabat (UIR)** est une université privée d'excellence fondée en 2010, située sur le campus Technopolis à Rabat-Salé. Reconnue par l'État marocain, l'UIR propose des formations innovantes dans les domaines de l'ingénierie, de l'architecture, du management (Rabat Business School), du droit, des sciences politiques, des énergies renouvelables et des sciences de la santé.

Partenaire de grandes universités françaises et européennes, notamment l'Université de Nantes, l'UIR offre des doubles diplômes et une forte ouverture internationale à ses étudiants. L'université s'est distinguée récemment par un palmarès historique au Salon International des Inventions de Genève (4 médailles et un prix spécial) et par l'intégration de Rabat Business School dans le classement QS Executive MBA 2026.



FIGURE 1.5 – L'Université Internationale de Rabat

1.4.2 L'École Supérieure d'Informatique et du Numérique (ESIN)

Le présent PFE est réalisé dans le cadre de la formation d'**ingénieur en informatique** dispensée par l'**École Supérieure d'Informatique et du Numérique (ESIN)**, composante de l'UIR. L'ESIN a pour mission de former des informaticiens hautement qualifiés et de mener des activités de recherche accompagnant le développement technologique et économique du Maroc.

La formation s'étend sur cinq ans : deux années de cycle préparatoire intégré, suivies de trois années de cycle ingénieur. La première année du cycle ingénieur constitue un tronc commun, et la deuxième année offre un choix de spécialisation entre : **Big Data**, **Ingénierie des systèmes d'information**, **Sécurité des systèmes d'information** et **Cloud Computing & Virtualisation**.

Les objectifs pédagogiques du programme (PEO) visent à former des ingénieurs capables d'appliquer les principes de l'informatique dans un cadre professionnel, de déployer des fondements interdisciplinaires, et de résoudre de manière créative des problèmes au sein d'équipes pluridisciplinaires.

L'ESIN est née d'un partenariat académique entre l'UIR et l'Université de Nantes, et bénéficie de partenariats industriels avec des entreprises de premier plan, assurant ainsi une pédagogie axée sur l'insertion professionnelle et le rapprochement avec le monde socio-économique.

1.5 Cadrage du projet de stage

1.5.1 Sujet et périmètre de la mission

Le sujet de ce PFE s'intitule : « **Développement d'une plateforme de migration de données basée sur l'IA pour l'amélioration et l'optimisation des processus d'intégration des données** ».

Il s'inscrit dans le programme d'évolution d'ADMP visant à intégrer l'intelligence artificielle au cœur de la plateforme. Les objectifs stratégiques de cette intégration sont triples :

- **Rester un différenciateur réel** en matière de migration grâce à un moteur IA dédié (ADMP AI Engine).
- **Optimiser et accélérer** le temps nécessaire à la rédaction des spécifications de migration, et automatiser l'analyse des audits de données.
- **Créer un véritable assistant intelligent** pour les spécificateurs, réduisant la charge globale de travail.

Le périmètre de la mission couvre principalement la **génération du bundle Databricks**, un module central de la nouvelle architecture ADMP, dont les détails techniques seront présentés dans les chapitres 5 et 6. Ce module vise à automatiser la création des artefacts de migration en s'appuyant sur des technologies de traitement distribué (Apache Spark / Databricks) et d'intelligence artificielle générative.

1.5.2 Objectifs opérationnels et livrables attendus

Les objectifs opérationnels du PFE se déclinent comme suit :

- **Comprendre et maîtriser** la méthodologie ADMP et ses livrables (SDS, IDS, TDS, DS, RC, DP, TT, MS) à travers la formation Core ADMP Design School (CIDS).
- **Contribuer opérationnellement** aux projets de migration en cours, notamment en matière d'analyse de données, de validation de tickets et de rédaction de spécifications.
- **Concevoir et implémenter** le module de génération du bundle Databricks dans le cadre de l'évolution IA de la plateforme.
- **Tester et valider** la solution développée sur des cas réels de migration.
- **Documenter** l'ensemble du travail réalisé dans le présent rapport de PFE.

Ce travail s'inscrit dans la continuité des contributions précédentes de l'équipe : le PFE de Elharrioui Aymen portant sur la conception d'un agent intelligent basé sur RAG et l'architecture AppSync/GraphQL, et le PFE de Majbar Nizar portant sur le fine-tuning d'un LLM (Mistral 7B avec LoRA) pour la génération de règles de transformation.

1.5.3 Planning prévisionnel

Le stage se déroule sur une période de six mois, organisée en phases progressives, comme le résume le Tableau ??.

TABLE 1.4 – Planning prévisionnel du stage

Phase	Période	Activités principales
Intégration & Formation	Mois 1–2	Onboarding, CIDS (2 semaines), découverte des outils et de la méthodologie ADMP
Contribution opérationnelle	Mois 2–4	Participation aux projets de migration, analyse de données, gestion de tickets, validation
Conception & Développement	Mois 3–5	Conception et implémentation du module de génération du bundle Databricks
Tests & Validation	Mois 5–6	Tests, évaluation, documentation, rédaction du rapport

Un diagramme de Gantt détaillé est présenté en annexe.

1.6 Organisation du rapport

Le présent rapport est structuré selon une logique narrative séquentielle, guidant le lecteur depuis la compréhension du problème jusqu'à la validation de la solution proposée :

- **Chapitre 2, Contexte et Problématique** : présente de manière générique les enjeux et défis de la migration de données, indépendamment de tout projet client, et formule la problématique de recherche.
- **Chapitre 3, État de l'Art** : explore les fondements théoriques de la migration, les solutions existantes sur le marché (outils ETL, services cloud), la plateforme ADMP dans son état actuel, les avancées de l'IA dans l'intégration de données, et identifie les limites et opportunités qui positionnent notre contribution.
- **Chapitre 4, Cadre Méthodologique et Gestion de Projet** : décrit l'organisation agile du travail, le cycle de vie des tickets, les processus de validation des données et les pratiques collaboratives de l'équipe.
- **Chapitre 5, Conception et Architecture de la Solution** : présente exclusivement les éléments nouveaux de notre contribution, l'architecture IA cible et le module de génération du bundle Databricks, en s'appuyant sur la description de l'existant fournie au chapitre 3.
- **Chapitre 6, Implémentation** : détaille la réalisation technique des modules, l'environnement de développement, et les difficultés rencontrées avec leurs solutions.
- **Chapitre 7, Résultats et Évaluation** : présente le protocole de test, les résultats obtenus et une discussion critique de la solution.
- **Chapitre 8, Conclusion et Perspectives** : synthétise les contributions, les compétences acquises et les pistes d'évolution futures.

Chapitre 2

Contexte et Problématique

La transformation numérique est devenue un impératif stratégique pour les entreprises de toutes tailles et de tous secteurs. Au coeur de cette transformation se trouve un processus souvent sous-estimé mais fondamental : la migration de données. Qu'il s'agisse de remplacer un système legacy par une plateforme moderne, de consolider des bases de données après une fusion-acquisition, ou d'adopter des solutions cloud pour gagner en agilité, la migration de données constitue le socle invisible sur lequel repose le succès – ou l'échec – de tout projet de modernisation. Ce chapitre dresse un panorama des enjeux et des défis liés à la migration de données, avant de formuler la problématique qui guidera l'ensemble de ce travail.

2.1 La migration de données : définition et enjeux

2.1.1 Qu'est-ce qu'une migration de données ?

La migration de données désigne le processus de transfert de données d'un système source vers un système cible, tout en garantissant leur intégrité, leur qualité et leur conformité aux exigences du nouvel environnement. Ce processus ne se limite pas à un simple déplacement physique de fichiers : il implique l'extraction des données depuis le système d'origine, leur transformation pour les adapter au modèle cible (types de données, formats, contraintes métier, relations entre entités), et leur chargement dans le nouveau système. Ce triptyque, universellement connu sous l'acronyme **ETL** (*Extract, Transform, Load*), constitue le paradigme fondamental de toute opération de migration [microsoft_etl].




FIGURE 2.1 – Schéma du processus ETL classique.

Il est essentiel de distinguer la migration de données d'autres processus apparentés. L'**intégration de données** vise à combiner en continu des données provenant de sources hétérogènes, tandis que la **réplication** crée des copies synchronisées entre systèmes. La migration, quant à elle, est un événement ponctuel et planifié, avec un début et une fin définis, qui s'inscrit généralement dans un projet plus large de transformation des systèmes d'information [cloudficient2025].

2.1.2 Typologies de migration

Les projets de migration de données se déclinent en plusieurs typologies selon le contexte métier qui les déclenche :

- **Re-platforming (migration applicative)** : il s'agit du remplacement d'un système legacy par une plateforme moderne. C'est le cas, par exemple, lorsqu'une entreprise migre son CRM on-premise vers Salesforce, ou son ERP vers SAP S/4HANA. Cette catégorie représente la majorité des projets de migration à grande échelle [admp_core].
- **Consolidation et fusion (Merger & Acquisition)** : lors d'une fusion ou d'une acquisition, les entreprises doivent fusionner leurs bases de données hétérogènes en un référentiel unifié,

un défi d'autant plus complexe que les systèmes à consolider peuvent avoir des modèles de données radicalement différents.

- **Migration vers le cloud** : avec 94 % des organisations utilisant déjà une infrastructure cloud en 2025 et 85 % engagées dans une transition *cloud-first*, la migration des données on-premise vers des environnements cloud (AWS, Azure, GCP) ou hybrides est devenue un processus incontournable [duplocloud2025].
- **Profiling et cleansing** : certaines migrations sont motivées principalement par un objectif d'amélioration de la qualité des données – nettoyage, déduplication, enrichissement – avant leur réinjection dans un système existant ou nouveau [admp_core].
- **Externalisation de processus métier (BPO)** : le transfert de processus métier vers un prestataire externe nécessite la migration sécurisée des données associées, avec des contraintes strictes de confidentialité et de conformité.

2.1.3 Enjeux stratégiques pour les entreprises

La migration de données est bien plus qu'un exercice technique : c'est un enjeu stratégique à fort impact business. Les chiffres du marché en témoignent de manière éloquent.

Le **marché mondial de la migration de données** est estimé à **12,8 milliards USD en 2025** et devrait atteindre **36,8 milliards USD d'ici 2033**, soit un taux de croissance annuel composé (CAGR) de **14,6 %** [datamintel2026]. En parallèle, le marché plus large de l'**intégration de données** (incluant les plateformes ETL/ELT, iPaaS et outils de streaming) est évalué à **17,58 milliards USD en 2025**, avec une projection à **33,24 milliards USD en 2030** (CAGR de 13,6 %) [mam2025]. Le marché spécifique des **logiciels ETL**, quant à lui, est estimé à **15 milliards USD en 2025** et devrait atteindre **45 milliards USD d'ici 2033** (CAGR de 12 %) [mordor2025].

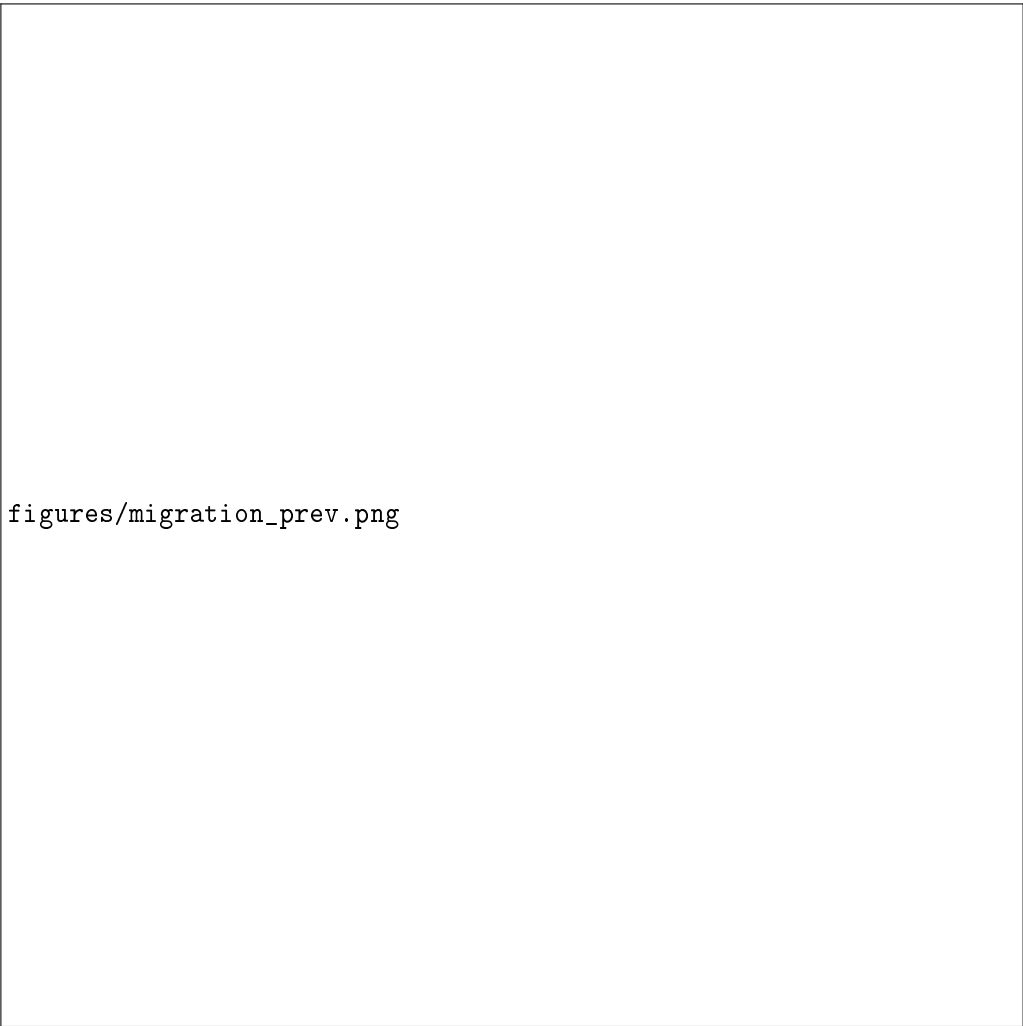


FIGURE 2.2 – Évolution du marché mondial de la migration de données (2024–2034).

Le tableau ?? synthétise les principales estimations de marché issues de différents cabinets d’analyse :

TABLE 2.1 – Estimations du marché de la migration de données selon différentes sources.

Source	Val. 2025	Projection	CAGR	Période
DataM Intelligence	12,8 Mds USD	36,8 Mds USD (2033)	14,6 %	2026–2033
Market Research Future	10,56 Mds USD	34,57 Mds USD (2035)	12,59 %	2025–2035
Market Trends Analysis	15,2 Mds USD (2024)	32,8 Mds USD (2033)	9,2 %	2025–2033

Ces chiffres révèlent une réalité sans équivoque : la migration de données est un marché en pleine expansion, porté par la transformation digitale, l’adoption massive du cloud, et l’émergence de l’intelligence artificielle qui exige des données propres, structurées et accessibles. Les outils de migration pilotés par l’IA connaissent d’ailleurs une croissance de **28 %** selon Gart-

ner [kellton2025].

Au-delà de la croissance du marché, les enjeux stratégiques se déclinent en quatre dimensions :

- **Continuité d'activité** : toute interruption ou perte de données durant une migration peut paralyser les opérations métier, avec des conséquences financières et réputationnelles considérables.
- **Conformité réglementaire** : les réglementations sur la protection des données (RGPD, CCPA, HIPAA) imposent des exigences strictes en matière de traçabilité, de sécurité et de gouvernance durant le processus de migration [kaopiz2025].
- **Coût et time-to-market** : les coûts de migration représentent typiquement **30 à 50 % du budget total d'un projet de modernisation IT**. La capacité à migrer rapidement et efficacement devient donc un avantage compétitif majeur [kaopiz2025].
- **Fondation pour l'IA** : les systèmes d'intelligence artificielle modernes exigent des données de haute qualité. Une migration mal exécutée peut compromettre l'ensemble des initiatives IA d'une organisation avant même leur démarrage [kaopiz2025].

2.2 Anatomie d'un projet de migration : les défis

Malgré son importance stratégique, la migration de données reste l'un des processus les plus risqués et les plus complexes du paysage IT. Comme le souligne une analyse approfondie publiée en 2025, **83 % des projets de migration échouent ou dépassent leur budget et leurs délais**. Selon Gartner, près de **70 % des projets de migration n'atteignent pas leurs objectifs**, souvent en raison de risques sous-estimés, d'une planification insuffisante ou d'une validation inadéquate [kaopiz2025, kanerika2025].

2.2.1 Hétérogénéité des systèmes source et cible

Le premier défi fondamental réside dans la disparité entre les systèmes d'origine et de destination. Les données sources peuvent provenir de bases relationnelles (Oracle, SQL Server, DB2), de fichiers plats (CSV, TXT), de systèmes mainframe (VSAM, IMS), ou d'applications métier propriétaires, chacun avec ses propres formats, encodages et conventions de nommage. Le système cible, quant à lui, impose son propre modèle de données, ses contraintes d'intégrité référentielle et ses règles de validation [admp_core].

Cette hétérogénéité génère des **incompatibilités de schéma** qui sont à l'origine de **45 % des échecs de migration** selon les analyses sectorielles. La réconciliation entre ces modèles divergents nécessite un travail minutieux de *mapping* – à la fois au niveau des tables (*Table Mapping*) et des champs (*Data Mapping*) – qui constitue l'un des exercices les plus chronophages et les plus sujets à erreur du processus [cloudficient2025].

2.2.2 Volumétrie et performance

L'explosion des volumes de données amplifie considérablement la complexité des migrations. La création mondiale de données devrait atteindre **181 zettaoctets en 2025**, et l'entreprise moyenne gère ses données à travers **14 systèmes distincts simultanément**. À cette échelle, les défis de performance deviennent critiques : les temps d'extraction s'allongent, les transformations consomment des ressources considérables, et les fenêtres de migration (souvent limitées à des week-ends ou des périodes de faible activité) deviennent insuffisantes [kaopiz2025].

Les organisations traitent désormais des volumes allant du téraoctet au pétaoctet, avec une vélocité de données exigeant des migrations à temps d'arrêt quasi nul. Les risques ETL se multiplient de manière exponentielle avec l'augmentation de la taille des données, rendant la validation et la réconciliation de plus en plus complexes et chronophages [kanerika2025].

2.2.3 Qualité et intégrité des données

La qualité des données sources constitue un facteur déterminant – et souvent sous-estimé – du succès d'une migration. Selon un rapport Gartner de 2023, la mauvaise qualité des données

coûte aux organisations en moyenne **12,9 millions de dollars par an** en ressources gaspillées et en opportunités manquées [gartner_quality]. Un rapport IBM de 2025 confirme cette tendance : **43 % des directeurs des opérations** identifient la qualité des données comme leur priorité la plus critique, et plus d'un quart des organisations estiment perdre plus de **5 millions de dollars annuellement** en raison de données de mauvaise qualité [ibm2025].

Dans le contexte spécifique de la migration, les problèmes de qualité se manifestent sous plusieurs formes :

- **Données incomplètes** : champs obligatoires non renseignés, enregistrements tronqués, historiques partiels.
- **Données incohérentes** : doublons, formats hétérogènes (dates, adresses, codes), valeurs contradictoires entre systèmes.
- **Données obsolètes** : informations périmées qui ne reflètent plus la réalité métier.
- **Données corrompues** : altérations dues à des bugs applicatifs, des migrations antérieures mal exécutées, ou des problèmes d'encodage.

Selon une étude Experian, **64 % des projets de migration analysés dépassent leur budget**, et seulement **46 % sont livrés dans les délais prévus**, en grande partie à cause de problèmes de qualité de données non anticipés [montecarlo2025]. Par ailleurs, **35 % des projets de migration cloud échouent directement à cause d'une qualité de données insuffisante** [wifitalents2025].

2.2.4 Complexité des règles de transformation métier

Au-delà du simple transfert de données, la migration implique l'application de **règles de transformation métier** souvent complexes et spécifiques à chaque domaine fonctionnel. Ces règles déterminent comment les données sources doivent être restructurées, enrichies, filtrées ou agrégées pour correspondre au modèle cible.

Les défis typiques incluent :

- **Relations N :M (Many-to-Many)** : les associations complexes entre entités (par exemple, entre compétences et ressources, ou entre contrats et prestations) nécessitent des étapes intermédiaires de regroupement et de dédoublonnage.
- **Transcodification** : la correspondance entre les valeurs codifiées du système source et celles du système cible (codes pays, types de contrat, statuts) requiert des tables de correspondance exhaustives et validées par le métier.
- **Création conditionnelle d'enregistrements** : certains enregistrements cibles n'existent pas dans le système source et doivent être créés selon des règles métier spécifiques (par exemple, la création automatique d'un enregistrement maître pour chaque groupe d'enregistrements détail).

- **Gestion des cas particuliers** : les exceptions, les cas limites et les incohérences historiques nécessitent un traitement au cas par cas, difficilement automatisable.

La formalisation et l'implémentation de ces règles constituent l'un des postes les plus coûteux en temps et en expertise dans un projet de migration, et c'est souvent à ce niveau que se creuse le fossé entre les spécifications fonctionnelles et leur traduction technique.

2.2.5 Traçabilité et auditabilité du processus

Dans un environnement réglementaire de plus en plus exigeant, la capacité à **tracer l'ensemble du processus de migration** – de l'extraction à la source jusqu'au chargement dans la cible – est devenue une exigence non négociable. Les régulateurs et les auditeurs attendent des organisations qu'elles puissent démontrer :

- **L'origine de chaque donnée migrée** (*data lineage*) : d'où vient-elle, quelles transformations a-t-elle subies, qui les a validées.
- **L'intégrité du transfert** : aucune donnée n'a été perdue, altérée ou dupliquée durant le processus.
- **La conformité des transformations** : les règles appliquées correspondent exactement aux spécifications validées par le métier.

Or, **34 % des organisations rapportent des lacunes de conformité durant la migration**, et **38 % déclarent que la préparation aux audits est difficile** dans ce contexte. Les outils ETL traditionnels, souvent qualifiés de boîtes noires, rendent cette traçabilité particulièrement ardue, car le lien entre les spécifications fonctionnelles et le code exécuté n'est ni direct ni transparent [gitnux_cloud, admp_overview].

2.2.6 Coordination entre équipes IT et Business

La migration de données se situe à l'intersection de deux mondes : celui des **équipes techniques** (développeurs ETL, DBA, architectes) qui maîtrisent les outils et les systèmes, et celui des **équipes métier** (analystes fonctionnels, utilisateurs finaux, responsables qualité) qui détiennent la connaissance des règles de gestion et des cas d'usage. Cette dualité engendre des défis organisationnels majeurs :

- **Barrière linguistique** : les équipes techniques raisonnent en termes de tables, de requêtes et de schémas, tandis que les équipes métier parlent de contrats, de clients et de polices. La traduction entre ces deux langages est source de malentendus et d'erreurs.
- **Cycle de validation long** : chaque itération de migration nécessite une revue fonctionnelle par le métier, qui doit vérifier que les données migrées correspondent à ses attentes. Ce cycle peut s'étendre sur plusieurs semaines.

- **Résistance au changement** : 70 % des migrations échouent en partie à cause d'une mauvaise gestion du changement et de la résistance des utilisateurs [worldmetrics2025].
- **Pénurie de compétences** : 80 % des organisations rapportent que le manque d'expertise interne est leur principal frein à la réussite des migrations, et 25 % citent le manque de compétences comme cause directe d'échec [wifitalents2025, gitnux_cloud].

Le tableau ?? synthétise les six défis majeurs avec leur impact et leur fréquence :

Défi	Impact principal	Statistique clé
Hétérogénéité des systèmes	Incompatibilités, corruption	45 % des échecs
Volumétrie et performance	Dépassements de délais	Estimation erronée de 40–60 %
Qualité des données	Surcoûts, reprises	12,9 M\$/an en moyenne (Gartner)
Complexité des transformations	Écart design–build	30–50 % du budget IT total
Traçabilité et auditabilité	Non-conformité	34 % de lacunes de conformité
Coordination IT / Business	Retards, malentendus	70 % d'échecs liés au change management

TABLE 2.2 – Synthèse des principaux défis d'un projet de migration de données.

2.3 Formulation de la problématique

L'analyse des enjeux et des défis présentés dans les sections précédentes met en lumière un constat central : **la migration de données reste un processus à haut risque, coûteux et fortement dépendant de l'expertise humaine**, malgré l'existence d'outils ETL et de méthodologies établies.

Trois lacunes structurelles émergent de cette analyse :

- **Le fossé Design–Build** : dans la plupart des approches actuelles, il existe un décalage significatif entre la rédaction des spécifications fonctionnelles (le *design*) et leur implémentation technique (le *build*). Ce fossé est source d'erreurs, de retards et de surcoûts, car il nécessite une traduction manuelle des règles métier en code ETL exécutable [admp_overview].
- **L'opacité des processus** : les outils ETL traditionnels fonctionnent comme des boîtes noires, rendant difficile la validation fonctionnelle, l'auditabilité et la réconciliation des données par les équipes non techniques.
- **L'absence d'intelligence artificielle** : alors que l'IA transforme de nombreux domaines de l'IT, les processus de migration de données restent largement manuels – de la rédaction des spécifications à la détection des anomalies, en passant par la génération des programmes de transformation. Les outils de migration pilotés par l'IA n'en sont qu'à leurs débuts, avec seulement **35 % des entreprises utilisant des plateformes augmentées par l'IA** pour leurs migrations [reanin2025].

Ces constats nous amènent à formuler la problématique suivante :

Comment concevoir et implémenter une plateforme de migration de données intégrant l'intelligence artificielle pour automatiser et optimiser les processus d'intégration, réduire le fossé entre la conception fonctionnelle et l'exécution technique, et améliorer la qualité, la traçabilité et l'efficacité globale du processus de migration ?

Cette problématique sera explorée à travers l'état de l'art (chapitre suivant), qui examinera les solutions existantes – y compris la plateforme ADMP – et les avancées de l'IA dans le domaine de l'intégration de données, avant de présenter notre contribution visant à enrichir cette plateforme par des capacités d'intelligence artificielle.

Chapitre 3

État de l'Art

3.1 État de l'Art

Le chapitre précédent a mis en lumière les défis structurels de la migration de données et formulé la problématique centrale de ce travail. Le présent chapitre explore l'état de l'art scientifique et technologique afin d'identifier les fondements, les solutions existantes, et les opportunités d'amélioration qui positionnent notre contribution. Nous commençons par les fondements théoriques, passons en revue les solutions du marché, décrivons en profondeur la plateforme ADMP dans son état actuel, explorons les avancées de l'intelligence artificielle appliquées au domaine, avant d'analyser les limites de l'existant et de formuler notre positionnement.

3.1.1 Fondements théoriques

3.1.1.1 Le paradigme ETL / ELT : principes et évolution

Le paradigme **ETL (Extract, Transform, Load)** constitue depuis plusieurs décennies le socle fondamental de toute opération d'intégration de données. Il décrit un processus en trois phases séquentielles : l'**extraction** des données depuis les systèmes sources, leur **transformation** dans une zone intermédiaire (staging) pour les adapter au modèle cible, puis leur **chargement** dans le système de destination. Ce paradigme a été le pilier de l'ère du data warehousing classique, où les ressources de calcul étaient limitées et coûteuses, imposant un pré-traitement rigoureux des données avant leur insertion dans l'entrepôt.

Avec l'avènement du cloud computing et des entrepôts de données modernes (Snowflake, BigQuery, Amazon Redshift), un paradigme alternatif a émergé : l'**ELT (Extract, Load, Transform)**. Dans cette approche, les données brutes sont d'abord chargées dans le système cible, puis transformées directement en exploitant la puissance de calcul élastique de l'infrastructure cloud. L'ELT offre une flexibilité analytique accrue, une meilleure utilisation des ressources et un time-to-insight réduit, tout en posant de nouveaux défis en matière de gouvernance et de gestion technique.




FIGURE 3.1 – Comparaison des paradigmes ETL et ELT

L'évolution de l'ETL vers l'ELT ne se résume pas à une simple réorganisation des étapes : elle reflète un changement fondamental dans la philosophie de gestion des données. Comme le souligne Vanga (2024) dans son étude publiée dans *l'International Journal for Multidisciplinary Research*, cette transition est catalysée par la croissance exponentielle des volumes de données, la prolifération des sources hétérogènes, et les exigences d'analyse en temps réel. Les architectures modernes tendent vers des modèles hybrides combinant les forces des deux approches, avec l'émergence de concepts tels que le **zero-ETL** et le **data mesh** qui promettent de réduire encore la complexité des pipelines de données. Le Tableau ?? présente une comparaison synthétique des deux paradigmes.

Critère	ETL	ELT
Transformation	Avant le chargement (staging)	Après le chargement (in-warehouse)
Infrastructure	On-premise, ressources limitées	Cloud-native, calcul élastique
Flexibilité	Schéma rigide, pré-défini	Schéma flexible, late-binding
Vitesse	Plus lent sur grands volumes	Plus rapide (puissance cloud)
Gouvernance	Contrôle pré-chargement	Nécessite gouvernance SQL forte
Outils typiques	Informatica, Talend, SSIS	dbt, Snowflake, BigQuery

TABLE 3.1 – Comparaison entre ETL et ELT

3.1.1.2 Modélisation des données

La réussite d'un projet de migration repose en grande partie sur la maîtrise des modèles de données source et cible. Trois approches principales de modélisation coexistent dans l'écosystème :

- **Le modèle relationnel**, fondé sur les travaux de Codd (1970), organise les données en tables liées par des clés primaires et étrangères. Il reste le standard dominant dans les systèmes transactionnels (OLTP) et les plateformes CRM comme Salesforce.
- **Le modèle dimensionnel**, popularisé par Kimball, structure les données autour de tables de faits et de dimensions, optimisées pour l'analyse (OLAP). Il est au cœur des entrepôts de données classiques.
- **Le modèle orienté objet**, qui encapsule données et comportements dans des objets liés par héritage et composition, est utilisé dans les systèmes modernes et les plateformes cloud-native. Comme le détaille la formation CIDS d'ADMP, « *an object-oriented data model consists of basic concepts : Object, Object identifier, Attributes, Methods, Class, Class hierarchy, and Inheritance* ».

La compréhension de ces modèles est essentielle pour le Data Analyst qui doit établir les correspondances (mappings) entre le système source et le système cible, en tenant compte des différences structurelles, des contraintes d'intégrité et des relations entre entités.

3.1.1.3 Qualité des données : métriques et frameworks

La qualité des données est un facteur déterminant du succès de toute migration. Le concept de dimensions de qualité des données a été formalisé en 1996 par les professeurs Richard Y. Wang et Diane M. Strong dans leur article fondateur « *Beyond Accuracy : What Data Quality Means to Data Consumers* ». Depuis, le framework DAMA-DMBOK a standardisé **six dimensions fondamentales** universellement adoptées, présentées dans le Tableau ??.

Dimension	Description	Exemple d'impact en migration
Exactitude	Les données reflètent-elles fidèlement la réalité ?	Adresse client erronée → livraison échouée
Complétude	Tous les champs requis sont-ils renseignés ?	Champ obligatoire vide → rejet au chargement
Cohérence	Les données sont-elles uniformes entre systèmes ?	Prix différent entre web et mobile
Fraîcheur	Les données sont-elles disponibles à temps ?	Données obsolètes → décisions erronées
Validité	Les données respectent-elles les formats et règles ?	Date « 30 février » → rejet de validation
Unicité	Pas de doublons ?	Doublons clients → métriques faussées

TABLE 3.2 – Dimensions de la qualité des données et impact en migration

Le coût de la non-qualité est considérable : selon Gartner (2023), la mauvaise qualité des données coûte en moyenne **12,9 millions de dollars par an** aux organisations. Dans le contexte spécifique de la migration, la mise en place de contrôles de qualité automatisés (profiling, validation pré-chargement, réconciliation post-chargement) est donc un prérequis incontournable.



FIGURE 3.2 – Les dimensions de la qualité des données

3.1.1.4 Gouvernance des données et conformité

La gouvernance des données établit les politiques, processus et responsabilités qui encadrent la gestion des données tout au long de leur cycle de vie. Dans le contexte de la migration, elle revêt une importance critique pour trois raisons :

Premièrement, la **traçabilité des données** (*data lineage*), la capacité à retracer le parcours complet d'une donnée depuis son origine jusqu'à sa destination, en passant par chaque transformation, est devenue une exigence réglementaire explicite. Le RGPD (Article 30) impose aux organisations de maintenir des registres des activités de traitement, incluant la classification des données, le suivi de la qualité, et les politiques de rétention.

Deuxièmement, le **principe de responsabilité** (*accountability*, Article 5(2) du RGPD) exige que les organisations puissent **démontrer**, et non simplement affirmer, leur conformité, à travers des politiques documentées, des rôles définis, des contrôles techniques et des traces d'audit.

Troisièmement, les réglementations émergentes comme l'**EU AI Act** ajoutent une couche supplémentaire de complexité : les organisations utilisant l'IA dans leurs processus de migration doivent documenter de manière exhaustive les flux de données, avec des amendes pouvant atteindre **7,5 à 35 millions d'euros** en cas de non-conformité.

L'intégration du data lineage dans le cadre de gouvernance offre des avantages concrets :

amélioration de la redevabilité, support au troubleshooting, analyse d'impact proactive lors des mises à jour, et simplification des audits de conformité.




FIGURE 3.3 – Exemple de traçabilité des données (Data Lineage)

3.1.2 Solutions existantes sur le marché

3.1.2.1 Outils ETL traditionnels

Le marché des outils ETL traditionnels est dominé par trois acteurs majeurs, chacun avec ses forces et ses limites :

Informatica PowerCenter est considéré comme la référence enterprise-grade. Il offre une large connectivité (Oracle, DB2, Teradata, NoSQL), un profilage automatique des données, et des mécanismes robustes de gestion des erreurs. Cependant, son coût de licence élevé, sa courbe d'apprentissage abrupte et son interface vieillissante limitent son accessibilité.

Talend propose une approche open-source (Talend Open Studio) complétée par une édition entreprise. Basé sur Java, il offre plus de 900 connecteurs, un support natif du Big Data (Hadoop, Spark), et une interface drag-and-drop accessible. Il constitue un choix privilégié pour les organisations cherchant flexibilité et maîtrise des coûts.

SSIS (SQL Server Integration Services) de Microsoft est intégré à SQL Server sans coût de licence additionnel. Performant dans les environnements Microsoft-centric, il souffre néanmoins d'un support limité pour les systèmes non-Microsoft et d'une scalabilité restreinte en environnements hétérogènes.

Le Tableau ?? présente une comparaison détaillée de ces trois outils.

TABLE 3.3 – Comparaison des outils ETL traditionnels

Critère	Informatica	Talend	SSIS
Type	Propriétaire	Open-source + Enterprise	Propriétaire (inclus SQL Server)
Coût	Élevé	Gratuit (OS) / Modéré (Ent.)	Inclus avec SQL Server
Cloud	Fort (IICS)	Excellent (cloud-native)	Limité (via ADF)
Big Data	Add-ons requis	Support natif (Spark, Hadoop)	Support basique
Connectivité	Très large	900+ connecteurs	Fort en Microsoft
Courbe d'apprentissage	Raide	Modérée	Modérée

3.1.2.2 Services cloud natifs

L'essor du cloud a donné naissance à des services d'intégration de données entièrement managés :

AWS Glue est un service ETL serverless basé sur Apache Spark, intégré à l'écosystème AWS (S3, Redshift, Athena). Il propose un Data Catalog automatisé, le support batch et streaming, et un studio visuel de développement de pipelines.

Azure Data Factory (ADF) de Microsoft offre plus de 90 connecteurs natifs, des Data Flows Spark pour les transformations no-code, et un runtime d'intégration hybride permettant de connecter données on-premise et cloud. Son intégration avec Azure Synapse, Databricks et Power BI en fait un choix naturel pour les organisations dans l'écosystème Microsoft.

Google Cloud Dataflow, basé sur Apache Beam, se distingue par son modèle unifié batch/streaming et sa facturation à la seconde. Il excelle dans le traitement en temps réel et les workloads analytiques avancés.

Le Tableau ?? compare ces trois services cloud.

TABLE 3.4 – Comparaison des services cloud natifs

Critère	AWS Glue	Azure Data Factory	GCP Dataflow
Moteur	Apache Spark	Spark (Data Flows)	Apache Beam
Modèle	Serverless	Serverless + IR	Serverless
Connecteurs	70+	90+	Google Cloud natif
Streaming	Oui (Kinesis, MSK)	Limité	Excellent (Pub/Sub)
Coût/TB batch	~1,84	~1,42	~2,11
Latence streaming p99	~120ms	~148ms	~89ms

3.1.2.3 Approches ad hoc / scripts custom

De nombreuses organisations développent encore des scripts ad hoc (SQL, Python, Shell) pour gérer leurs migrations. Cette approche offre une flexibilité maximale et un coût initial faible, mais présente des limites critiques : absence de standardisation, aucune traçabilité intrinsèque, dépendance aux développeurs individuels, maintenance difficile, et risque élevé d'erreurs sur les projets à grande échelle.

3.1.2.4 Analyse comparative et limites communes

Malgré leurs différences, toutes ces solutions partagent des limitations structurelles communes :

- **Le fossé Design-Build** : dans chaque cas, les spécifications fonctionnelles doivent être traduites manuellement en code exécutable par une équipe technique, créant un risque permanent de décalage entre le design et l'implémentation.
- **Effet boîte noire** : les moteurs ETL traditionnels ne permettent pas aux équipes fonctionnelles de vérifier directement que le code implémenté correspond aux spécifications validées.
- **Absence de couche métier** : les services cloud natifs sont performants pour le transport de données, mais manquent de la couche fonctionnelle nécessaire pour gérer les règles de transformation complexes, les Key Decisions, et la validation métier itérative.
- **Coûts cachés** : licences logicielles, infrastructure dédiée, main-d'œuvre technique spécialisée, et coûts de maintenance s'accumulent au fil du projet.

C'est dans ce contexte que la plateforme ADMP se positionne comme une réponse industrielle visant à combler ces lacunes.

3.1.3 La plateforme ADMP : état actuel

3.1.3.1 Philosophie et principes fondateurs

L'**Accenture Data Migration Platform (ADMP)** est une plateforme propriétaire développée par Accenture depuis plus de 25 ans, dédiée à l'accélération, l'automatisation et la sécurisation des projets de migration de données à grande échelle. Sa philosophie repose sur un constat fondamental : « *Migration is not an investment priority : it is a cost that delivers few benefits in itself. However, Migration is highly risky and an essential part of the wider transformation project success* ».

Pour répondre à ce constat, ADMP s'articule autour de trois principes fondateurs :

- **Smart Designs** : des documents structurés (Word/Excel) qui décrivent les règles de transformation, les mappings de champs, les relations entre tables et les contraintes métier. Ces documents sont à la fois lisibles par les équipes fonctionnelles et interprétables automatiquement par la plateforme.
- **No-Code / Low-Code** : « *No ETL developer required. Smart designs are executed on ADMP platform with no manual action required* », ce qui élimine le fossé Design-Build identifié comme limitation majeure des solutions existantes.
- **Transparence totale** : « *No black box effect* », les équipes fonctionnelles ont une visibilité et un contrôle complets sur le processus de migration, contrairement aux outils ETL traditionnels.

L'ADMP fait partie de l'**Accenture Migration Suite**, un ensemble de composants de migration qui peuvent être utilisés individuellement ou combinés pour transformer, nettoyer, archiver, réactiver et rechercher des données, offrant ainsi une réponse complète à la décommission des systèmes legacy.

3.1.3.2 Architecture fonctionnelle existante

L'architecture actuelle d'ADMP se compose de quatre modules principaux, décrits dans le Tableau ??.

TABLE 3.5 – Modules de la plateforme ADMP

Module	Type	Fonction
ADMP Core Engine	Moteur de migration	Récupère les documents de design depuis Teams/SharePoint, se configure automatiquement, et exécute le cycle ETL complet
ADMP Design Tools	Plugins VBA (Word/Excel)	Création structurée et standardisée des documents de design
ADMP Portal	Interface web	Lancement des extractions/transformations/chargements, consultation des rapports, analyse des erreurs
IDMF Explorer	Outil de versioning	Gestion de configuration des documents via SharePoint

L'hébergement de la plateforme est flexible : **SaaS** (datacenter sécurisé) ou **On-Premise** (installé dans l'environnement du client). Les transferts de données sont sécurisés via SFTP/VPN.




FIGURE 3.4 – Architecture fonctionnelle de la plateforme ADMP

3.1.3.3 Méthodologie ADM for ADMP

La méthodologie **ADM for ADMP** (Accenture Delivery Method for ADMP) structure le processus de migration en cinq phases :

1. **Discovery** : Analyse initiale du périmètre, identification des systèmes source et cible, cadrage du projet.
2. **Data Analysis (Design Phase 1)** : Phase itérative comprenant la création des Data Scopes (SDS, TDS), du Table Mapping et du Data Mapping. L'objectif est de « *validate the scope of the Data Migration and identify most of the gaps between the source system and the target system* ».
3. **Detailed Design (Design Phase 2)** : Élaboration des spécifications fines : Migration Steps (MS), Data Structure (DS), Intermediary Data Scope (IDS), Record Creation (RC), Data Population (DP), et Transcodification Tables (TT).
4. **Build & Test** : Le Core Engine génère automatiquement les programmes de migration à partir des Smart Designs. Les données sont extraites, transformées et chargées, puis validées via des rapports automatiques.
5. **Deploy** : Migration finale en production, réconciliation des volumes, et validation post-migration.

L'ensemble de la méthodologie est enseigné dans la **Core ADMP Design School (CIDS)**, une formation intensive de **deux semaines (80 heures)** couvrant la théorie, la pratique et les exercices sur tous les livrables ADMP.




FIGURE 3.5 – Les cinq phases de la méthodologie ADM for ADMP

3.1.3.4 Les livrables structurés

Chaque livrable ADMP répond à un besoin précis dans la chaîne de migration, comme le résume le Tableau ??.

TABLE 3.6 – Livrables structurés de la plateforme ADMP

Livrable	Phase	Rôle
SDS	Data Analysis	Dictionnaire des tables et champs sources
TDS	Data Analysis	Dictionnaire des tables et champs cibles
Table Mapping	Data Analysis	Correspondance tables source ↔ cible
Data Mapping	Data Analysis	Correspondance champs source ↔ cible
Key Decisions	Transversal	Suivi des écarts majeurs et décisions métier
Q&A	Transversal	Questions/réponses avec le client
MS	Detailed Design	Workflows par domaine avec dépendances
IDS	Detailed Design	Tables intermédiaires réutilisables
DS	Detailed Design	Modèle hiérarchique des relations
RC	Detailed Design	Règles de création d'enregistrements cibles
DP	Detailed Design	Règles de peuplement des champs cibles
TT	Detailed Design	Tables de correspondance de codes

3.1.3.5 Bilan : forces et chiffres clés

Les chiffres clés d'ADMP ont déjà été présentés dans le Tableau ?? de l'introduction générale. La comparaison directe entre l'approche ADMP et l'approche ETL standard révèle des avantages structurels significatifs, synthétisés dans le Tableau ??.

TABLE 3.7 – Comparaison ADMP vs ETL standard

Critère	ETL Standard	ADMP Smart Designs
Build	Équipe technique requise	Aucun développeur ETL requis
Traçabilité	Impossible de valider design vs implémentation	Une seule source de vérité
Rapports	Développés en supplément	Générés automatiquement
Scalabilité	Contrainte par les outils/équipes	Gérée par design et templates
Mises à jour	Nouvelle implémentation requise	Mise à jour du Smart Design uniquement
Réutilisabilité	Compétences techniques avancées requises	Personnalisation facile (Word/Excel)

3.1.4 Intelligence artificielle et intégration de données

3.1.4.1 LLM et génération de code (GPT, Mistral, fine-tuning, LoRA)

Les **Large Language Models (LLM)** ont révolutionné le domaine de la génération automatique de code et de la compréhension du langage naturel. Des modèles comme GPT-4, Llama 3, Claude et Mistral sont capables de générer du code SQL, Python ou PySpark à partir de spécifications en langage naturel, ouvrant des perspectives considérables pour l'automatisation des processus de migration.

La technique de **LoRA (Low-Rank Adaptation)**, introduite par Hu et al. (2021), a transformé l'approche du fine-tuning en permettant d'adapter des modèles de plusieurs milliards de paramètres avec une fraction des ressources habituellement nécessaires. LoRA gèle les poids du modèle pré-entraîné et injecte des matrices de rang faible entraînables dans chaque couche, réduisant les paramètres entraînaibles de **99%+** tout en atteignant **95-98% de la performance** d'un fine-tuning complet.

Concrètement, le fine-tuning d'un modèle Llama 3.1 70B passe de **8 GPU A100 pendant 48 heures (~15 000 \$)** en fine-tuning complet à **1 GPU A100 pendant 4 heures (~500 \$)** avec LoRA. Cette démocratisation rend le fine-tuning accessible pour des cas d'usage spécifiques à un domaine, comme la génération de règles de transformation de données.

La variante **QLoRA** combine LoRA avec une quantification 4-bit, permettant le fine-tuning sur du matériel grand public, une avancée particulièrement pertinente pour les équipes ne disposant pas d'infrastructure GPU dédiée.




FIGURE 3.6 – Principe du fine-tuning avec LoRA (Low-Rank Adaptation)

3.1.4.2 RAG (Retrieval-Augmented Generation)

Le **RAG (Retrieval-Augmented Generation)**, introduit par Lewis et al. (2020), est une architecture qui enrichit les LLM en les couplant avec des sources de connaissances externes au moment de l'inférence. Plutôt que de s'appuyer uniquement sur les connaissances intériorisées

lors de l'entraînement, le RAG récupère dynamiquement des passages pertinents depuis une base documentaire et les injecte dans le contexte du modèle pour générer des réponses factuellement ancrées.

L'architecture RAG se décompose en deux composants principaux :

- **Le composant de récupération** : les requêtes sont encodées en vecteurs denses, puis comparées aux vecteurs de documents pré-encodés dans une base vectorielle (FAISS, pgvector, Pinecone). Les passages les plus pertinents sont extraits.
- **Le composant de génération** : les documents récupérés sont combinés avec la requête pour produire une réponse contextuelle et précise via le LLM.

Microsoft propose une architecture RAG de référence dans Azure Architecture Center, intégrant Azure AI Search, Semantic Kernel et des modèles de langage pour construire des applications d'entreprise robustes.

Dans le contexte de la migration de données, le RAG permet d'exploiter la documentation existante (SDS, TDS, RC, DP) comme base de connaissances pour assister les spécificateurs dans la rédaction de règles, la résolution de questions fonctionnelles, et la validation des designs.




FIGURE 3.7 – Architecture Retrieval-Augmented Generation (RAG)

3.1.4.3 Agents IA et automatisation de workflows

Les **agents IA** représentent une évolution majeure par rapport à l'automatisation traditionnelle. Contrairement aux systèmes RPA (*Robotic Process Automation*) qui suivent des scripts prédéfinis, les agents IA combinent perception, raisonnement et action pour accomplir des objectifs de manière autonome.

Leurs caractéristiques distinctives incluent :

- **Autonomie** : fonctionnement indépendant sans supervision constante.
- **Conscience contextuelle** : compréhension des scénarios métier nuancés.
- **Raisonnement multi-étapes** : décomposition de tâches complexes en sous-tâches exécutables.

- **Auto-correction** : identification et rectification des erreurs en cours d'exécution.
- **Intégration d'outils** : connexion transparente avec APIs, bases de données et systèmes d'entreprise.

Le marché mondial des agents IA est estimé à **5,1 milliards USD en 2024**, avec une projection à **47,1 milliards USD d'ici 2030** (CAGR de 44,8%). Toutefois, selon Gartner (2025), moins de **5% des applications d'entreprise intègrent de véritables agents IA** à ce stade, la majorité n'utilisant que des assistants basiques.

3.1.4.4 Applications de l'IA dans la migration de données

L'application de l'IA au domaine spécifique de la migration de données est un champ émergent mais prometteur, avec cinq cas d'usage à fort impact identifiés par Blackburn (2025) :

- **Mapping automatique de schémas** : les modèles ML analysent la structure, le contenu et les métadonnées des sources pour suggérer des correspondances source-cible, réduisant le temps de mapping de **30-60%**.
- **Évaluation et nettoyage de la qualité** : les LLM détectent les anomalies que les règles statiques ne capturent pas, et peuvent suggérer des actions de nettoyage automatiques.
- **Génération de données synthétiques de test** : les modèles génératifs produisent des jeux de test réalistes préservant les propriétés statistiques sans exposer de données réelles.
- **Planification intelligente de la migration** : le reinforcement learning optimise l'ordonnancement des lots de migration en fonction des dépendances et des contraintes de fenêtre.
- **Monitoring et détection d'anomalies en production** : des pipelines de détection identifient les écarts en temps réel et accélèrent le triage des erreurs.

La plateforme **MAiGRATE** de Compliance Group illustre cette tendance : elle combine IA, ML et LLM pour automatiser l'ingestion, la transformation, le mapping de champs, la déduplication, la détection d'anomalies et la validation, avec un apprentissage continu améliorant la précision à chaque cycle de migration.

3.1.5 Limites de l'existant et opportunités

3.1.5.1 Limites des outils de design actuels

Les Design Tools actuels d'ADMP reposent sur des **plugins VBA intégrés à Word et Excel**. Si cette approche a l'avantage d'utiliser des outils familiers aux équipes fonctionnelles, elle présente des limitations de plus en plus critiques :

- **Technologie vieillissante** : VBA est un langage de macro datant des années 1990, dont le support et l'évolutivité sont limités.

- **Pas de collaboration en temps réel** : contrairement aux outils web modernes, les documents Word/Excel ne permettent pas l'édition simultanée avec traçabilité fine.
- **Intégration IA impossible** : l'architecture VBA ne permet pas d'intégrer nativement des appels à des API d'IA (OpenAI, Bedrock) pour assister la rédaction.
- **Maintenance complexe** : les macros VBA sont fragiles, sensibles aux versions d'Office, et difficiles à déboguer.

3.1.5.2 Rédaction manuelle des spécifications

La rédaction des spécifications de migration (RC, DP, DS, TT) reste un processus **largement manuel et chronophage**. Chaque document nécessite une compréhension approfondie du modèle source, du modèle cible, et des règles métier spécifiques. Comme le souligne la présentation d'évolution ADMP, l'un des objectifs stratégiques de la modernisation est de « *Optimize and accelerate the time needed to write specifications* » et de « *Create a true wizard for specifiers and reduce the overall burden* ».

Le rapport PFE de Abbad el andaloussi, Larbi estime que l'automatisation de la génération des livrables de migration permettrait une **réduction de 50 à 60% du temps** nécessaire à leur production, tout en minimisant les risques d'erreurs humaines.

3.1.5.3 Absence d'IA dans le processus de migration

Malgré les avancées considérables de l'IA dans d'autres domaines de l'IT, le processus de migration ADMP reste **dépourvu d'intelligence artificielle**. Aucun module IA n'assiste actuellement les spécificateurs dans la rédaction des règles, la détection des incohérences, ou la validation automatique des designs. Cette absence représente une opportunité majeure d'amélioration.

3.1.5.4 Dépendance à l'expertise humaine

La qualité de la migration repose fortement sur l'expertise individuelle des Data Analysts. L'**onboarding** de nouveaux membres nécessite une formation intensive (la CIDS dure **2 semaines (80 heures)**) et l'acquisition de la maturité opérationnelle prend plusieurs mois supplémentaires. Cette dépendance crée un risque de perte de connaissances (*knowledge drain*) lors des rotations d'équipe et limite la scalabilité des opérations.

3.1.6 Synthèse et positionnement de la contribution

3.1.6.1 Tableau de synthèse des gaps identifiés

Le Tableau ?? synthétise les principaux gaps identifiés et les opportunités associées.

TABLE 3.8 – Synthèse des gaps identifiés et opportunités

Gap identifié	Impact	Opportunité
Outils de design VBA obso- lètes	Pas de collaboration, pas d'IA	→ ADMP Studio (outil web mo- derne)
Rédaction manuelle des spéci- fications	Chronophage, risque d'erreur	→ ADMP AI Engine (généra- tion assistée)
Absence d'IA dans le proces- sus	Aucune assistance intelligente	→ Intégration LLM + RAG
Dépendance à l'expertise hu- maine	Onboarding long, scalabilité limitée	→ Assistant IA pour spécifica- teurs
Pas de génération automa- tique de code	Build manuel des pro- grammes	→ Bundle Databricks (notre contribution)

3.1.6.2 Positionnement du PFE

L'analyse de l'état de l'art révèle que la plateforme ADMP, malgré sa maturité et ses avantages concurrentiels significatifs, se trouve à un tournant stratégique. Les outils existants ont prouvé leur efficacité pendant plus de 25 ans, mais l'absence d'intelligence artificielle dans le processus constitue désormais un frein à l'innovation et à la compétitivité.

Le programme d'évolution d'ADMP, articulé autour de l'**ADMP AI Engine**, de l'**ADMP Studio** et de l'amélioration des outils de design, vise à combler ces gaps.

Notre contribution, le **développement du module de génération du bundle Databricks**, s'inscrit précisément dans cet axe d'industrialisation. Ce module vise à automatiser la création des artefacts de migration en s'appuyant sur des technologies de traitement distribué (Apache Spark / Databricks) et d'intelligence artificielle générative, transformant ainsi les Smart Designs en programmes exécutables sur des infrastructures cloud modernes.

Ce positionnement se situe à l'intersection de trois tendances identifiées dans l'état de l'art : l'**automatisation du cycle Design-Build** (section ??), l'**application de l'IA à la migration** (section ??), et le besoin de **modernisation des outils** (section ??). Le chapitre suivant présentera le cadre méthodologique et organisationnel dans lequel ce travail a été réalisé.

Chapitre 4

Méthodologie et designe

4.1 Methodology and Design

Describes how the student planned and designed the solution before touching any code or implementation. This includes :

1. Functional and non-functional requirements
2. System architecture diagrams (UML, component diagrams, data-flow diagrams)
3. Design decisions and their justification

4.1.1 Requirements Analysis

4.1.2 System Architecture

4.1.3 Design Choices and Justification

Chapitre 5

Implementation

5.1 Implementation

Documents the development process in detail — tools, languages, frameworks, version control strategy, and key modules built. Students should describe the most technically significant parts of their work and explain how they overcame difficulties. Code snippets can be included but should be kept concise.

5.1.1 Development Environment

5.1.2 Key Modules and Components

5.1.3 Difficulties and Solutions

5.2 Results and Evaluation

Presents what was produced and how well it works. Students should include :

1. Test cases and their outcomes
2. Performance metrics, benchmarks, or user feedback
3. Screenshots or figures illustrating the final product
4. A honest discussion comparing results against the initial objectives

5.2.1 Testing and Validation

5.2.2 Discussion

5.3 Conclusions and Future Work

The closing chapter with two subsections :

1. Conclusions — what was accomplished, whether objectives were met, and personal reflections on the internship experience
2. Future Work — what could not be done due to time or scope constraints, and concrete suggestions for whoever continues the project

5.3.1 Conclusions

5.3.2 Future Work

.1 Appendix A : ...

Supporting material that is too detailed for the main body but necessary for completeness.
Typical content includes :

1. Full source code listings
2. Database schemas
3. API documentation
4. User manuals or installation guides
5. Raw data tables or additional figures

Each appendix should be a separate

.2

with a clear label (Appendix A, B, etc.) and referenced from the relevant chapter using ??.

.3 Appendix B : ...